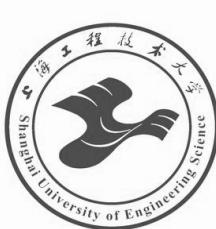


中图分类号:

学校代码: 10856

学 号: M025120320



上海工程技术大学硕士学位论文

基于 PDR 和 RSSI 融合的 室内行人定位技术研究

作者姓名: 杨运成

指导教师: 吴 飞

专 业: 电子信息

学 院: 电子电气工程学院

申请学位: 工程硕士

完成时间: 2023 年 3 月

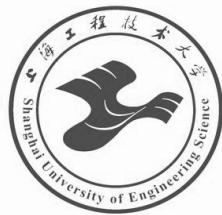
评 阅 人 : _____

答 辩 委 员 会 主 席: _____

成 员: _____

University Code: 10856

Student ID:



Research On Indoor Pedestrian Location Technology Based on PDR and RSSI Fusion

Candidate: Yuncheng Yang

Supervisor: Fei Wu

Major: Electronic Information

School of Electronic and Electrical Engineering

Shanghai University of Engineering Science

Shanghai, P.R. China

May, 2023

上海工程技术大学

学位论文原创性声明

本人郑重声明：所递交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海工程技术大学

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海工程技术大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密，在____年解密后适用本授权书。

本学位论文属于

不保密。

(请在以上方框内打“√”)

学位论文作者签名:

日期: 年 月 日

指导教师签名:

日期: 年 月 日

基于 PDR 和 RSSI 融合的室内行人定位技术研究

摘要

随着智能设备的普及和智慧建筑群的涌现，位置服务（Location Based Service, LBS）已成为移动设备不可或缺的基本信息之一。在室外情况下，卫星导航系统已经基本满足人们的需求，但在复杂室内环境下，由于建筑物遮挡和多径效应等问题，提供准确可靠的室内定位服务成为研究热点。目前，基于蓝牙信号强度指示值（Received Signal Strength Indication, RSSI）的定位技术具有低成本和高精度的优势，但其无线射频信号在传播过程中易受环境影响而导致定位结果不稳定；基于惯性传感器的行人航位推算（Pedestrian Dead Reckoning, PDR）定位技术能够在短时间内实现高精度连续定位，但受传感器误差影响，其定位轨迹会随时间推移产生漂移。因此，本文基于智能终端设备为载体，通过改进蓝牙 RSSI 定位和 PDR 定位技术，采用融合定位算法来提高行人室内定位的精度。论文主要研究工作如下：

1) 针对蓝牙 RSSI 信号在室内定位中受干扰问题。首先分析 RSSI 信号分布特性和传播规律，对信号在受干扰下会出现骤升和急降的异常值现象，提出一种基于 iForest-MF 的 RSSI 信号修正方法。该方法采用孤立森林分割 RSSI 信号，检测出偏离的异常值，并采用均值滤波平滑处理，以还原贴近理论下的蓝牙 RSSI 信号。其次，本文改进了蓝牙 RSSI 定位方法中的双距离加权质心算法，通过改进权重分配和引入修正系数，提高了蓝牙技术定位的精度。实验结果表明，相对于双距离加权质心算法，在静态定位中，本文改进算法的定位精度提高了 9.18%；在动态定位中，其 OWD（One Way Distance）距离轨迹相似度提高了 15.1%。

2) 针对 PDR 定位中由于传感器噪声所导致的计步误差和航向角误差问题。首先利用行人加速度和角速度特征信息，提出一种 CNN-BiLSTM-SA 模型以实现行人在不同运动模式下的识别，其准确率达到 98.52%。其次，针对步频检测中伪波峰导致的计数误差问题，在运动模式识别的基础上提出一种基于自适应最小峰距和自适应动态阈值的步频检测算法，其平均误差率为 1.31%。最后，针对实际运动中航向角累积误差导致的航向漂移问题，本文在航向估计中设计一种转向判断阈值，通过该优化减少了航向角累积误差，提高了 PDR 算法的定位精度。

3) 针对蓝牙定位结果跳跃、不连续问题和 PDR 定位的传感器累积误差导致轨迹漂移现象，采用 EKF (Extended Kalman Filter) 算法将两种定位结果进行融合。实验结果表明，相比与本文提出的蓝牙算法和 PDR 算法，EKF 算法的定位平均误差降低了 13.30% 和 10.29%，OWD 距离精度分别提高 12.96% 和 8.49%。

关键词：室内定位，蓝牙定位，行人航位推算，模式识别，融合定位，扩展卡尔曼滤波

RESEARCH ON INDOOR PEDESTRIAN LOCALIZATION TECHNOLOGY BASED ON PDR AND RSSI FUSION

ABSTRACT

With the widespread use of smart devices and the emergence of intelligent building clusters, Location Based Service (LBS) has become one of the essential basic information for mobile devices. While satellite navigation systems have largely met people's needs in outdoor environments, providing accurate and reliable indoor positioning services has become a research hotspot due to issues such as building obstruction and multipath effects in complex indoor environments. Currently, location technologies based on Bluetooth Received Signal Strength Indication (RSSI) have the advantages of low cost and high accuracy, but their wireless radio frequency signals are easily affected by the environment during propagation, leading to unstable positioning results. Pedestrian Dead Reckoning (PDR) positioning technology based on inertial sensors can achieve high-precision continuous positioning in a short time, but its positioning trajectory will drift over time due to sensor errors. Therefore, this thesis proposes to use smart terminal devices as carriers, improve Bluetooth RSSI positioning and PDR positioning technologies, and adopt a fusion positioning algorithm to improve the accuracy of pedestrian indoor positioning. The main research work of this thesis is as follows:

- 1) In response to the interference issue of Bluetooth RSSI signal-based indoor positioning, this study first analyzed the distribution characteristics and propagation patterns of RSSI signals. It was found that under interference, signals may exhibit abnormal value phenomena such as sudden spikes and sharp drops. To address this, an iForest-MF-based RSSI signal correction method was proposed. This method uses Isolation Forest to segment RSSI signals, detects deviating abnormal values, and uses mean filtering to smooth the signals to restore Bluetooth RSSI signals close to theoretical values. Secondly, this study improved the double distance weighted centroid algorithm in Bluetooth RSSI positioning method. By improving the weight allocation and introducing a correction factor, the accuracy of Bluetooth technology positioning was enhanced. The experimental results showed that

compared to the double distance weighted centroid algorithm, the improved algorithm in this study increased the positioning accuracy by 9.18% in static positioning and improved the OWD (One Way Distance) distance trajectory similarity by 15.1% in dynamic positioning.

2) To address the issue of step counting errors and heading angle errors caused by sensor noise in PDR positioning, this study first utilized pedestrian acceleration and angular velocity features to propose a CNN-BiLSTM-SA model for pedestrian recognition in different motion modes, achieving an accuracy of 98.52%. Secondly, to address the counting errors caused by spurious peaks in step frequency detection, a step frequency detection algorithm based on adaptive minimum peak distance and adaptive dynamic threshold was proposed on the basis of motion mode recognition, with an average error rate of 1.31%. Finally, to address the heading drift problem caused by cumulative error in actual motion, this study designed a turning judgment threshold in heading estimation, which optimized the cumulative heading angle error and improved the positioning accuracy of the PDR algorithm.

3) To address the issues of Bluetooth positioning results jumping, discontinuity, and trajectory drift caused by cumulative sensor error in PDR positioning, the Extended Kalman Filter (EKF) algorithm was used to fuse the two positioning results. The experimental results show that compared to the Bluetooth algorithm and PDR algorithm proposed in this study, the EKF algorithm reduced the average positioning error by 13.30% and 10.29%, and improved the OWD (One Way Distance) distance accuracy by 12.96% and 8.49%, respectively.

KEY WORDS: Indoor positioning, Bluetooth positioning, Pedestrian dead reckoning, pattern recognition, fusion positioning, Extended Kalman Filter.

目 录

第一章 绪 论	1
1.1 课题研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于无线电的定位技术	2
1.2.2 基于非无线电的定位技术	4
1.3 主要研究内容	6
1.4 论文组织结构和安排	7
第二章 室内定位相关技术介绍	9
2.1 蓝牙定位技术原理	9
2.1.1 蓝牙设备介绍与测距模型	9
2.1.2 基于测距的定位方法	11
2.1.3 基于非测距的定位方法	12
2.2 PDR 定位技术原理	14
2.2.1 步频检测	16
2.2.2 步长估计	17
2.2.3 航向估计	19
2.3 融合定位算法	19
2.3.1 卡尔曼融合算法	19
2.3.2 粒子滤波融合算法	20
2.4 本章小结	21
第三章 基于 iForest-MF 修正 RSSI 的加权质心定位方法	22
3.1 RSSI 信号传播特征分析	22
3.1.1 RSSI 信号分布特性分析	22
3.1.2 RSSI 信号传播规律分析	25
3.2 基于 iForest-MF 的 RSSI 修正方法	26
3.2.1 基于 iForest 的异常值检验	26
3.2.2 iForest-MF 组合滤波	29
3.3 改进的 RSSI 加权质心定位方法	31
3.3.1 加权质心定位算法	31
3.3.2 基于距离修正的加权质心定位算法	32

3.4 实验设计与结果分析	33
3.4.1 实验设计	33
3.4.2 实验结果分析	35
3.5 本章小结	36
第四章 支持行人模式感知的 PDR 定位优化方法	37
4.1 基于 CNN-BiLSTM-SA 的行人运动模式识别	37
4.1.1 运动模式划分	37
4.1.2 CNN-BiLSTM-SA 模型	38
4.1.3 模型评价	42
4.2 基于运动模式识别的自适应步频检测	44
4.2.1 基于混合滤波的数据预处理	44
4.2.2 基于特征约束的峰值检测算方法	46
4.2.3 步频实验分析	50
4.3 行人航向估计的优化算法	53
4.3.1 姿态角估计	53
4.3.2 航向优化	57
4.4 本章小结	59
第五章 融合定位算法与实验分析	60
5.1 PDR/RSSI 融合定位流程与算法	60
5.2 融合定位实验验证与分析	63
5.2.1 实验场景与条件	63
5.2.2 蓝牙定位实验验证	64
5.2.3 PDR 定位实验验证	65
5.2.4 EKF 融合定位实验验证	66
5.3 本章小结	68
第六章 总结与展望	69
6.1 本文工作总结	69
6.2 未来工作展望	70
参考文献	71
攻读硕士学位期间发表的学术论文及取得的相关科研成果	76
致 谢	77

第一章 绪 论

1.1 课题研究背景及意义

随着智能移动设备的应用与发展，位置服务已成为移动设备必不可少的基本信息之一^[1]。室内定位技术的研究旨在解决卫星导航系统（Global Navigation Satellite System, GNSS）无法在室内提供准确可靠的定位服务问题。虽然室外定位技术已经相对成熟，但在室内环境中，信号遮挡和时变环境等因素会影响卫星导航系统的精度和可靠性^[2]。随着现代化进程和城镇化步伐的加快，大型建筑数量不断攀升，人们对于室内定位服务的需求也日益增长。尤其是在商业、教育、医疗、安防等领域中，对于室内定位服务需求呈现出迅猛上升之势。根据《2018 年室内定位的发展前景分析》报告，我国室内定位市场的经济总量已超过 3000 亿元。

室内定位技术的应用将为人们的生活和工作带来更加智能化和便利化的体验^[3]。目前，国内外的很多大型商业中心通过利用室内定位技术，使得消费者可以更加方便地找到自己需要的商家和产品。在医疗领域，室内定位也可以用于医院导诊和患者定位，使得医疗服务更加便捷和高效。在智慧城市建设中，室内定位技术可以用于智能交通、智能停车等领域，使城市交通更加流畅和便捷。

为了满足人们对室内定位服务的需求，国内外的研究者积极开展室内定位技术的研究和相关标准的制定。例如，2013 年科技部和 863 计划导航主题专家组联合发布的《室内外高精度定位导航白皮书》明确提出应加强室内定位技术的研究，以提高室内外协同实时精密定位的能力。除了政策支持之外，商业巨头也积极投入室内定位导航系统的研发，以促进该领域生态系统成熟。例如，谷歌、苹果、华为、阿里巴巴等公司都在室内定位领域投入了大量的研发资金^[4]。这些公司积极探索使用不同的技术来提高室内定位精度和可靠性，并不断优化算法，提高定位的准确度和稳定性。

由于智能手机的发展，现在的室内定位产品无需像过去需要购买昂贵复杂的设备，只需通过手机内置的丰富传感器元件，便可以实现较为精准的定位结果。例如，手机里内置加速度计、陀螺仪等传感器所提供的数据可用于行人航位推算。内置的蓝牙模块，可以接收低功耗蓝牙发射的射频信号。将两者融合，便可仅用手机就能实现精准

的室内位置服务。综上所述，随着智能设备的普及，室内定位技术将在更多领域得到应用，其未来发展前景十分广阔。因此，室内定位技术的研究和发展具有非常重要的意义，需要加强相关的研究和开发以推动其在各个领域的广泛应用。

1.2 国内外研究现状

室内定位技术可以广泛应用于商业、教育、医疗、安防等领域。由于 GNSS 定位系统无法在复杂室内环境下提供准确可靠的位置服务，因此国内外的研究者都在积极探索新的技术和方法，大致可以分为基于无线电的定位技术和非无线电的定位技术两种。

1.2.1 基于无线电的定位技术

无线电定位技术是一种将电磁波在时空中的传播规律应用于物体距离测量和定位的方法。随着无线通信技术的发展，新兴的无线网络技术正在广泛应用，常用的几种室内无线电定位技术如下：

1) 低功耗蓝牙定位技术

低功耗蓝牙（Bluetooth Low Energy, BLE）是蓝牙技术的一种变体，专门设计用于低功耗和短距离数据传输。相对传统蓝牙技术，低功耗蓝牙在传输速度和功耗上都有很大的改进，可以广泛用于室内定位和物联网等领域^[5]。

通常，低功耗蓝牙室内定位是基于蓝牙 RSSI 的定位方法，该方法通常分为两类：一种是基于测距方法，另一种是基于非测距方法例如指纹法^[6,7]和质心定位法^[8,9]。基于测距的定位方法是通过测量移动设备与参考节点之间的距离来确定设备的位置。Xue 等人^[10]结合滤波处理技术，采用 RSSI 物理距离差分定位策略，最终实现了 3m 到 6m 之间的平均定位精度。唐宗山等人^[11]通过信号差分改进了最小二乘定位算法，实现平均定位精度约 2m 左右。陶金龙等人^[12]提出一种基于 RSSI 测距的加权概率定位算法，通过将未知节点区域划分成栅格并构建信号传播概率模型，解决无线传感网络中链路衰减因子不同的问题。在非测距方法中，指纹定位法是通过创建环境地图，在不同位置采集蓝牙信标的 RSSI 数据并存储在数据库中，形成该位置的“指纹”。在定位期间，移动设备测量附近蓝牙信标的 RSSI，并将其与指纹数据库进行比较以确定其位置。Li 等人^[13]通过对信号衰减的分析研究，提出一种快速采集指纹信息方法。

Zhang 等^[14]提出自主的众包系统用来动态更新指纹库，并对自动生成的数据库进行评估以降低更新成本。然而，指纹定位需要提前建立复杂的指纹库，并且需经常维护更新，在大范围定位中成本较高。质心定位是根据已知信标的位置，通过计算这些信标组成的多边形质心来估计移动设备的位置。由于该方法定位精度受信标布置密度等影响，因此常引入其他权重提高定位精度。林玮等人^[15]引入 RSSI 测距与三角质心结合的新型定位算法，以减少定位误差。熊海龙等人^[16]利用加权质心算法，将距离未知节点一定距离的锚节点来校正其定位坐标值，从而提高定位精度。

然而，蓝牙信号在室内传播时会受到复杂环境的多种干扰，这些干扰会影响蓝牙信号的传输和接收，从而降低室内定位的精度和稳定性。因此通常会对信号进行一定滤波来减少噪声，吴斌^[17]采用均值滤波和中值滤波等预处理方法对 RSSI 进行滤波处理，然后使用高斯滤波进行加权，得到较为精确的 RSSI 值。李桢等人^[18]基于 Friis 传输方程和运动学方程，采用抗差卡尔曼滤波方法对信号强度进行估计，以达到平滑信号的目的。

2) Wi-Fi 定位技术

Wi-Fi 是一种基于 802.11 IEEE 网络标准的设备无线局域网(WLAN)技术，运行在 2.4 和 5GHz 无线频段。Wi-Fi 网络被认为是室内定位的一种潜在解决方案^[19]，该技术利用建筑物中已有的 Wi-Fi 基础设施来确定支持 Wi-Fi 的设备（如智能手机或笔记本电脑）的位置。基于 Wi-Fi 的室内定位技术中，最常见的方法之一是指纹法，这涉及到从建筑物内的不同位置收集信号强度测量值的数据库，然后将设备的当前信号测量值与数据库中最接近的指纹集相匹配，以估计其位置^[20]。另一种方法是三角测量法，即使用信号强度或飞行时间测量法来测量设备与至少三个已知 Wi-Fi 接入点之间的距离。通过计算以已知信标为中心的圆相交处来确定设备位置，从而提供精确的定位估计。室内 Wi-Fi 定位的准确性取决于几个因素，包括建筑物内 Wi-Fi 信标密度、Wi-Fi 信号强度以及室内环境的复杂性。由于室内环境中 Wi-Fi 信号的衰减比蓝牙信号更为显著，因此在相同环境下，Wi-Fi 定位的精度较低于蓝牙定位。

3) UWB 定位技术

UWB (Ultra Wide Band) 是无线传感器网络中的一项重要技术^[21,22]，其原理是通过发射超短脉冲信号实现高精度室内定位。UWB 技术的工作频率范围在 3.1-10.6GHz 之间，可以实现高精度的位置跟踪和低延迟的数据传输。目前，UWB 在雷达成像、

车辆雷达、医疗设备等领域都有所应用。在 UWB 定位系统中，常用 AOA^[23] (Angle Of Arrival, AOA) 和 TDOA^[24] (Time Difference Of Arrival, TDOA) 两种不同的测量方法来确定目标和参考点之间的距离，但由于 UWB 定位技术需要使用专用的硬件和设备，而这些设备通常成本较高，因此可能会增加系统的总成本。

4) RFID 定位技术

RFID (Radio Frequency Identification) 是一种无线非接触技术，其主要功能是识别和跟踪标签或物品的位置^[25]。近年来，RFID 技术被越来越多地应用于室内定位领域，成为一种低成本、高效率的室内定位技术^[26]。RFID 技术可以实现对室内环境中的物品进行准确的定位和跟踪。其基本原理是在物品上植入 RFID 标签，并在室内布置 RFID 读取器，通过读取 RFID 标签的信号来确定物品的位置。但是 RFID 标签的读取距离较短，需要更密集地布置 RFID 读取器才能实现精确的定位，因此仅适合短距离定位服务。

1.2.2 基于非无线电的定位技术

在室内环境中无线电信号往往受到多径效应和衰减等影响，导致定位精度下降甚至无法定位。相比之下，不依赖于无线电信号的非无线电定位技术可以避免以上问题，同时在一些特定的场景下如高精度要求的应用场景，也可以提供更好的定位精度。常见的非无线电定位技术如下：

1) 惯性传感器定位技术

惯性传感器 (Inertial Measurement Unit, IMU) 是一种测量物体加速度和角速度的传感器，可以根据其测量数据来实时确定物体的位置和方向^[27,28]。用于定位的惯性传感器的两种最常见类型是加速度计和陀螺仪，加速度计测量物体的线性加速度，而陀螺仪测量物体的角速度。行人航位推算是惯性传感器定位技术的一种，即结合加速度计、陀螺仪等传感器测量数据来估计步频、步长和方向信息，进而推算出行人的运动轨迹来实现定位目的。该算法的实用性较高，无需额外布置定位设备，可以通过手机等移动设备进行使用。

PDR 算法原理核心可以分为步频检测、步长估计和航向估计三个部分。步频检测是保证 PDR 精确定位的重要一环，因此步频检测算法众多，其常见的有峰值检测法^[29]、过零检测法^[30]、自相关法^[31]和有限状态机四种。Wang 等^[32]通过组合低通滤波和

滑动平均滤波对加速度数据进行过滤，从而减少使用智能手机数据采集的波动影响。Van 等人^[33]提出四个特征限制来优化峰值检测算法，并利用周期规律减少虚假行走问题。Yao^[34]为了精准识别行走中每步的起始点，将波峰检测法和过零检测法相结合。由于行人步行状态复杂，通过运动分类也有效提高步频检测效果，Tian 等^[35]使用有限状态机对手机姿势分为摇摆、导航和口袋三类，准确率为 89%。Yang 等人^[36]设计一个随机森林分类摆臂、包内和上下衣口袋四种模式，准确率为 93.7%。步长估计是基于行人步频数量来计算走过的路径长度，常见的步长估计模型包括常数模型^[37]、线性模型^[38]、非线性模型^[39]以及机器学习模型^[40]等四种。航向估计通常通过陀螺仪、加速计和磁力计等传感器获取航向角信息，通过算法解算出航向信息，通常方法有欧拉角法、余弦矩阵和四元数法。尽管 PDR 算法在短时间内具有精准定位效果，但由于智能手机内置的传感器精度低且具有累积误差，长期定位会产生严重漂移现象，因此 PDR 也与其他定位技术融合使用，例如李景文等人^[41]将 PDR 技术与 UWB 技术利用卡尔曼滤波融合，定位精度均高于单独使用单一定位技术。Xu 等^[42]利用改进的滤波器对航向信号进行过滤，在与基于指纹的 RSSI 技术相结合，结果其平均精度约 0.8m。韩冷等^[43]利用蓝牙信号和 Wi-Fi 信号的多源信息，使用粒子滤波方法对 PDR 信息进行更新，有效抑制 PDR 定位的累积误差。

2) 地磁定位技术

由于地球的磁场是相对稳定和可预测的，围绕地球的磁场线在强度和方向上随地点和时间的不同而变化，但它们在大的地理区域内通常一致^[44,45]。因此，地磁定位技术利用智能手机或其他移动设备上的磁场传感器，检测建筑物或室内环境中存在的金属或磁性物体引起的磁场变化来实现定位^[46]。地磁定位技术使用建筑物的磁指纹，通过在不同位置绘制建筑物的磁场图来创建。磁指纹可以根据设备获取的磁场读数来定位用户在建筑物内的位置^[47]。地磁定位优势是不需要在建筑物内安装额外的硬件或基础设施，由于大多数智能移动设备已经内置了传感器，这使得它成为一种便捷的室内定位解决方案。然而，地磁定位技术有其局限性，特别是在金属物体密集或存在磁干扰的区域其定位精度会显著降低。

3) 视觉定位技术

视觉定位技术是一种使用视觉提示（例如由相机捕获的图像或视频）确定物体或人员精确位置的方法，这项技术广泛运用在导航、增强现实、机器人和自动驾驶车辆

等领域^[48,49]。视觉定位技术使用计算机视觉算法分析图像并提取特征，例如角点、边缘和纹理。然后将这些特征与预先存在的地图或参考图像数据库进行匹配，以确定物体的位置^[50]。该技术还可以结合其他传感器，例如陀螺仪、加速度计和 GPS 来提高定位精度和鲁棒性。例如，谷歌在 2017 年发布的 VPS (Visual Positioning System) 技术，通过对高分辨率摄像头采集到的图像进行智能分析和学习，可以对任意地点进行三维测绘定位和目标特征标识实现无 GPS 信号下的区域精准三维定位^[51]。同时，在自动驾驶车辆中使用相机和其他传感器用于检测和识别物体并在复杂环境中导航^[52]。视觉定位技术还用于机器人应用程序，例如仓库自动化，机器人可以使用视觉提示在仓库中导航并定位特定物品。然而，视觉定位技术也存在一些局限性。其中一种限制是它需要大量的计算资源和高性能计算机，以实时处理图像和视频数据。另一个限制是它对环境光照条件的敏感性，可能需要额外的光源或使用具有强大低光传感器的设备。

4) 超声波定位技术

超声波定位技术是使用超声波来定位在指定区域内的物体或设备。该技术通过从发射器发射高频声波，并由位于被定位物体或设备上的接收器接收这些声波来工作。通过分析发射和接收之间的时间差，可以计算发射器和接收器之间的距离，并用于确定被定位物体或设备的位置^[53,54]。相比视觉定位，超声波可以用于光线不佳的室内环境，其次它具有相对较高的精度，定位误差通常在几厘米到几米之间。但超声波在传播过程中遇到障碍会产生折射现象，这中现象会影响定位的准确性，因此其实际应用范围有限。

1.3 主要研究内容

根据上述室内定位技术的研究现状，本文对基于无线电的蓝牙定位技术与非无线电的 PDR 定位技术进行具体研究。针对蓝牙 RSSI 信号在受干扰下出现定位不稳定现象和 PDR 定位由于累积误差会导致定位轨迹漂移的问题，本文的主要研究内容如下：

1) 在基于蓝牙 RSSI 的室内定位研究中，为了降低干扰环境下对蓝牙 RSSI 信号的影响从而提高蓝牙定位精度。本文首先分析蓝牙 RSSI 信号的分布特性与传播规律，通过分析 RSSI 信号强度分布规律和环境的关系，提出先利用孤立森林算法检测受干

扰下的异常值，再使用均值滤波对信号进行平滑处理。最后在 RSSI 信号预处理的基础上，使用修改权值分配后的加权质心定位算法对蓝牙信号进行解算，从而提高蓝牙定位效果。

2) 在 PDR 定位技术研究中，为了降低行人运动中的计步误差和航向角误差。首先，根据行人的运动习惯进行分类，然后通过其加速度和角速度特征信息，设计了一种基于深度学习的分类器，以实现对行人在不同运动模式下的识别。其次，在运动模式识别后的基础，先使用低通滤波和卷积平滑滤波的组合方法对加速度数据进行过滤消除明显伪波峰，再提出一种自适应阈值的步频检测方法，通过利用自适应最小峰距和自适应动态阈值对加速度波峰的限制，从而减少检测中伪波峰导致的计步误差。最后，在航向估计中引入转向判断阈值，通过优化左转、右转和前进三个方向的航向角从而减少了定位漂移现象。

3) 蓝牙和 PDR 定位技术由于其自身特性，即使在改进后仍会产生一些问题。如蓝牙 RSSI 定位会出现定位结果跳跃、聚集等不合理现象，PDR 算法的累积误差会随着时间积累导致后续定位轨迹偏移。故在蓝牙和 PDR 融合定位流程中使用 EKF 算法将蓝牙和 PDR 的定位结果进行融合，有效解决单一方法定位问题，提高了定位精度。

1.4 论文组织结构和安排

本文正文部分共有六章，每章安排如下：

第一章：绪论。首先对室内定位的研究背景与意义进行介绍。其次，将室内定位技术分为基于无线电和非无线电两类，并对其国内外相关技术的研究发展进行介绍。最后简要概括本文的主要研究内容、组织结构和安排。

第二章：室内定位相关技术介绍。首先，在蓝牙定位技术原理中介绍低功耗蓝牙设备和蓝牙测距模型，并对蓝牙的测距与非测距定位技术进行说明。其次，对 PDR 定位技术原理进行简述，并从步频检测、步长估计和航向估计三个方面进行阐述。最后介绍室内定位领域中常用的融合定位算法。

第三章：基于 iForest-MF 修正的 RSSI 加权质心定位方法。对蓝牙 RSSI 信号分布特性和传播规律进行分析，提出对蓝牙 RSSI 的信号修正，并介绍修正方法与原理。然后介绍加权质心定位方法，并提出对双距离加权质心定位算法的改进。最后通过实验设计对几种定位方法进行评价。

第四章：行人运动模式识别与 PDR 定位方法。为了提高步频检测精度，首先对行人进行运动模式区分，并在此基础上提出特征约束条件限制波峰检测算法。针对航向估计漂移现象，对手机姿态角解算方法进行介绍，并提出对航向角阈值约束减少偏移误差。

第五章：融合定位算法与实验分析。首先介绍 PDR 和 RSSI 的融合定位流程，并建立 EKF 融合算法方程。其次，介绍融合定位实验环境并引入 OWD 轨迹相似度评价模型概念。最后，分别对蓝牙定位、PDR 定位和 EKF 融合定位进行实验验证与分析。

第六章：总结与展望。总结本文的工作内容，并对未来需要解决的问题进行展望。

第二章 室内定位相关技术介绍

本章主要对有关本文的定位技术进行介绍。首先，对蓝牙的设备、测距模型和其常见的定位方法进行详细说明；其次，阐述了 PDR 定位原理和其相关算法；最后，对主流的融合定位算法说明介绍。

2.1 蓝牙定位技术原理

蓝牙定位技术主要利用蓝牙信号的强度衰减来确定设备在空间中的位置。当一个蓝牙设备广播信号时，接收器可以测量到该信号的强度，通过这个强度值可以估算出接收器位置。根据使用定位方法不同，通常分为测距和非测距两类定位方法。

2.1.1 蓝牙设备介绍与测距模型

1) 蓝牙设备介绍

随着蓝牙 4.0 BLE 标准的推出^[55]，一种名为“蓝牙信标（Bluetooth beacons）”的新型设备被引入。与使用先前标准的设备不同，新设备可以按设置间隔发送信号，这在很大程度上有助于系统的能源效率，同时还提高了硬件和抗干扰性。2013 年，苹果公司推出了一种新的 iBeacon 技术，iBeacon 技术基于 BLE 标准创建，可以直接与智能手机通信，并且比传统蓝牙和 Wi-Fi 技术具有更低的功耗和成本^[56,57]。此外，谷歌在 2015 年推出了 EddystoneTM 开放标准，有助于蓝牙信标平台的广泛使用和发展^[58]。同时随着蓝牙技术的不断发展，蓝牙技术联盟（Bluetooth Special Interest Group, SIG）分别在 2016 年推出全新蓝牙 5.0 协议和在 2021 年推出最新 5.3 协议，这些新技术使得使用蓝牙技术进行室内定位的精度也会不断提升^[59]。相比定位精度低的 Wi-Fi 路由器和价格昂贵的 UWB 基站定位设备，低功耗蓝牙信标能提供更低功耗、更稳定、更经济的位置服务功能。

如图 2-1 所示，本文采用深圳云里物里公司生产基于蓝牙 4.0 协议的 E5 型号蓝牙信标，其广播功率范围为 -30dBm 到 +4dBm 之间，可调节广播频率范围在 100ms 到 10s 之间。该设备最大传输距离为 150m，并支持安卓和苹果系统的移动设备。

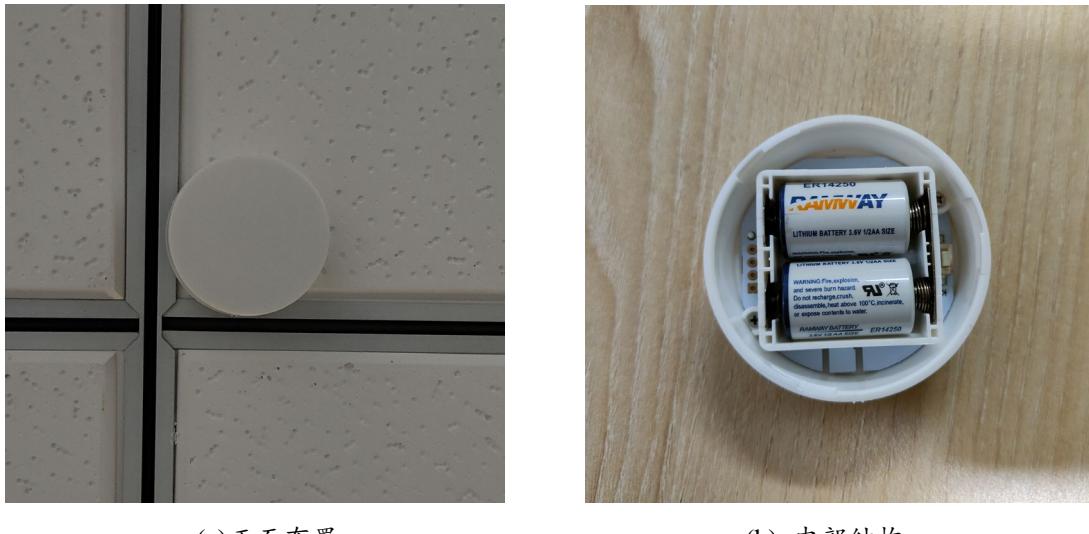


图 2-1 低功耗蓝牙设备

Fig.2-1 Bluetooth low energy devices

2) 蓝牙测距模型

无线电在空间传播过程中会遭受能量损耗，并且随着传播距离增加能量值愈发减小^[60]。因此，蓝牙测距模型基于蓝牙信号在传输过程中的 RSSI 和距离之间的非线性关系建立数学模型，通过测量接收到的 RSSI 值来计算设备之间的距离，这种模型通常采用经验公式来描述信号衰减和干扰的影响。在基于 RSSI 信号的室内定位中，对数路径损耗模型最为常见^[61]，其数学模型表示如下：

$$RSSI(d) = RSSI(d_0) - 10n \log_{10} \left(\frac{d}{d_0} \right) + X_\sigma \quad (2-1)$$

其中， $RSSI(d)$ 为从发射端经过距离 d 后的信号强度值， d_0 为参考距离，通常取 $d_0=1m$ ， n 为损耗因子， X_σ 为方差为 σ 均值为 0 的高斯随机变量，在实际计算中常用 0 代替。因此上式也简写为公式(2-2)，其中 A 代表 $d_0=1m$ 的信号强度值。

$$RSSI(d) = A - 10n \log_{10} (d) \quad (2-2)$$

由于不同的室内环境复杂多样，其损耗因子 n 和 A 值也会有所差别。如图 2-2 为不同 A 和 n 时的路径损耗模型图，可以看出随着距离增加，RSSI 信号强度逐渐变小且近似对数函数，并且根据 A 和 n 的选择不同其信号衰减程度也不尽相同，因此根据不同的室内环境测量选择 A 和 n 值对定位精度也有重要意义。

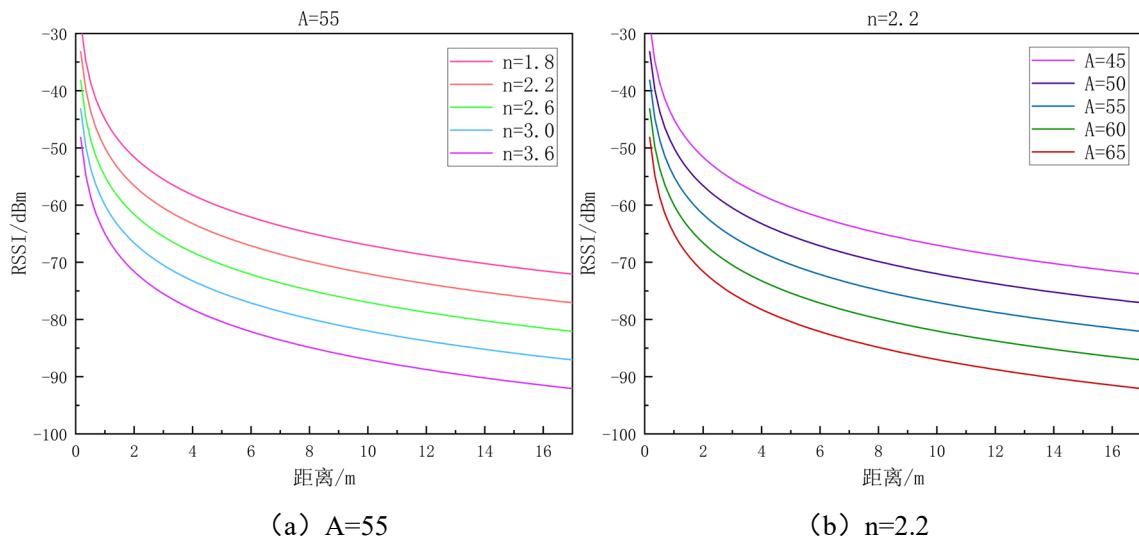


图 2-2 蓝牙 RSSI 路径损耗模型图

Fig.2-2 Bluetooth RSSI path loss model diagram

2.1.2 基于测距的定位方法

基于测距定位是首先通过测量蓝牙信标与接收器之间的信号强度，再根据测距模型转换成两者之间的距离，最后利用距离解算出接收器坐标的方法。

1) 三边定位法

三边定位法 (Triangulation) 是一种常用的信号定位方法，用于确定一个未知节点在三个锚节点 (如蓝牙信标) 之间的位置。如图 2-3 所示，分别以三个已知坐标的蓝牙信标 AP 节点为中心，根据信号解算距离为半径画圆，其相交点即为接收器的坐标位置。

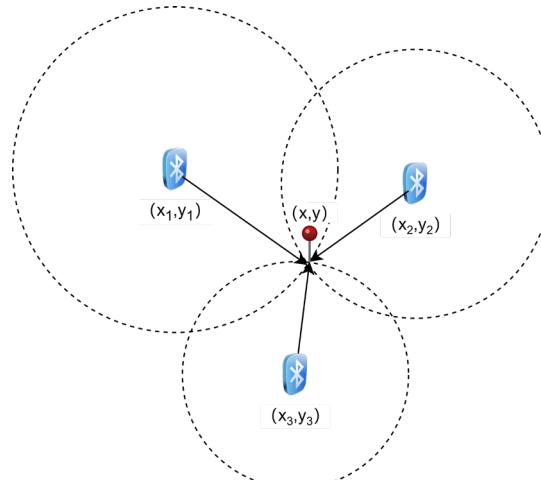


图 2-3 三边定位原理

Fig.2-3 Trilateral positioning principle

在这种方法中，可以通过公式(2-3)解算出未知节点坐标位置：

$$\begin{cases} (x_1 - x)^2 + (y_1 - y)^2 = r_1^2 \\ (x_2 - x)^2 + (y_2 - y)^2 = r_2^2 \\ (x_3 - x)^2 + (y_3 - y)^2 = r_3^2 \end{cases} \quad (2-3)$$

三边定位法实现简单适用性强，但是由于信号有一定波动性，通过测距获得距离总是略大于两点之间距离，因此三个圆相交会产生一个公共区域范围，因此为了提高定位精度，通常配合质心定位使用。

2) 多边定位法

多边定位法是三边定位法的一种拓展，是根据三个以上不共线的锚节点和其测距值，解算出测距误差对定位精度影响最小的点，并作为未知节点的坐标。设信标节点坐标为 (x_n, y_n) ，未知节点坐标 (x, y) 通常使用最小二乘法计算，公式(2-4)如下：

$$\begin{cases} (x - x_1)^2 + (y - y_1)^2 + (z - z_1)^2 = d_1^2 \\ (x - x_2)^2 + (y - y_2)^2 + (z - z_2)^2 = d_2^2 \\ \dots \\ (x - x_n)^2 + (y - y_n)^2 + (z - z_n)^2 = d_n^2 \end{cases} \quad (2-4)$$

为了化简计算，将每个式子依次减去第一项，并化成矩阵 $AX = B$ 表示，其中：

$$A = \begin{bmatrix} 2(x_2 - x_1) & 2(y_2 - y_1) \\ 2(x_3 - x_1) & 2(y_3 - y_1) \\ \dots & \dots \\ 2(x_n - x_1) & 2(y_n - y_1) \end{bmatrix} \quad (2-5)$$

$$B = \begin{bmatrix} d_1^2 - d_2^2 + x_2^2 + y_2^2 - x_1^2 - y_1^2 \\ d_1^2 - d_3^2 + x_3^2 + y_3^2 - x_1^2 - y_1^2 \\ \dots \\ d_1^2 - d_n^2 + x_n^2 + y_n^2 - x_1^2 - y_1^2 \end{bmatrix} \quad (2-6)$$

则根据最小二乘法，可以求出未知节点最优解 $X = \begin{bmatrix} x \\ y \end{bmatrix}$ 如下：

$$X = (A^T A)^{-1} A^T B \quad (2-7)$$

2.1.3 基于非测距的定位方法

与测距定位方法不同，非测距方法无需将接收器采集的 RSSI 信号值转换成与信

标之间距离，而是利用 RSSI 其他信息特征获取当前坐标。例如质心定位法利用网络的连通性，指纹定位法利用 RSSI 信息库进行匹配定位。

1) 质心定位法

传统的质心定位法是一种基于网络连通性的非测距算法，通过计算发送信息的锚节点坐标所组成的多边形质心作为未知节点的坐标位置，然而该方法定位精度低，受信标密度影响大。因此，在基于蓝牙 RSSI 信号的质心定位中结合了三边定位法，通常以未知节点接收到距离最近的 n 个锚节点（蓝牙信标）为圆心，需要利用路径损耗模型计算的距离为半径画圆。由于受到室内复杂环境的影响，通过 RSSI 距离转化公式计算得到的半径通常略大于实际距离^[62]。如图 2-4 所示，这种情况下所构成的多个圆（以三个为例）往往相交于一个公共多边形区域，每个交点坐标为 $p_i(x_i, y_i)$ 。

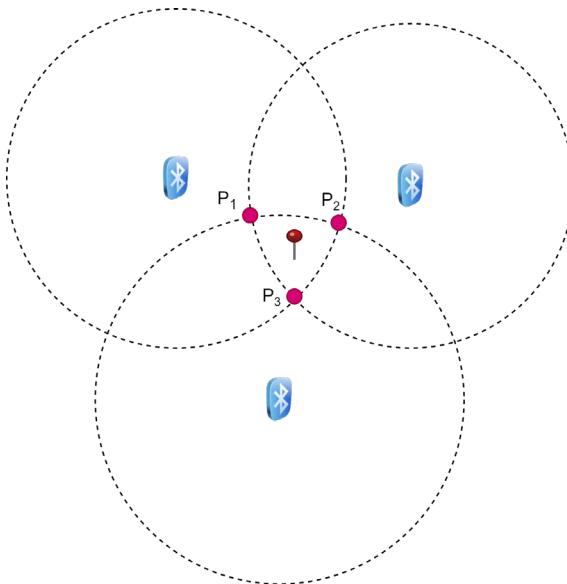


图 2-4 蓝牙 RSSI 质心定位原理图

Fig.2-4 Bluetooth RSSI mass location schematic

因此，基于 RSSI 的质心定位就是计算公共多边形质心作为未知节点的估计坐标。其计算公式(2-8)如下：

$$\begin{cases} x = \frac{1}{n} \sum_{i=1}^n x_i \\ y = \frac{1}{n} \sum_{i=1}^n y_i \end{cases} \quad (2-8)$$

质心定位计算简单适用性强，广泛应用在定位算法中。但由于定位精度受蓝牙信号影响，因此常引入其他权重提高定位精度。在本文第三章对质心定位的改进详细介绍

绍。

2) 指纹定位法

指纹定位法是通过创建环境地图，并在不同位置采集蓝牙信标或其他蓝牙设备的信号强度数据。这些数据被存储在数据库中，形成该位置的“指纹”。在定位期间，移动设备测量附近蓝牙信标的信号强度，并将其与指纹数据库进行比较以确定其位置。

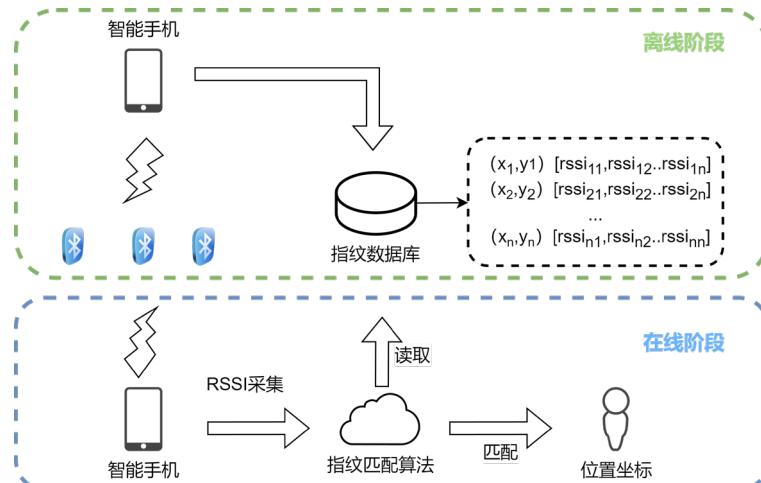


图 2-5 指纹定位原理图

Fig.2-5 Fingerprint positioning schematic

如图 2-5 所示，蓝牙指纹定位的实现大致分为两个阶段：离线指纹采集和在线匹配定位^[63,64]。在离线采集阶段，首先，需要在所要进行定位的区域内安置一些固定的蓝牙信标。然后，等间隔的参考点坐标，并使用智能手机或其他蓝牙设备在每个参考点上对这些蓝牙信标进行扫描采取其 RSSI 序列。这些与参考点对应的 RSSI 值就构成了一个指纹数据库。在线匹配阶段中，首先利用手机在每个要定位的位置处进行 RSSI 值的采集，一旦采集到足够数量的位置信息和 RSSI 值之后，就可以开始进行指纹匹配。具体地，算法会根据当前位置所采集到的 RSSI 值，从指纹数据库中找到与之最相似的一组 RSSI 值。这个最相似的 RSSI 值组合就是当前位置的匹配指纹。其计算方式有多中，常见的有 K 近邻法（K Nearest Neighbor, KNN）用欧氏距离筛选出最近的 K 个指纹点，其均值作为待测点坐标^[65]。同时，引入不同权值的加权 KNN 也有效提高其定位进度^[66,67]。

2.2 PDR 定位技术原理

PDR 定位技术是基于行人步态周期特征的一种惯性传感器定位技术，利用传感器

获取行走步数和步长信息，并结合航向角和初始位置可解算出行人的位置。由于人在行走过程中身体重心都会有规律的上下起伏，因此垂直方向的加速度数据能够体现每一步的信息；当行人在转向时，手机内置的陀螺仪和纵向加速度计也能捕捉到身体改变的角度信息；同时，磁力计也能利用磁场信息获取移动的绝对方向，因此通过循环以上步频检测、步长估计和航向估计步骤，则可以重现行人的行走轨迹。PDR 定位流程如图 2-6 所示：

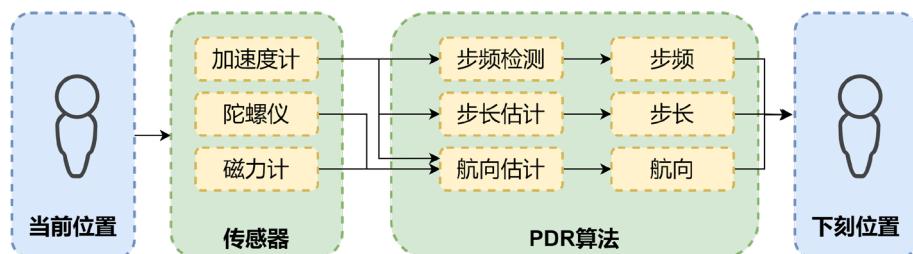


图 2-6 PDR 定位流程图

Fig.2-6 PDR technology positioning flow chart

由于 PDR 是相对定位技术，还需额外知道行人初始位置，假设行人初始位置坐标 (x_0, y_0) 已知，则其未来时刻位置坐标 (x_t, y_t) 的航位推算公式如下：

$$\begin{pmatrix} x_t \\ y_t \end{pmatrix} = \begin{pmatrix} x_{t-1} \\ y_{t-1} \end{pmatrix} + S_{t-1} \cdot \begin{pmatrix} \sin \theta_{t-1} \\ \cos \theta_{t-1} \end{pmatrix} \quad (2-9)$$

其中， S_t 代表行走距离， θ_t 为方向角。如图 2-7 所示为 PDR 定位原理图，根据原理可知，行人行走过程中的步频、步长和航向角数据决定着 PDR 定位技术的准确程度，由于目前智能手机大多配置低廉的消费级微机电系统（MEMS, Micro-Electro-Mechanical System），因此如何获得稳定精确的数据是 PDR 技术研究的关键。

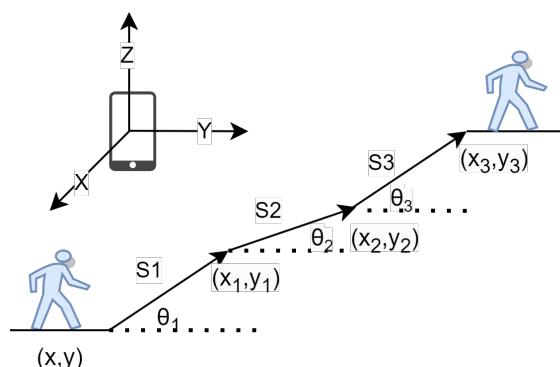


图 2-7 PDR 定位原理图

Fig.2-7 PDR positioning principle diagram

2.2.1 步频检测

步频检测是 PDR 定位技术中的一个重要步骤。由于在行走过程中，人的身体会有一个周期性的变化规律，这种变化规律可以被手持的加速度计所捕捉到，因此常用加速度数据进行步频检测分析。

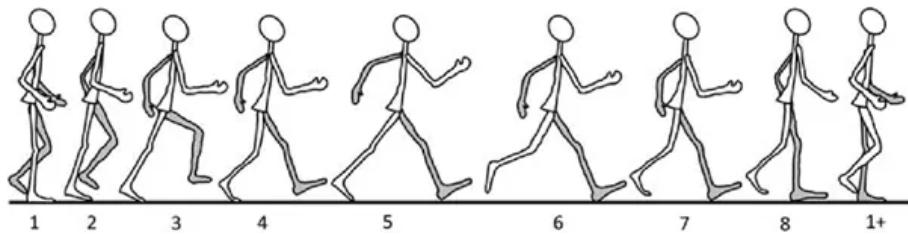


图 2-8 行人步态周期

Fig.2-8 Pedestrian Gait Cycle

如图 2-8 所示，代表行人的一一个标准的步态周期图。图中步态 1 到步态 5 过程中，右脚脚面从着地到抬起，身体重心随之逐渐提高，垂直方向的加速度增加；步态 5 指左脚跟刚着地，身体重心到最高处，此时垂直方向的加速度达到峰值；步态 5 到步态 8 过程中，左脚从脚跟着地到左脚面完全着地，行人身体重心逐渐下移，随之垂直方向加速度同时向下达到最低值。如图 2-9 所示行人在连续行走下的加速度示意图，尽管波峰检测能对步伐有效计步，但手机抖动导致的伪波峰会引起计步误差。

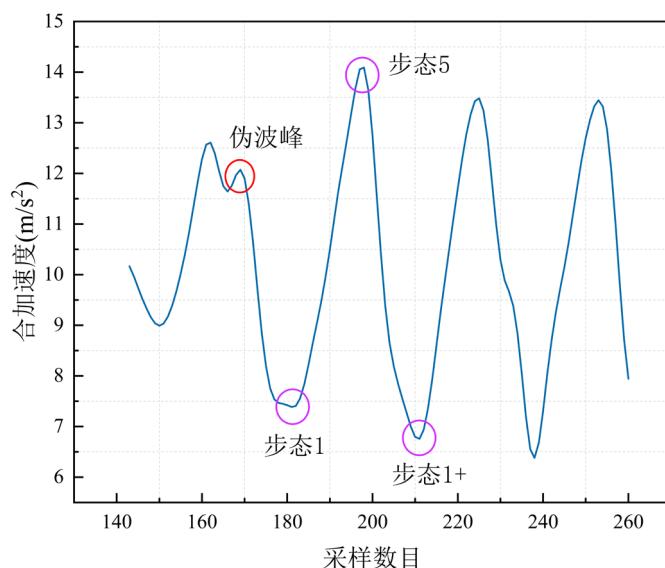


图 2-9 行走下的加速度序列特征

Fig.2-9 Acceleration sequence characteristics under walking

2.2.2 步长估计

在基于 PDR 的室内行人定位中，步长估计算法通常结合用户的身高、体重以及步行速度等因素来估计用户的步幅长度。为了更加准确地估计步幅长度，算法利用统计模型和机器学习技术来学习这些变量与用户步幅长度之间的关系。一旦步幅长度被估计出来，算法就可以通过将步幅长度乘以步数来计算每步行程的距离。最后，每步行程的距离被用于更新行人在室内环境中的位置估计，从而实现对行人位置的精确估计。步长估计算法的高精度和可靠性使得它在室内行人定位技术中具有一定应用价值。步长估计模型的类型多样化，包括常数模型、线性模型、非线性模型以及机器学习模型等四种。

1) 常数模型

步长估计中，常数模型是一种简单而有效的模型，假设步长对所有行人都保持恒定，不考虑其运动模式和步行速度的影响。这种方法易于实现且计算效率高，因而在早期实践中得到了广泛应用。文献^[37]通过对大量用户进行统计分析，编制了一张固定步长的统计表，可以根据行人的运动情况选择不同的步长，这为研究者和实践者提供了有用的参考资源。然而，常数模型存在一些局限性，它没有考虑行人步行模式的个体差异，并且假设在所有步行条件下步长保持不变。因此，常数模型不适用于需要高准确性定位的场景。

2) 线性模型

线性模型是步长估计中一种常见的模型，通常用于估计行人的步长。该模型基于一个假设，即行人的步长与其步行频率之间存在线性关系。具体来说，该模型假设行人的步长可以用如下公式(2-10)表示：

$$L_g = a \cdot f + b \quad (2-10)$$

其中， L_g 表示行人的步长， f 表示行人的步行频率， a 和 b 是模型中的系数。这个模型可以用来估计行人的步长，只需测量行人的步行频率，即可通过上述公式计算出行人的步长。为了确定模型中的系数 a 和 b ，需要收集一定数量的数据进行分析。在分析数据之后，可以使用最小二乘法等方法来拟合模型，从而得到最佳的系数估计值。对于不同的行人，可能需要调整模型中的系数，以便更好地适应其个体差异。

在线性模型中，文献^[38]引入更多参数来提高步长模型的精度，具体公式如(2-11)

所示：

$$S_l = A + B \cdot f_l + C \cdot \text{var}_l + w \quad (2-11)$$

其中， S_l 和 f_l 代表行走 l 步后的步长和步频， var_l 和 w 表示 l 步后方差和噪声， A 、 B 、 C 为常量参数。

3) 非线性模型

除了常数和线性模型外，非线性模型也广泛用于各种应用中，非线性模型相对常数和线性模型略微复杂，但是可以提供更精确的步长估计。

Weinberg 模型^[39]是最典型的用于步长估计的非线性模型之一，由于其涉及额外参数少、复杂度低且精确度高而广泛流行。其公式如（2-12）所示，其中 k 为常量参数， a_{\max} 和 a_{\min} 分别为行人在运动周期中的最大、最小加速度。

$$S_l = k \cdot \sqrt[4]{a_{\max} - a_{\min}} \quad (2-12)$$

另一个典型的非线性模式是 Kim 模型^[68]，与 Weinberg 模型不同，Kim 模型是基于平均加速度的经验公式，公式如（2-13）所示，其中 k 为常量参数， a_i 为 i 时刻的三轴加速度。

$$S_l = k \cdot \sqrt[3]{\frac{\sum_{i=1}^n |a_i|}{n}} \quad (2-13)$$

4) 机器学习模型

除了传统的物理模型外，机器学习算法也被广泛运用于步长估计中。例如，决策树、神经网络和支持向量机等算法能够处理更为复杂的步行模式，包括踏步时间、踏步长度、行走速度、姿态变化等多种因素，并具有自适应学习能力^[69]。Wang 等人^[70]利用传感器数据在运动中的变化来训练遗传优化神经网络模型，实现表明模型输出对行人运动数据有较好拟合性，可以用于预测步长。

与传统的物理模型相比，机器学习模型具有更高的精度和更好的泛化性能，适用范围更广。然而，机器学习模型的训练和预测复杂度通常更高，需要更多的数据和计算资源。此外，由于其黑盒性质，机器学习模型的解释和调试可能会更加困难。因此，在选择步长估计算法时需要综合考虑算法的精度、复杂度和可解释性等因素，以确定最适合特定应用场景的算法。

2.2.3 航向估计

在 PDR 定位技术中，步频检测和步长估计计算行人走过的距离长度，航向估计判断行走方向角度。加速度计、陀螺仪和磁力计均可获取一定的航向角信息，根据选择算法不同，可由不同数据组合使用。但由于智能手机内置的传感器精度低且具有累积误差，随着时间航向会产生一定偏移现象。李蓉等^[71]通过对加速度计和陀螺仪的组合使用，得到相对单一数据精度更高的姿态角。刘元成等^[72]利用地磁匹配地图信息，通过粒子滤波来校正 PDR 中航向角的累积误差，定位精度在 1m 内。

2.3 融合定位算法

PDR 定位技术是通过利用传感器数据计算步长、方向和速度等信息，来推断行人相对移动的位置。PDR 技术可以在没有信号或信号弱的情况下进行定位，但是由于误差累积的问题，长时间使用 PDR 技术可能会导致定位误差累积增加。相反，蓝牙的无线电定位技术可以在覆盖范围内提供高精度的绝对位置信息，但是由于复杂的室内环境，定位稳定性存在一定问题。因此，为了解决室内定位中存在的问题，通常将无线电技术和 PDR 技术相融合，以形成互补优势。在融合过程中，无线电定位技术可以为 PDR 提供初始位置，在运动过程中两者分别计算的位置信息通过融合滤波互相修正，最终获取稳定的定位结果。在已有的研究成果中，基于卡尔曼滤波算法和粒子滤波算法是常用的融合滤波算法^[73,74]，本文将对这两种算法进行简要介绍。

2.3.1 卡尔曼融合算法

卡尔曼滤波（Kalman Filtering, KF）算法是一种常用于融合多种传感器数据的滤波算法，其旨在通过组合多个传感器的信息以提高系统的精度和鲁棒性。该算法最初由美国航空航天局的 Rudolf E. Kalman 于 1960 年提出^[75]，用于处理航天器在轨道上的状态估计问题，后来被广泛应用于自动驾驶、室内导航和机器人等领域。

在卡尔曼滤波中，系统被抽象为一个状态空间模型，包含了状态方程和观测方程。其中，状态方程描述了系统随时间的动态变化规律，而观测方程则用于将部分系统状态转换为可观察的数据。假设状态方程和观测方程都是线性的，且系统存在高斯白噪声且彼此独立，则状态方程（2-14）和观测方程（2-15）公式分别如下：

$$x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} \quad (2-14)$$

$$z_k = Hx_k + v_k \quad (2-15)$$

其中, x_k 为当前系统状态, z_k 为测量状态, A 为状态转移矩阵, B 为控制输入矩阵, u_k 为控制向量, w_k 为系统过程噪声, H 为观测矩阵, v_k 为观测噪声。

KF 算法包括两个阶段: 预测和更新。在预测阶段, 根据系统的动态模型和先前状态的估计值来预测当前状态的值 (2-16) 和协方差矩阵 (2-17)。具体来说, 预测过程如下:

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1} \quad (2-16)$$

$$P_k^- = AP_{k-1}A^T + Q \quad (2-17)$$

其中, \hat{x}_k^- 和 P_k^- 分别表示预测的状态向量和协方差矩阵, Q 为系统过程噪声的协方差矩阵。

在更新阶段, 利用当前时刻的测量值来校正预测值, 从而得到最终的状态估计值。具体来说, 更新过程如下:

$$K_k = P_k^- H^T \left(HP_k^- H^T + R \right)^{-1} \quad (2-18)$$

$$\hat{x}_k = \hat{x}_k^- + K_k (z_k - H\hat{x}_k^-) \quad (2-19)$$

$$P_k = (I - K_k H) P_k^- \quad (2-20)$$

其中, K_k 为卡尔曼增益, R 为过程噪声协方差矩阵。

2.3.2 粒子滤波融合算法

粒子滤波算法 (Particle Filter, PF) 是一种基于蒙特卡罗方法的非线性滤波算法, 被广泛应用于状态估计和参数优化问题中^[76]。它最初由 Gordon 等人在 1993 年提出, 用于处理非线性、非高斯分布的状态估计问题。随着计算机技术的发展和蒙特卡罗方法的应用越来越广泛, 粒子滤波算法在融合定位、机器学习、智能控制等领域中得到了广泛的研究和应用。

粒子滤波融合算法的基本思想是通过一系列的随机粒子来代表状态的概率密度函数, 每个粒子都有一个权重, 表示该粒子与实际状态之间的匹配程度。在每个时刻, 根据传感器的数据更新每个粒子的权重, 然后通过粒子重采样的方式产生新的粒子集合, 最终得到状态的估计值。其具体流程如下:

1) 初始化: 生成一组粒子 $X_o^{(i)} \sim P(X_0)$, $i=1,2,\dots,N$, 服从先验概率分布 $P(X_0)$, 并赋予相同的初始权重 $W_k^{(i)} = 1/N$ 。

2) 重要性采样, 从重要性概率密度函数 q 中生成采样粒子:

$$\hat{X}_k^{(i)} \sim q(X_k | X_{0:k-1}^{(i)}, Z_{1:k}) \quad (2-21)$$

3) 为每个粒子计算权重 (2-22) 并归一化 (2-23):

$$W_k^{(i)} = W_{k-1}^{(i)} \frac{P(Z_k | X_k^{(i)}) P(X_k^{(i)} | X_{k-1}^{(i)})}{q(X_k | X_{0:k-1}^{(i)}, Z_{1:k})} \quad (2-22)$$

$$\tilde{W}_k(X_{0:k}^{(i)}) = \frac{W_k(X_{0:k}^{(i)})}{\sum_{i=1}^N W_k(X_{0:k}^{(i)})} \quad (2-23)$$

4) 重采样: 根据归一化权值 $\tilde{W}_k(X_{0:k}^{(i)})$ 对粒子进重采样, 新权重为 $W_k^{(i)} = 1/N$

5) 输出样本点, 近似表示后验分布 (2-24) 且计算均值 (2-25):

$$P(X_{0:k} | Z_{1:k}) \approx \hat{P}(X_{0:k} | Z_{1:k}) = \frac{1}{N} \sum_{i=1}^N \delta_{X_{0:k}^{(i)}}(dX_{0:k}) \quad (2-24)$$

$$E(g_k(X_{0:k})) = \int g_k(X_{0:k}) P(X_{0:k} | Z_{1:k}) dX_{0:k} \approx \frac{1}{N} \sum_{i=1}^N g_k(X_{0:k}^{(i)}) \quad (2-25)$$

6) 循环: 重复步骤 2 至步骤 5, 直至估计出整个状态序列。

与传统卡尔曼滤波算法不同的是, 粒子滤波融合算法可以处理非线性系统。但粒子滤波计算复杂度高和存在粒子退化问题, 且当系统噪声为高斯噪声时粒子滤波的效果不如卡尔曼滤波。

2.4 本章小结

本章主要对蓝牙、PDR 和融合定位的相关技术与方法进行介绍。首先, 介绍低功耗蓝牙设备和其测距模型, 并在基于蓝牙的测距方法中介绍了三边定位和多边定位法, 在非测距方法中介绍了质心定位和指纹定位法。随后, 介绍了 PDR 定位技术原理, 并从步频检测、步长估计和航向估计三个部分展开说明。最后, 根据两种定位技术的特点介绍了室内定位领域中常用的两种融合定位算法: 卡尔曼滤波和粒子滤波。

第三章 基于 iForest-MF 修正 RSSI 的加权质心定位方法

蓝牙定位具有低成本和高精度等优点，但在复杂的室内环境中，信号传播会受到干扰，从而导致定位的稳定性存在一定问题。为此，本章重点对蓝牙定位技术进行分析，主要包括对蓝牙信号特性和定位方法的研究。首先，根据蓝牙 RSSI 信号的特点，分析了信号分布特性和传播规律。接着，根据分析结果，提出了基于 iForest-MF 的 RSSI 修正方法。最后，对基于距离加权质心定位方法进行了分析，并提出了改进方法。

3.1 RSSI 信号传播特征分析

在室内定位应用中，智能手机所采集的蓝牙 RSSI 信号常常受到多种干扰，例如障碍物阻挡和信号噪声等。这些干扰会影响蓝牙信号的传输和接收，导致其与理论值不符，从而影响室内定位准确性和稳定性。因此，在提高室内定位精度的过程中，有必要对蓝牙信号的分布特性和传播规律进行详细的分析，以深入了解信号的特性和性能。并且，采取相应的措施来降低噪声和干扰的影响，从而提高定位精度与鲁棒性。

3.1.1 RSSI 信号分布特性分析

在理想情况下，同一点接收到的蓝牙 RSSI 信号应是时间平稳且服从高斯分布，然而实际情况下受多径效应和行人使用等因素影响，采集到的信号可能出现大量异常值，且概率分布不严格反映实际情况。因此，为了验证实际环境下蓝牙 RSSI 信号的分布特性，本文在实验场地内分别模拟了理想无干扰环境和受干扰环境的情况，并采用智能手机对蓝牙信标 AP 进行了 RSSI 采样分析。

首先，为观察在理想无干扰环境下，不同蓝牙 AP 的 RSSI 信号强度变化，实验设计选取了实验场地内的四个蓝牙 AP：CB、C4、C6 和 C3，并在同一位置下进行了 10 分钟的采样，采样频率为 5Hz。实验场地处于封闭状态，不允许有路人经过且无遮挡物。

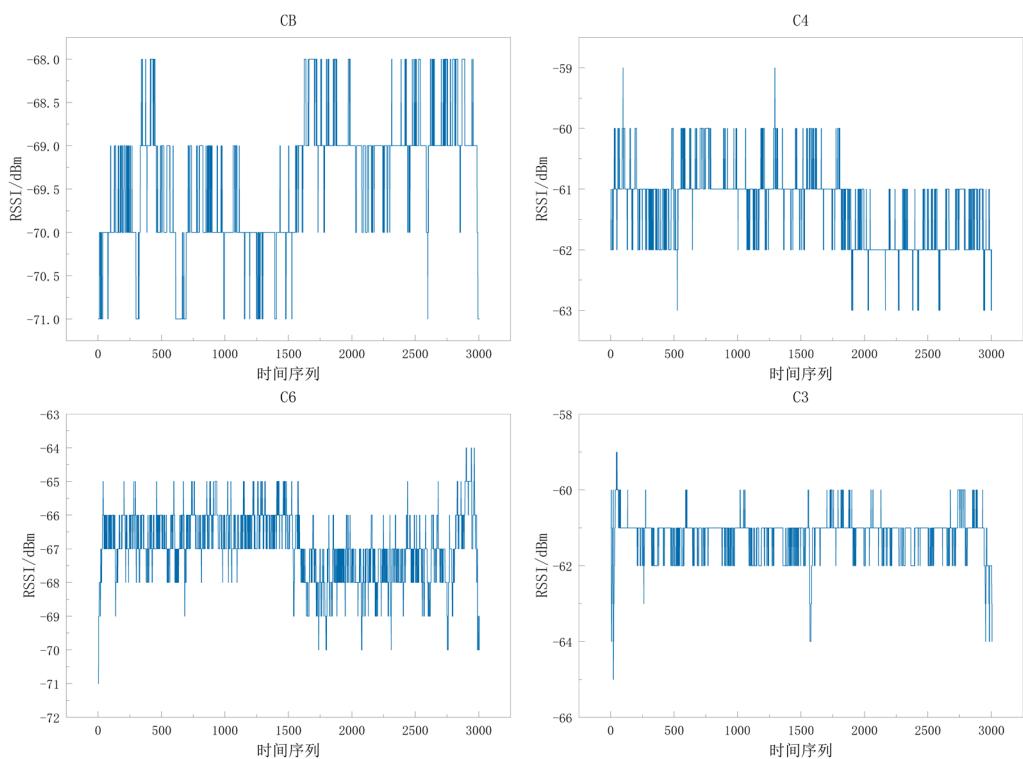


图 3-1 场地封闭状态下 RSSI 随时间的分布规律

Fig.3-1 The distribution pattern of RSSI with time in the closed state of the site

如图 3-1 所示，横坐标表示采样的时间序列，纵坐标表示接收到的信号强度值，每个蓝牙 AP 大约扫描了 3000 组 RSSI 数据。从图中信号波动情况可以看出，在无干扰环境下，每个蓝牙的 RSSI 值都具有一定的波动性，并且根据蓝牙 AP 距离的不同，RSSI 值也有相应的变化。大部分 RSSI 值的波动幅度都在 4dBm 以内。然而，由于不可避免的信号噪声影响，在某些时刻，极少数异常数据会脱离前后时刻的信号波动规律，表现出 RSSI 信号骤升和急降的特点。这些异常值的 RSSI 波动幅度不超过 7dBm。

接下来，为了研究实际受到干扰的室内环境，我们仍然选择了同样的实验场地和采样点，并对同样的四个蓝牙信标 CB、C4、C6 和 C3 进行了 10 分钟的采样，采样频率为 5Hz。为了模拟受干扰的环境，我们允许路人穿越实验环境，并放置了一些遮挡物。

如图 3-2 所示，在受干扰的室内环境中，信号传输时出现了多种多样的干扰，蓝牙 RSSI 信号的波动程度明显增大。在这种环境下，实验场景中路人经过和遮挡物等干扰会显著增加 RSSI 信号的骤升和急降情况，进而导致 RSSI 的异常数据远远超过理想环境下的情况。这些异常值的波动幅值通常在 18dBm 以内，因此对于这些情况，需要使用相应的算法进行处理，以提高定位精度和稳定性。

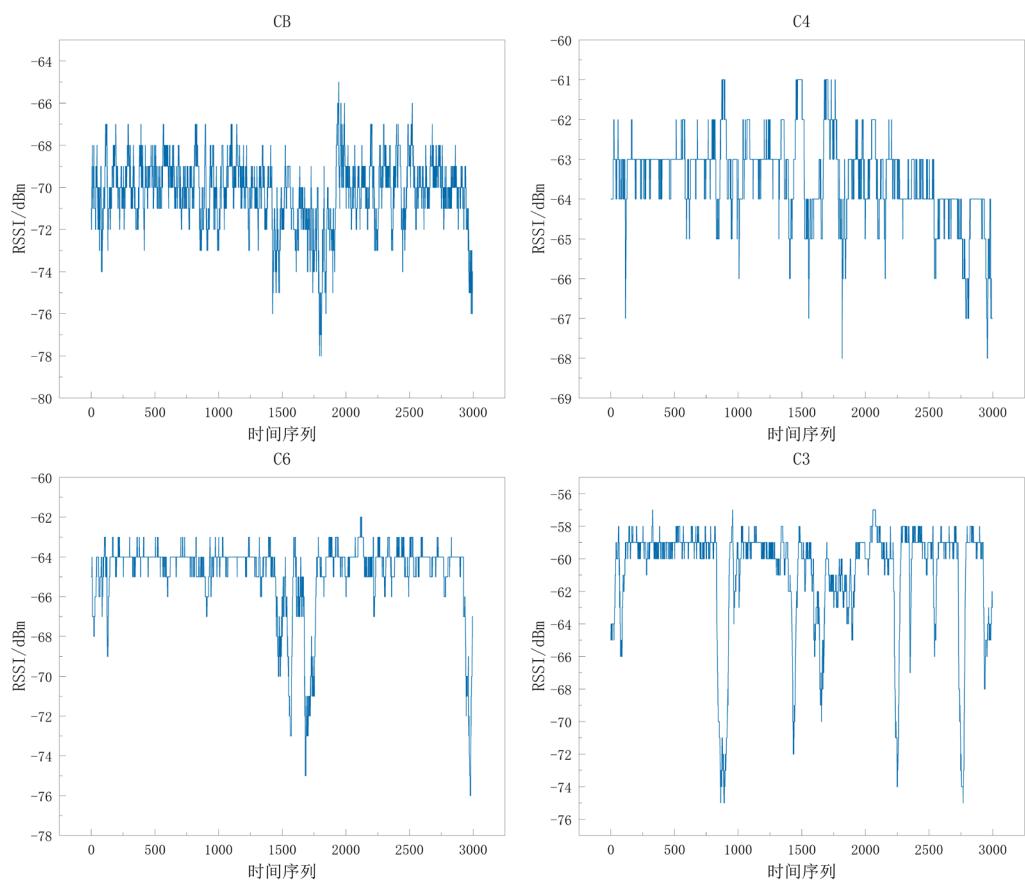


图 3-2 场地开放状态下 RSSI 随时间的分布规律

Fig.3-2 Distribution pattern of RSSI with time in the open state of the site

其次，为了观察在干扰环境下，对同一蓝牙 AP 下不同采样位置接收到的 RSSI 信号变化情况。实验设计对随机一个蓝牙信标节点的距离间隔 2m、3m 和 4m 处分别设置一个采样点，采样时长 3 分钟，采样频率为 5Hz。

如图 3-3 所示，可以观察到在不同位置处，同一时刻的 RSSI 值具有差异性，呈现不同的浮动规律。例如在 2m 处，蓝牙 AP 的 RSSI 值在 -57dBm 至 -61dBm 之间波动；在 3m 处，蓝牙 AP 的 RSSI 值在 -56dBm 至 -69dBm 之间波动；在 4m 处，蓝牙 AP 的 RSSI 值在 -66dBm 至 -72dBm 之间波动。虽然三个采样位置相对蓝牙 AP 的距离不同，但由于受到干扰和噪声影响，在不同采样点下会有一些偏幅过大的异常点之间的信号强度值会有一定重合，这些重合一定程度上为影响蓝牙定位精度。因此为了提高定位精度，需要对采样后的信号强度值进行一些修正过滤。

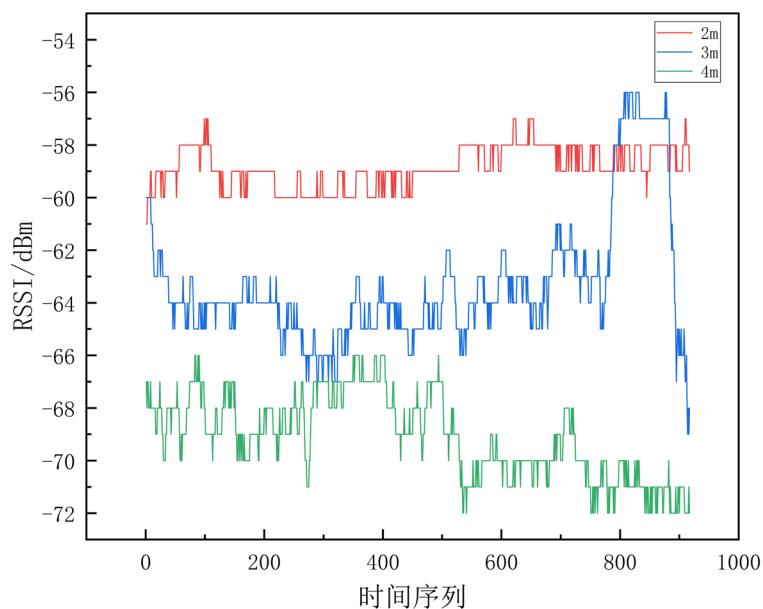


图 3-3 不同距离下 RSSI 随时间的分布规律

Fig.3-2 The distribution pattern of RSSI with time at different distances

3.1.2 RSSI 信号传播规律分析

蓝牙信号在空间传播中呈现衰减特性，因此研究其在室内传播特性是运用蓝牙 RSSI 定位的基础。本文第 2.1 节介绍了对数距离路径损耗模型，该模型可以反映了理论下 RSSI 值与传播距离的关系。但是，在复杂的室内环境中，由于障碍物的干扰，RSSI 信号会产生多径效应。这意味着信号在传播中会被反射、折射和散射，到达接收器时会形成多条路径。这些路径之间会相互干扰，导致信号质量下降。此外，噪声等因素也会对接收到的 RSSI 值产生影响。

因此，为了明确实际环境下蓝牙 RSSI 与传播距离的关系，本文在实验场地，根据采集蓝牙 RSSI 值，利用对数距离路径损耗模型拟合蓝牙传播规律。

首先，本研究采用等间隔 0.3m 的方式，在 0.3m 至 10m 的距离范围内进行采样，每个采样点持续采样 30 秒。其次，为减小误差影响，采样结果进行了均值统计，排除了采样结果中的均值偏差。最后，采用对数距离路径损耗模型计算 RSSI 参数，并据此拟合出室内环境下蓝牙信号传播规律。实验利用 2.1 节中的对数距离路径损耗模型公式(2-2)，对采样得到的蓝牙 RSSI 值进行拟合，从而拟合出参数 $A=-50.21$ 和 $n=2.87$ 。绘制出拟合曲线如图 3-4 所示，该图表明了在室内环境下，蓝牙信号的 RSSI 值随距离增加而降低。

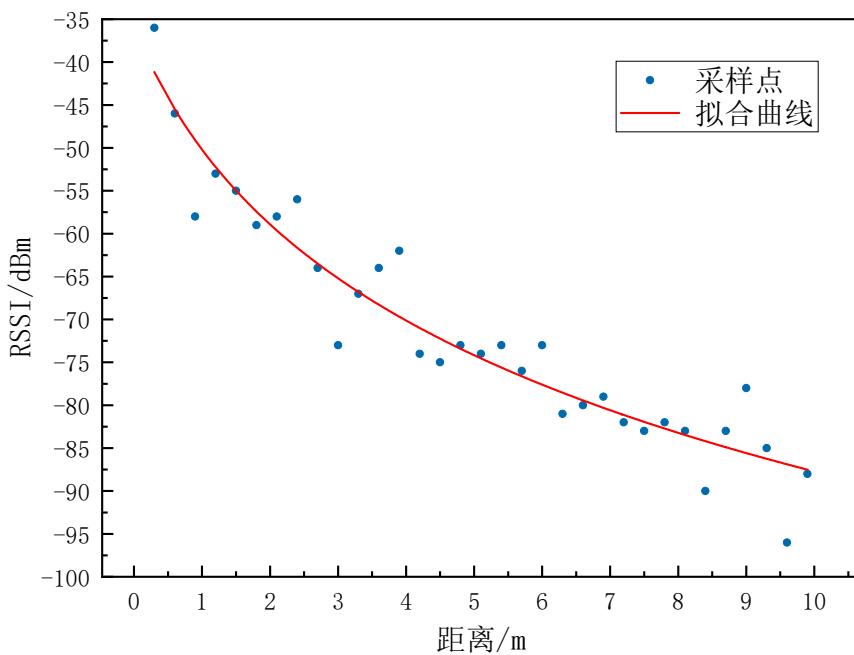


图 3-4 蓝牙信号传播模型拟合曲线

Fig.3-4 Fitted curve of Bluetooth signal propagation model

3.2 基于 iForest-MF 的 RSSI 修正方法

由于蓝牙 RSSI 信号在室内定位中受到复杂环境和其他信号噪音的影响，其波动性和异常值增加，从而降低了行人位置估计的准确性。为了应对此问题，本文基于 3.1 节对蓝牙 RSSI 信号特性的分析，提出了一种新的方法，即采用 iForest-MF 组合滤波技术来修正采集到的 RSSI 信号值，以减少干扰和噪音的影响，并提高室内定位的准确性。

3.2.1 基于 iForest 的异常值检验

根据 3.1.1 节对 RSSI 信号分布特性分析可知，在理想环境下，采样的蓝牙 RSSI 值较为稳定且异常值较少，通常使用高斯滤波、均值滤波和卡尔曼滤波均等平滑滤波可对其进行有效过滤。然而在实际受干扰情况下，采样的蓝牙 RSSI 值波动幅度较大且异常值较多，直接使用传统的滤波方法无法有效反应真实的信号强度情况。因此本文针对在干扰环境下的异常值较多情况，利用孤立森林（Isolation Forest, iForest）一种快速异常值检测方法，对采集到的蓝牙 RSSI 信号值进行有效修正，还原真实的 RSSI 信号值。

iForest 算法是一种基于树的无监督的机器学习算法，通常用于的入侵检测、欺诈

检测和故障诊断等领域。它是由周志华等人首次提出的，作为检测数据集中异常情况的一种方法。iForest 基本思想是通过识别与大多数数据点明显不同的数据点来隔离异常情况，而不是试图对整个数据集进行建模。

iForest 异常检测算法的工作原理是通过随机选择特征子集来递归划分数据。该过程一直持续到每个数据点被隔离在它自己的树的叶节点中。每棵树的高度或每个数据点的叶子节点深度可以衡量该点从其他数据中分离出来的容易程度。首先，该算法选择一个随机的数据点子集，然后从子集中随机选择一个特征。该特征用于将数据分成两个子集：一个包含该特征值较高的数据点，另一个包含该特征值较低的数据点。对于每个子集，该过程反复进行，直到每个数据点被隔离在它自己的叶子节点中。为了确定每个数据点的异常得分，算法计算从每棵树的根到数据点的平均路径长度。由于异常点被隔离，预计它们到各自叶子节点的平均路径长度会比正常点短。其主要步骤如下：

1) 随机选择特征和分割阈值

给定一个样本量 n 的数据集 $X = \{x_1, x_2, \dots, x_n\}$ ，随机选择一个特征 $i \in 1, 2, \dots, d$ 和在该特征上随机选择一个分割阈值 $c \in (min_i, max_i)$ 。其中 d 表示数据集的特征维度， min_i 和 max_i 表示特征 i 的最小值和最大值。

2) 分割数据点

选择一些数据点，根据它们在特征 i 上的取值将其分成两个子集，将其分为“左子树”和“右子树”，选择公式如下：

$$\begin{cases} \text{if } x_i < c, \text{ then go to left subtree} \\ \text{if } x_i \geq c, \text{ then go to right subtree} \end{cases} \quad (3-1)$$

3) 计算路径长度

路径长度表示数据点在树结构中从根节点到叶子节点所经过的边数。对于任意一个数据点 x ，在包含 n 个样本的数据集中，其在一棵树上的路径长度 $h(x)$ 可以通过路径长度的平均值 $c(n)$ 表示：

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n} \quad (3-2)$$

其中 $h(n-1)$ 为调和数，可以用 $\ln(n-1) + 0.5772156649$ 估算。

4) 计算异常得分:

对于一个数据点 x , 将其在所有树结构上的路径长度的平均值作为其异常得分定义为:

$$Score(x, n) = 2^{-\frac{E(h(x))}{C(n)}} \quad (3-3)$$

其中 $E(h(x))$ 指样本点的路径长度期望, 当 $s(x)$ 越小, 说明数据点 x 越有可能是异常点。最终, 通过设定阈值, 可以将异常点和正常点进行区分, 达到异常检测的目的。

如图 3-5, 在集合 $X = \{a, b, c, d\}$ 样本 d 是最早被孤立出来的, 所以是其中最大概率的异常点。

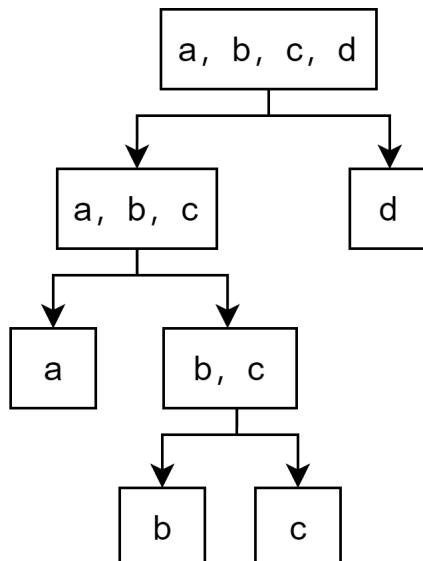


图 3-5 iForest 分类图

Fig.3-5 iForest Classification Chart

与其他常见异常检测算法相比, iForest 算法具有高度的可扩展性和效率, 使其非常适合于检测具有异常噪声的蓝牙 RSSI 数据。针对 3.1.1 在受干扰环境中采集的四个蓝牙 CB、C4、C6 和 C3 的 RSSI 数据集中, 利用基于 iForest 异常检测算法, 得到检测异常点和异常值剔除后的蓝牙 RSSI 值如图 3-6 所示, 对比剔除前后的 RSSI 波动异常情况, 修正后的 RSSI 值更趋向理想状态下的蓝牙信号强度, 表明该方法能有效抑制突变的异常信号干扰。

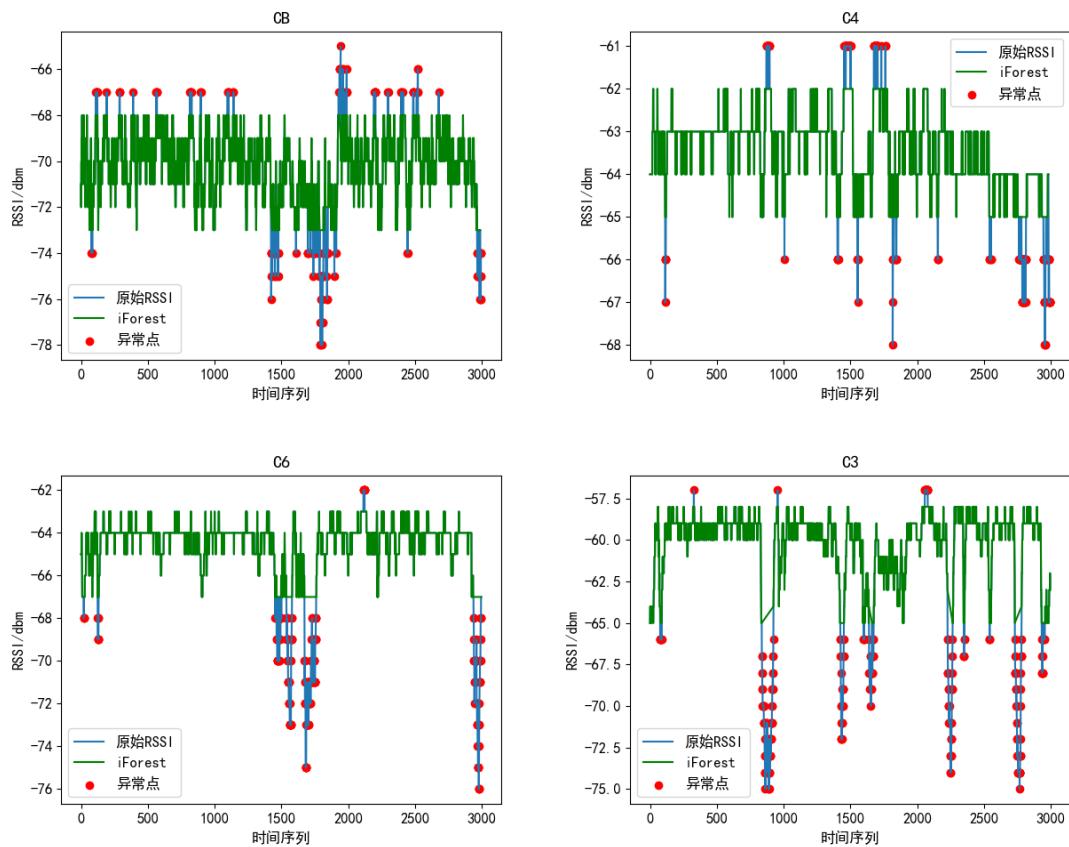


图 3-6 iForest 去除异常值后 RSSI 随时间分布规律

Fig.3-6 Distribution pattern of RSSI over time after iForest removes outliers

3.2.2 iForest-MF 组合滤波

均值滤波在蓝牙信号中是一种常用的数据预处理方法，用于去除一维信号中的噪声，并平滑信号的波形。其基本原理是通过计算信号中一定窗口内数据点的平均值来减少噪声，同时保留信号中的趋势和变化。

鉴于原始蓝牙信号在干扰环境下波动较大，异常值数量众多，振幅大，使用均值滤波难以实现良好的平滑效果。因此，本文提出了一种基于 iForest-MF 组合的检测滤波修正方法，以解决该问题。该方法首先使用 iForest 异常值检测法剔除明显的异常值，然后采用均值滤波对蓝牙 RSSI 信号进行平滑处理，最后采用插值法补偿平滑滤波后的信号延迟问题。实验结果表明，该方法能够有效地滤除信号骤高、骤低的异常跳动现象，并避免了信号延迟导致的误差问题。为了验证修正算法的效果，本文对不同阶段的 RSSI 值进行了数学统计分析。

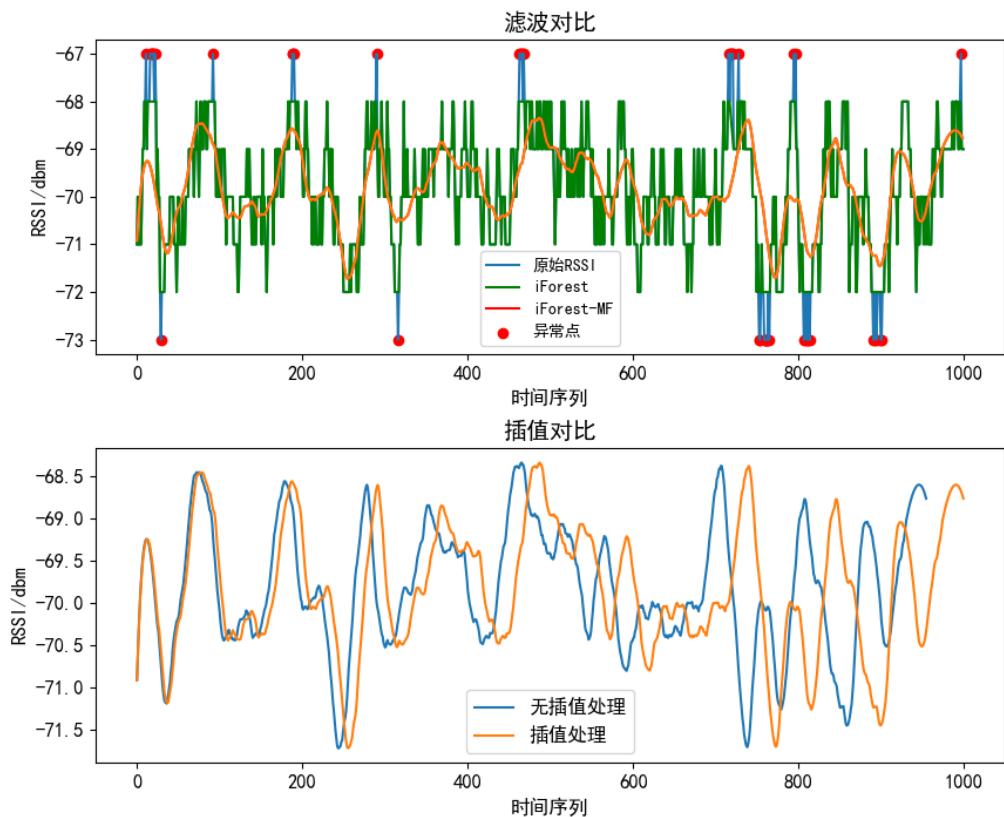


图 3-7 不同滤波算法对比

Fig.3-7 Comparison of different filtering algorithms

表 3-1 信号强度值统计结果对比

Tab.3-1 Comparison of statistical results of signal strength values

统计值	原始	iForest	MF	iForest-MF
	RSSI 值	修正层	修正层	修正
中位数 / dBm	-70.000	-70.000	-69.999	-69.984
平均值 / dBm	-69.824	-69.834	-69.821	-69.832
标准差	1.261	1.113	1.211	0.760
方差	1.591	1.239	1.522	0.577

根据表 3-1 的统计数据，本研究对采集到的原始蓝牙 RSSI 信号及其经过 iForest 和 MF 方法的中位数、平均值、标准差和方差进行对比分析。结果显示，各修正层的 RSSI 信号中位数和均值都接近于原始 RSSI 信号值，表现出更好的稳定性。在标准差和方差的参量下，iForest-MF 修正层的方差最小。相比之下，仅使用 iForest 或 MF

修正层的 RSSI 信号相对于未经修正的数据能够有效改善定位效果，但与同时采用这两种修正层相比，其效果不够稳定。因此，本研究认为在原始蓝牙 RSSI 信号中采用 iForest-MF 组合检测滤波效果最佳，修正后的 RSSI 信号波动规律呈现出近似正弦波的特征，各项指标更加接近理想的蓝牙 RSSI 信号情况。

3.3 改进的 RSSI 加权质心定位方法

本节的研究对象为基于蓝牙 RSSI 加权质心定位的改进算法，通过本文 2.1.2 和 2.1.3 节介绍中可以得知，基于非测距的传统质心算法，仅依据接收到的信标坐标信息进行定位，其定位精度较低且易受信标布置方式的影响。基于 RSSI 信号的质心定位结合了三边定位思想，通过利用最近的蓝牙信标为圆心，测距距离为半径画圆，其圆相交的公共多边形的质心则为待定位坐标，大大缩小未知节点的误差范围。然而，单一使用质心计算坐标仍有一定误差，本文根据 RSSI 信号传播特性，提出一种基于距离修正的加权质心定位方法。

3.3.1 加权质心定位算法

针对质心定位仅考虑简单计算平均值为未知节点坐标的问题，文献^[77]提出基于单距离加权的质心定位算法。该算法利用蓝牙 RSSI 信号的传播特性，认为距离路径损耗模型解算出的信标到未知节点的距离越短，则未知节点在多个信标组成的公共范围内更靠近其对应信标节点，反之未知节点和信标距离越大，则此信标在定位算法中权重越低。因此，该算法以信标节点到公共多边形区域的距离倒数为权重进行距离加权处理，加权后的交点值为未知点坐标。以三个信标为例，其未知节点坐标 $p(x, y)$ 公式如下：

$$\left\{ \begin{array}{l} x = \frac{\frac{x_a}{d_3} + \frac{x_b}{d_2} + \frac{x_c}{d_1}}{\frac{1}{d_1} + \frac{1}{d_2} + \frac{1}{d_3}} \\ y = \frac{\frac{y_a}{d_3} + \frac{y_b}{d_2} + \frac{y_c}{d_1}}{\frac{1}{d_1} + \frac{1}{d_2} + \frac{1}{d_3}} \end{array} \right. \quad (3-4)$$

虽然单距离加权质心定位算法相对于基于信号 RSSI 的质心定位算法在定位精度

上有所改善，但其仅限于对单个信标节点进行权重调整。然而，由于公共多边形中的每个节点都由两个距离值确定，因此文献^[78]提出同时引入两个距离权重值的双距离加权质心定位算法，在该算法中，每个信标节点到待定位未知节点的距离和倒数被用作权重，由此得到的待定位未知节点的坐标估算公式如下：

$$\left\{ \begin{array}{l} x = \frac{\frac{x_a}{(d_2+d_3)} + \frac{x_b}{(d_1+d_2)} + \frac{x_c}{(d_1+d_3)}}{\frac{1}{(d_2+d_3)} + \frac{1}{(d_1+d_2)} + \frac{1}{(d_1+d_3)}} \\ y = \frac{\frac{y_a}{(d_2+d_3)} + \frac{y_b}{(d_1+d_2)} + \frac{y_c}{(d_1+d_3)}}{\frac{1}{(d_2+d_3)} + \frac{1}{(d_1+d_2)} + \frac{1}{(d_1+d_3)}} \end{array} \right. \quad (3-5)$$

3.3.2 基于距离修正的加权质心定位算法

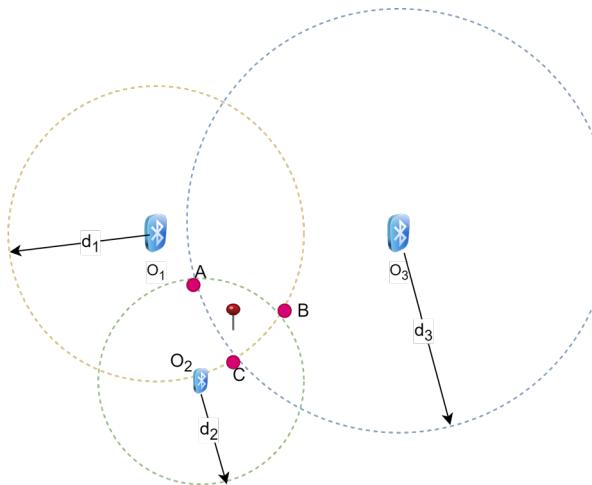


图 3-8 基于距离修正的加权质心定位算法

Fig.3-8 Schematic diagram of the improved weighted centroid location algorithm

虽然上述公式(3-30)引入两个距离作为权重，可以一定程度上提高加权质心定位算法的精度。如图 3-8 所示，在实际室内定位应用场景中，往往会出现两个距离数值相差较大的情况（例如 $d_3 > d_2$ ），导致较远信标（ O_3 ）的距离在权重分配中占据主导地位，给另一个较近信标（ O_2 ）的距离分配较低的权重值。

因此为了解决上述问题，本文进一步改进权重分配策略，提出了以下的修正方法：

$$\frac{1}{(d_2+d_3)} \xrightarrow{\text{修正1}} \left(\frac{1}{d_2} + \frac{1}{d_3} \right) \xrightarrow{\text{修正2}} \left(\frac{1}{d_2^n} + \frac{1}{d_3^n} \right) \quad (3-6)$$

首先，为了改变引入两个距离权重后造成的次要数据主导地位现象，通过修正 1 步骤，弱化较远的距离 (d_3) 在其权值中的过大占比，而使得距离更远的信标变成次要，距离更近的变为主导。其次，在修正 1 方法的基础上加上修正 2 步骤，通过引入修正系数 n 可以根据实际情况调整修正的程度，因此基于距离修正的加权质心定位算法公式如下：

$$\left\{ \begin{array}{l} x = \frac{x_a \left(\frac{1}{d^n_b} + \frac{1}{d^n_c} \right) + x_b \left(\frac{1}{d^n_a} + \frac{1}{d^n_c} \right) + x_c \left(\frac{1}{d^n_a} + \frac{1}{d^n_b} \right)}{2 \left(\frac{1}{d^n_a} + \frac{1}{d^n_b} + \frac{1}{d^n_c} \right)} \\ y = \frac{y_a \left(\frac{1}{d^n_b} + \frac{1}{d^n_c} \right) + y_b \left(\frac{1}{d^n_a} + \frac{1}{d^n_c} \right) + y_c \left(\frac{1}{d^n_a} + \frac{1}{d^n_b} \right)}{2 \left(\frac{1}{d^n_a} + \frac{1}{d^n_b} + \frac{1}{d^n_c} \right)} \end{array} \right. \quad (3-7)$$

综上所述，通过对采集的蓝牙 RSSI 信号进行分析和修正，以及使用基于距离修正的加权质心定位，这些措施可以有效地降低环境因素对定位精度的干扰，提高定位精度，其技术流程如图 3-9 所示：

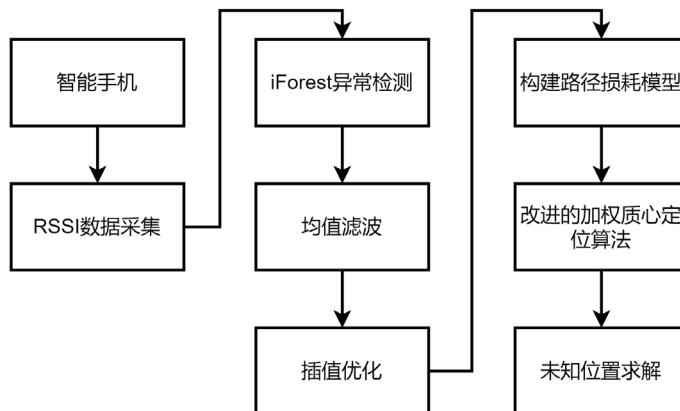


图 3-9 本文方法的技术流程

Fig.3-9 Technical flow of the method in this paper

3.4 实验设计与结果分析

3.4.1 实验设计

为验证本文方法的有效性，实验在长为 12m、宽为 10m 的室内走廊中进行，共部署 20 个低功耗蓝牙信标，信标距离地面高度约为 2.6m，相邻信标之间的距离为 1.8m。实验使用基于 Android 13 系统的 OPPO Reno6pro 智能手机采集蓝牙信号 RSSI 数据，

使用如图 3-10 所示的采集软件进行采集。采集到的蓝牙 RSSI 数据包括 MAC 地址和对应的 RSSI。

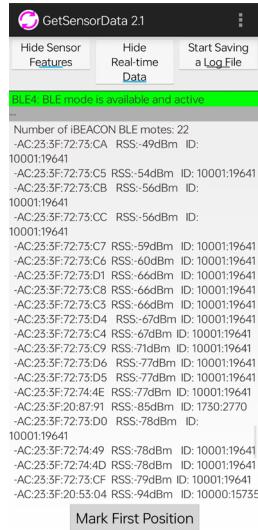


图 3-10 蓝牙采集界面

Fig.3-10 Bluetooth acquisition interface

为验证本章所提出算法的有效性，本节选择了三个蓝牙 AP 作为发射信标，它们分别是 AC:23:3F:72:73:CB、AC:23:3F:72:73:D4、AC:23:3F:72:73:C7，其坐标和简称为 CB (0, 1.8)、D4 (3.6, 0)、C7 (3.6, 5.4)。如图 3-11 所示，这三个蓝牙 AP 构成了一个三角形区域。在这个区域内选择了六个位置作为待定位的检查点，并进行了 30 秒的采集，采集频率为 5Hz。如图 3-11 所示，其中 P1、P3 和 P6 的分别靠近信标 CB、D4 和 C7，P2、P4 和 P5 随机分布在三个信标组成的中间范围。

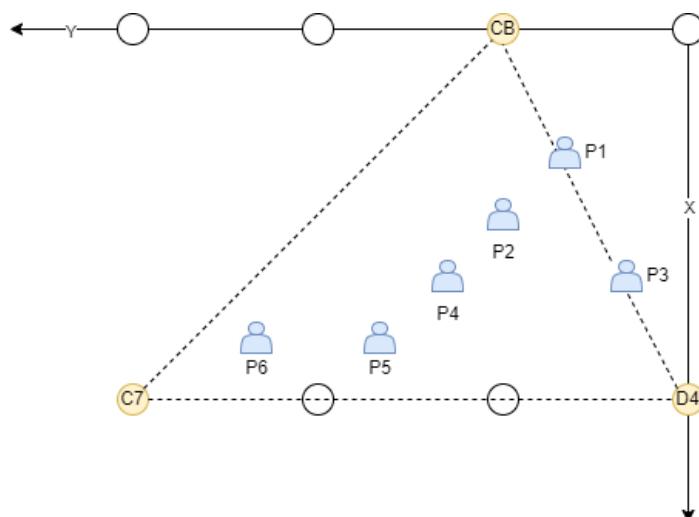


图 3-11 实验节点分布

Fig.3-11 Distribution of experimental nodes

3.4.2 实验结果分析

经过智能手机采集蓝牙 RSSI 信号并使用 iForest-MF 检测滤波后，利用对数距离路径损耗模型得出待定位节点到三个蓝牙 AP 的距离。接着，将距离值和蓝牙 AP 坐标带入基于 RSSI 定位的质心定位算法、双距离加权质心定位算法以及本文改进算法。由于改进算法的修正系数 n 对定位结果有着一定的影响，在多次实验对比后发现在 $n = 4$ 时效果最佳，因此本节选取 $n = 4$ 与另外两种算法进行比较。最终的定位坐标结果与误差值如下表 3-2 所示：

表 3-2 三种算法的定位坐标和误差

Tab.3-2 Positioning coordinates and errors of the three algorithms

待测 节点号	实际 坐标/m	质心定位算法		双距离加权质心 定位算法		本文改进算法	
		坐标值/m	误差值 /m	坐标值/m	误差值 /m	坐标值/m	误差值 /m
P1	(1.2, 1.2)	(2.32, 1.66)	1.21	(2.03, 1.48)	0.87	(1.80, 1.56)	0.69
P2	(1.8, 1.8)	(2.40, 2.53)	0.95	(2.33, 2.54)	0.91	(2.24, 2.58)	0.89
P3	(2.6, 0.6)	(1.04, 1.36)	1.55	(1.96, 1.48)	1.06	(2.11, 1.32)	0.87
P4	(2.4, 2.4)	(2.73, 3.10)	0.78	(2.65, 3.20)	0.83	(2.57, 3.13)	0.74
P5	(3.0, 3.0)	(2.07, 4.11)	1.44	(4.13, 3.21)	1.15	(3.94, 3.09)	0.95
P6	(3.0, 4.8)	(4.07, 3.71)	1.52	(3.85, 5.54)	1.10	(3.74, 5.53)	1.04

表 3-3 三种算法的定位误差统计

Tab.3-3 Positioning error statistics of the three algorithms

定位方法	最大定位误差/m	最小定位误差/m	平均定位误差/m
质心定位算法	1.55	0.78	1.24
双距离加权质心定位	1.15	0.83	0.98
本文改进算法	1.04	0.69	0.87

为了进一步探究三种定位算法的实验结果，对实验数据做以下可视化和统计分析。由图 3-12 和表 3-3 可知，在本文实验的三种算法中，质心定位的误差最大，最大定位

误差超过 1.5m，最小定位误差 0.78m。由于质心定位是对公共区域坐标的简单计算，因此显示定位结果不稳定。其次，双距离加权质心定位算法在引入两个距离权重后，相对质心定位有明显提升，最大和最小定位误差分别为 1.15m 和 0.83m，平均定位误差为 0.98m。最后，由于本文区分不同距离权重值，改进算法定位精度优于另外两种算法。改进算法的最大、最小定位误差分别为 1.04m 和 0.69m，平均定位误差为 0.87m。相对于质心定位算法，改进算法的定位精度提升 29.83%；相对于双距离加权质心算法，改进算法的定位精度提升 9.18%。

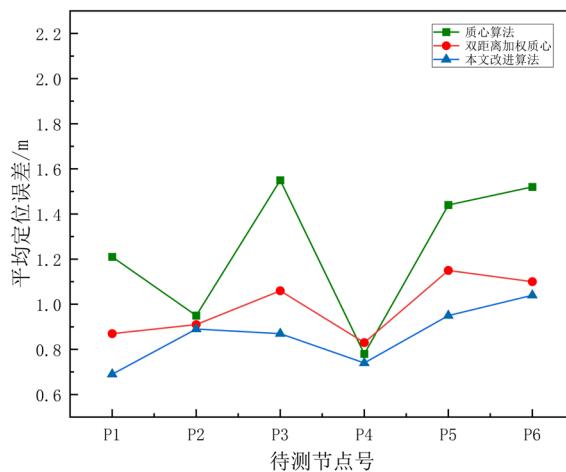


图 3-12 三种算法的平均定位误差对比

Fig.3-12 Comparison of the average positioning error of the three algorithms

3.5 本章小结

本章主要对蓝牙 RSSI 定位进行研究。首先，本章对蓝牙 RSSI 信号分布特性和传播规律进行分析，分析表明在受干扰环境中蓝牙 RSSI 信号会产生骤升和急降现象。其次，针对信号特性分析问题，提出基于 iForest-MF 修正的 RSSI 修正方法，通过修正后信号的标准差和方差均有所降低。其次，针对质心定位算法定位精度不高问题，介绍了基于距离的加权质心定位算法，并在双距离加权质心定位算法上提出基于距离修正的加权质心定位算法。实验结果表明，相对于质心定位和双距离加权质心定位算法，本章改进方法其定位精度分别提升了 29.83% 和 9.18%。

第四章 支持行人模式感知的 PDR 定位优化方法

PDR 技术无需额外部署定位设备，仅需智能手机便可实现短时间内的连续高精度定位效果。然而，由于行人运动状态多样化，且手机内置传感器存在噪声和累积误差，因此利用复杂的运动数据实现鲁棒、精准的定位具有重要意义。本章旨在解决上述问题，首先利用分类器模型对加速度和角速度信息进行分析，以识别感知行人的多种运动模式。其次，采用混合滤波还原真实加速度信号特征，并结合模式识别提出特征约束的峰值检测算法，以对步频进行检测，并在行走中动态调整阈值大小，从而减少计步误差。最后，介绍姿态角估计方法，并对航向角进行优化。

4.1 基于 CNN-BiLSTM-SA 的行人运动模式识别

在行走过程中，行人的不同运动状态和手机持有方式会导致波动特性的多样性，从而使得单一的步频算法难以适用于不同的运动模式。因此，本研究提出一种基于深度学习的分类模型，利用对加速度和角速度数据识别行人不同的运动模式，以优化步频算法的准确性和鲁棒性。该算法分为两个步骤：第一步，对运动状态和手机姿势进行定义和分类；第二步，利用采集的传感器数据训练分类器模型，并使用该模型进行分类识别。

4.1.1 运动模式划分

由于传统单一模式下的步频检测算法不适用于多种运动模式，本研究根据行人日常运动和使用手机的习惯，将运动模式分为运动姿态和手机姿态两类。其中，运动姿态代表行人在行走过程中的速度习惯，包括正常行走和快走；手机姿态代表行人使用手机时的姿势，包括导航、通话、摆臂和口袋四种。这两种姿态彼此独立，共同产生 8 种组合模式。

- 1) 导航：行人在走路时将手机保持在胸前水平。
- 2) 通话：行人在走路时保持通话状态。
- 3) 摆臂：行人在走路时右手握手机自然摆动，假设手机屏幕指向身体一侧。
- 4) 口袋：行人走路时，手机屏幕朝内放置裤子口袋里。

如图 4-1 所示显示了正常行走下使用四种手机姿态的惯性传感器特性。从数据中可以看出，行人在不同的手机姿态下，其加速度和角速度传感器的数值和波动变化存在差异。因此，可以充分利用这种差异性来识别不同的手机姿势。

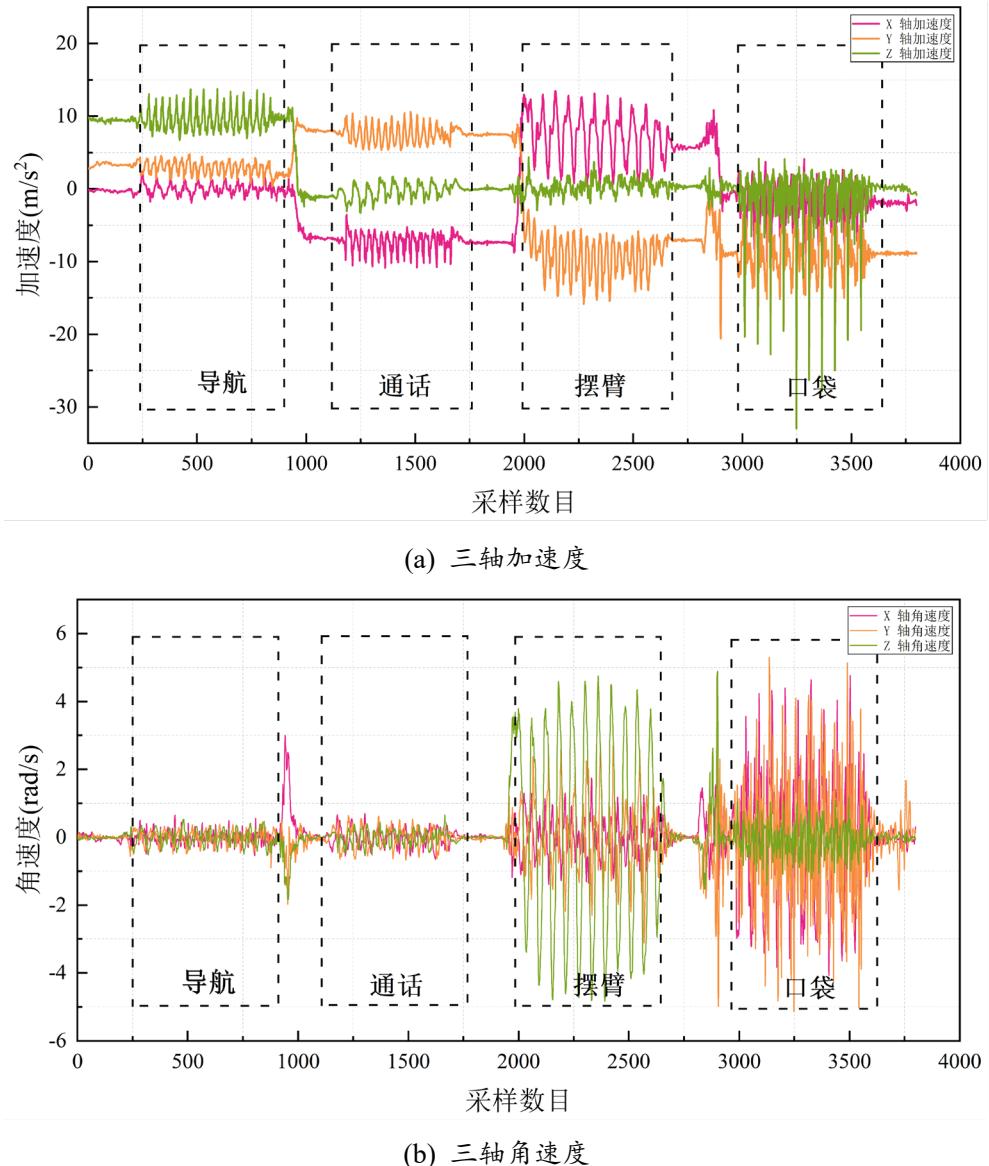


图 4-1 不同运动姿态下惯性传感器特性

Fig.4-1 Inertial sensor characteristics under different motion attitudes

4.1.2 CNN-BiLSTM-SA 模型

行人运动数据具有多样性和复杂性，需要采用适当的分类器来识别不同的运动模式。目前常用的机器学习方法包括决策树、随机森林、支持向量机和人工神经网络等^[79]。尽管传统分类器虽然能够识别不同的运动活动，但其准确率十分依赖于从源数据

中手动提取出不同类型的特征，如统计特征（例如均值、方差、能量）、时域特征（例如过零比）、频域特征（例如快速傅里叶变换）^[80]。此外，不同类型特征对于不同运动模式的敏感度存在差异，因此需要丰富的经验积累才能选取合适的特征，并且这些特征很难推广到其他模型中。

因此，为了提高运动识别的准确率，增强识别的鲁棒性，并减少手动提取特征的影响，本文提出一种无需从源数据二次提取特征的深度网络框架模型 CNN-BiLSTM-SA，其结构模型如图 4-2 所示。

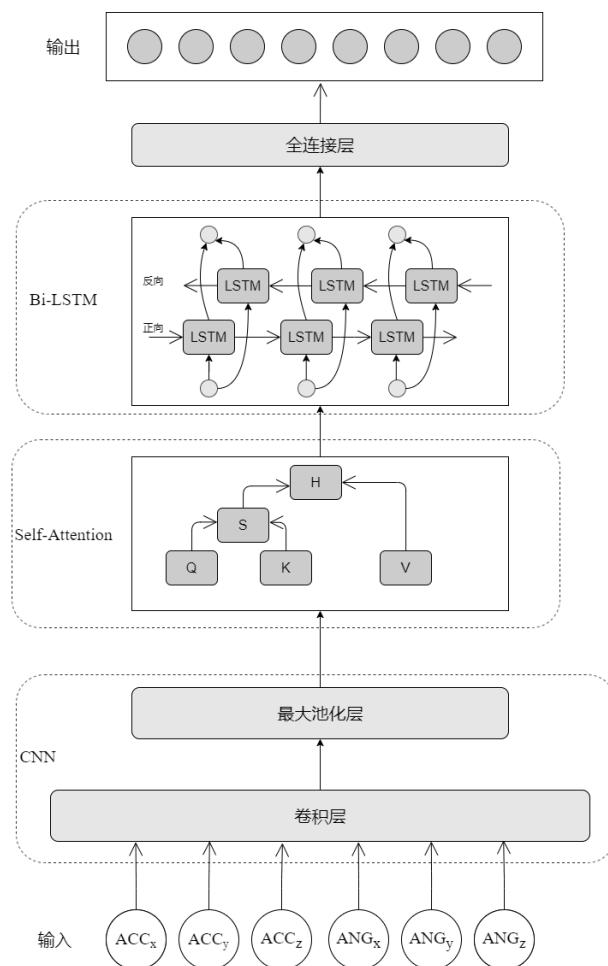


图 4-2 CNN-BiLSTM-SA 组合模型结构

Fig.4-2 Structure of CNN-BiLSTM-SA combined model

1) 卷积层

为了自动提取行人运动加速度和角速度数据中的局部关键特征，本文采用具有高效网格数据分析能力的 CNN (Convolutional Neural Networks) 神经网络。该网络的核心包括卷积层和池化层。卷积层通过卷积核对加速度和角速度数据进行卷积操作，提

取对应的运动特征信息。由于真实环境中的运动状态是非线性的，因此在网络中引入 ReLU 激活函数以增强非线性能力。最后，最大池化层被用于压缩和聚合从卷积层提取的特征，从而降低特征维度并保留关键特征信息。

2) 双向长短时记忆层

为解决行人运动姿态分析中的双向时序分析问题，本文提出采用 Bi-LSTM（Bidirectional Long Short-Term Memory Network）网络。该网络是在 LSTM 模型基础上进行扩展，具有双向传输时序分析能力。考虑到行人在行走时每一步动作姿态内存有密切的前后关系，并且在运动模式切换过程中前后数据会发生较大变化，因此采用由正向 LSTM 和反向 LSTM 结合的 Bi-LSTM 网络。相对于单向 LSTM，Bi-LSTM 具有更为丰富的时序分析能力^[81]，更能够充分地分析行人运动姿态前后之间的关联性。

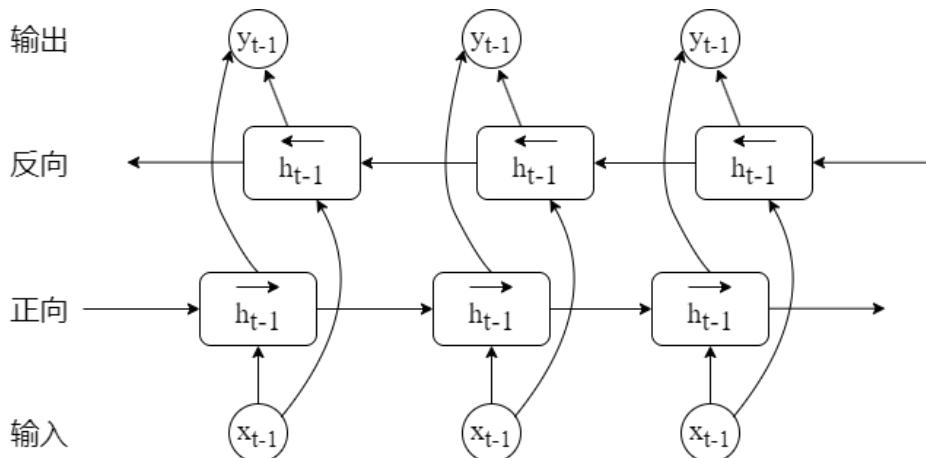


图 4-3 Bi-LSTM 模型结构

Fig.4-3 Bi-LSTM model structure

单层 Bi-LSTM 如图 4-3 所示，正向 LSTM 保留行人过去到未来时刻的重要信息，反向 LSTM 保留行人从未来到过去时刻的重要信息，且传输公式如下：

$$h_t^{\rightarrow} = f(U^1 h_{t-1}^{\rightarrow} + W^1 x_t + b^1) \quad (4-1)$$

$$h_t^{\leftarrow} = f(U^2 h_{t+1}^{\leftarrow} + W^2 x_t + b^2) \quad (4-2)$$

$$y_t = W'^1 h_t^{\rightarrow} + W'^2 h_t^{\leftarrow} + b^0 \quad (4-3)$$

正反层 LSTM 的公式分别为(4-1)和(4-2)，它们可用于对过去和未来的数据信息进行提取和保留，根据两个方向的隐层状态，由公式(4-3)计算 t 时刻 Bi-LSTM 网络的

输出值 y_t 。其中 h_t^{\rightarrow} 和 h_t^{\leftarrow} 分别表示正反 LSTM 隐藏层 t 时刻状态, U^1 和 U^2 分别为前后时刻权重值, W^1 和 W^2 为当前时刻权重值, W^{t1} 和 W^{t2} 为当前时刻隐层权重值, b^0 、 b^1 、 b^2 分别表示对应偏置向量。

3) 自注意力层

自注意力 (Self-Attention, SA) 机制本质是从大量信息中提高关键特征信息的权重, 减少不重要或不相关信息^[82]。由于运动中采样的三轴加速度和角速度信息在其不同运动模式中, 对应其不同轴数据的敏感程度也不同, 因此引入自注意力机制层如图 4-4, 为输入的特征分配不同权重。

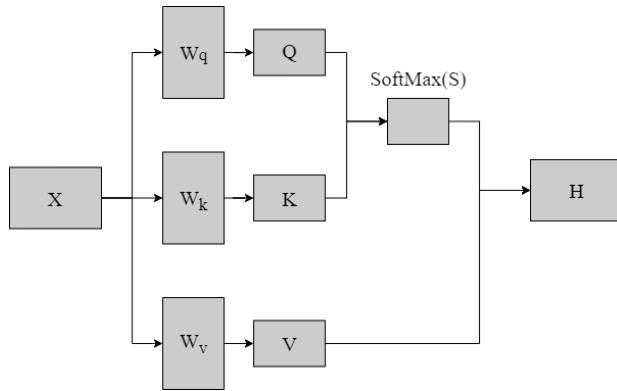


图 4-4 自注意力模型结构

Fig.4-4 Self-Attention Model Architecture

本文在 CNN 层后加入注意力机制, 首先对 CNN 输出的特征矩阵进行空间映射, 然后通过相似度计算得出注意力分数, 再使用 SoftMax 将分数归一化处理, 最后将得到结果进行加权求和得到全局的特征信息。其计算过程如下:

- 1) 首先对每个输入 $X = [x_1, \dots, x_N] \in R^{D_x \times N}$ 映射到三个不同空间分别得到查询向量、键向量和值向量的矩阵 Q 、 K 和 V , 计算公式如下:

$$Q = W_q X \in R^{D_k \times N} \quad (4-4)$$

$$K = W_k X \in R^{D_k \times N} \quad (4-5)$$

$$V = W_v X \in R^{D_v \times N} \quad (4-6)$$

其中 W_q 、 W_k 和 W_v 分别为线性映射的参数矩阵。

- 2) 其次利用得到的 Q 和 K 的转置点积计算输入特征间的相关性分数 S , 并引入 K 的维度 D_k 使得点积计算结果平滑从而在训练中保持梯度稳定。其中分数 S 计算公式

如下：

$$S = \frac{QK^T}{\sqrt{D_k}} \quad (4-7)$$

3) 最后使用 SoftMax 归一化处理为概率分布矩阵，再点积 V 得到输出特征矩阵 H ，公式如下：

$$H = V \cdot \text{SoftMax}\left(\frac{QK^T}{\sqrt{D_k}}\right) \quad (4-8)$$

4.1.3 模型评价

本文为了验证所提出的运动模式识别模型的有效性，使用基于 Android 13 系统的 OPPO Reno6pro 智能手机作为实验设备，该手机内置三轴加速度计和三轴陀螺仪，传感器输出频率 F_s 设置为 50Hz。实验选取了五名行人，身高范围在 1.65m 至 1.85m 之间。根据 4.1.1 节中划分的 8 种组合运动模式，每名行人按照每个运动模式直线行走 60 步，总计每位行人实际行走步数为 480 步。

为了验证模型的识别效果，本研究收集了五名行人的 69878 条实验样本数据，每条数据包含六种特征值，即三轴加速度(ACC_x 、 ACC_y 、 ACC_z)和三轴角速度(ANG_x 、 ANG_y 、 ANG_z)。将每 30 条数据制作成尺寸为 30*6 的二维切片数据，并按照 8 种运动模式进行标签分类。其中，将 70% 的数据作为训练集，30% 的数据作为测试集，以测试模型分类结果。

1) 不同卷积层的识别精度对比

为了分析 CNN-BiLSTM-SA 模型中不同卷积层数对模型识别性能的影响，本研究设计了不同层数进行对比实验，并分别采用分类交叉熵损失函数和准确率作为评价指标。交叉熵作为一种常用的度量模型预测结果与真实结果之间差异程度的指标，其值越小表示两个概率分布越相似^[83]。

实验分别对比使用 1~4 层 CNN 卷积层的模型识别交叉熵值和准确率，分析不同层数对识别精度的影响，实验结果如表 4-1 所示。实验结果，使用不同层数会对识别精度有不同影响，在分类交叉熵评价中，两层卷积层数相对于一层、三层和四层分别降低 0.0165、0.0078 和 0.0364，同时在识别准确率中两层卷积层分别高于其他层数 0.67%、0.48% 和 1.35%。实验证明了两层卷积层识别精度均高于其他网络层数，并且

增加层数并没有使识别精度提高，反而会增加模型复杂度和过拟合而降低识别效果。

表 4-1 不同 CNN 层数的识别精度对比

Tab.4-1 Comparison of recognition accuracy with different number of CNN layers

卷积层数	交叉熵	准确率(%)
1	0.1046	97.85
2	0.0881	98.52
3	0.0959	98.04
4	0.1245	97.17

2) 运动模式识别实验

本文为了验证模型的有效性，选择了决策树、随机森林、CNN、CNN-LSTM 以及本文提出的 CNN-BiLSTM-SA 五种模型进行对比实验，并以识别准确率作为评价标准。实验结果表明，在仅输入原始加速度角速度数据而未使用人工二次提取特征的情况下，深度学习模型相对于传统的决策树和随机森林方法表现出更高的识别准确率。此外，相较于同类深度学习模型 CNN 和 CNN-LSTM，本文提出的方法分别提高了 3.04% 和 2.21% 的准确率，结果如图 4-5 所示。。

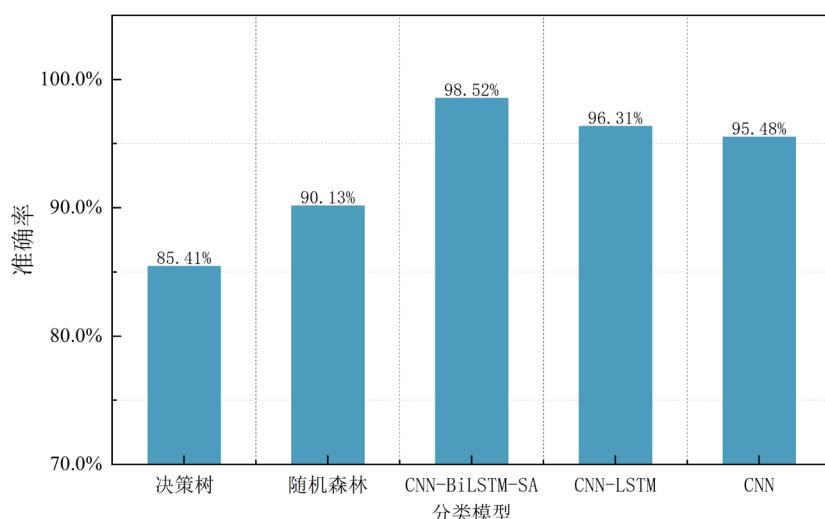


图 4-5 五种分类模型准确率结果

Fig.4-5 Accuracy results of five classification models

为了进一步验证 CNN-BiLSTM-SA 模型在分类任务中的性能，本研究采用三种深度学习网络模型进行了定量分析。在相同实验环境下，我们采用了初始学习率为 0.005、批尺寸 batch-size 为 64、迭代轮次 epoch 为 200 以及 he_uniform 方法初始化

每层网络权重和偏置的设置。图 4-6 展示了训练过程及结果，证明本文提出的 CNN-BiLSTM-SA 模型在识别行人运动模式方面准确率明显优于 CNN 和 CNN-LSTM 模型。

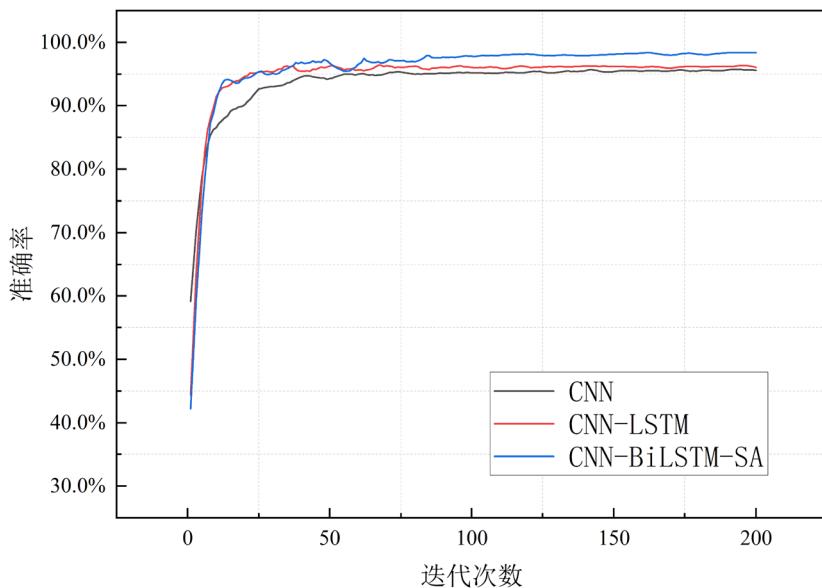


图 4-6 三种深度学习模型训练过程对比

Fig.4-6 Comparison of the training process of three kinds of deep learning models

4.2 基于运动模式识别的自适应步频检测

根据 2.2.1 节关于步频检测的介绍，人在行走过程中身体会呈现出周期性的变化规律，这种规律可以被加速度计采集到的类似正弦波的信号数据所表现。因此，本文提出了结合运动模式的预处理数据，并利用两个自适应特征来约束峰值检测算法，从而减少步频检测误差。

4.2.1 基于混合滤波的数据预处理

由于手机内置的廉价惯性传感器测量精度较低，且该传感器在数据采集过程中易受行人相对运动过程中身体抖动的影响，因此采集到的原始数据中存在大量噪声，这些噪声会产生伪波峰影响步频检测的计步精度。因此，在进行步频检测前，应对原始数据进行预处理，以减少伪波峰的影响。本文提出了一组滤波方法的组合，包括低通滤波和卷积平滑滤波。首先，使用低通滤波方法可以减少原始数据中的噪声，并消除明显的伪波峰。然后，使用卷积平滑滤波方法可以二次平滑数据，得到更适合进行步频检测的运动规律。

由于单轴加速度易受手机方向影响，因此使用三轴的合加速度：

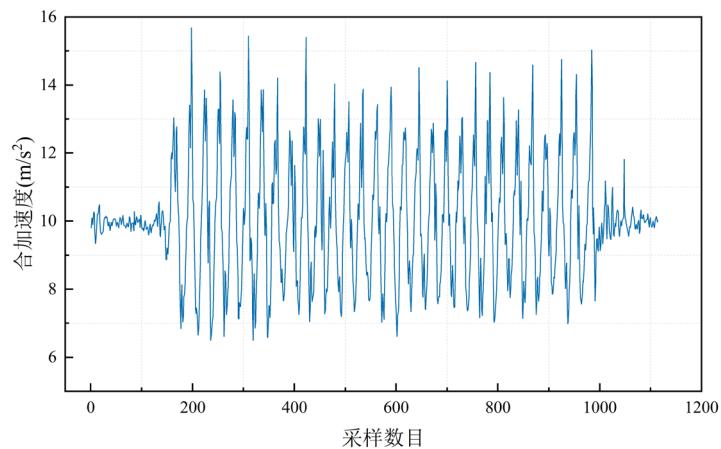
$$a_{mag} = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (4-9)$$

其中 a_{mag} 为合加速度大小， a_x 、 a_y 和 a_z 是分别是 x 轴、y 轴和 z 轴的加速度大小。

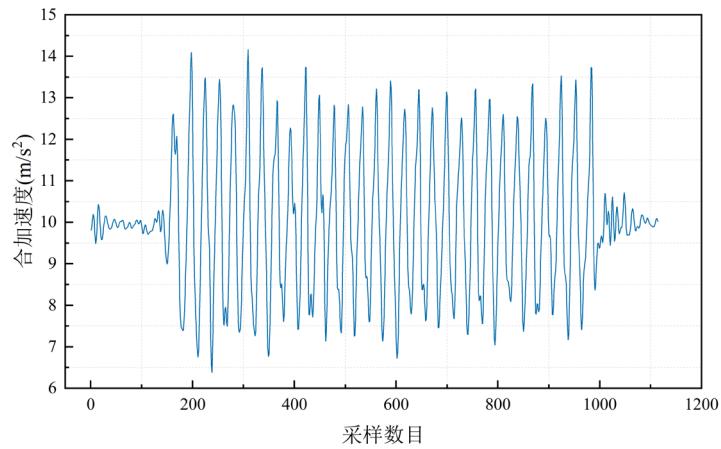
为了消除噪声影响，首先使用过滤器过滤噪声，以消除大量伪波峰。然后，使用卷积平滑滤波方法对数据进行平滑处理。该方法采用线性最小二乘法对相邻数据集进行拟合，使用一个低次多项式，在不改变信号趋势的前提下平滑数据，得到更适合进行步频检测的运动规律。其公式如下：

$$Y_j = \sum_{i=\frac{1-m}{2}}^{\frac{m-1}{2}} C_i y_{j+i}, \quad \frac{m+1}{2} \leq j \leq n - \frac{m-1}{2} \quad (4-10)$$

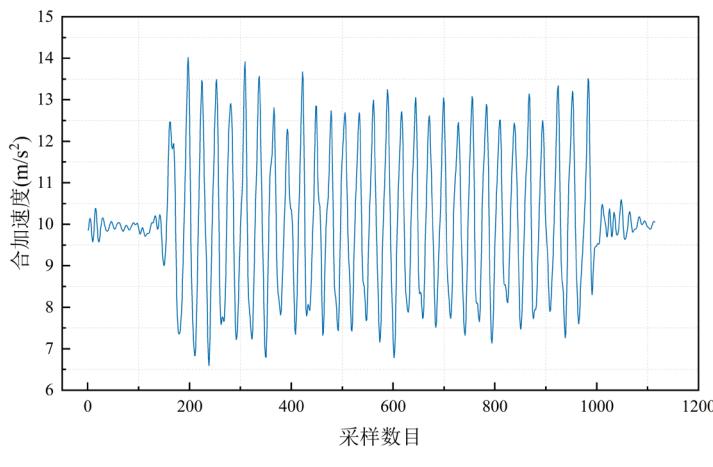
其中 Y_j 为过滤后值， C_i 为卷积系数， m 为多项式拟合阶数。



(a) 初始加速度数据



(b) 低通滤波后加速度数据



(c) 卷积平滑后加速度数据

图 4-7 加速度数据预处理

Fig.4-7 Acceleration data pre-processing

如图 4-7 所示, 初始加速度信号(a)中存在多个伪波峰, 这些伪波峰是造成计步较多的重要原因之一。与原始数据相比, 第一阶段(b)在通过低通滤波后, 可以过滤干扰噪声消除大量伪波峰; 第二阶段(c)为再次使用卷积平滑滤波器二次滤波, 伪波峰数量减少同时波形显得愈加平滑, 更加清晰的反映出行人运动的规律和特征。

4.2.2 基于特征约束的峰值检测算方法

行人在行走过程中, 身体重心会在垂直方向上产生周期性波动, 因此合加速度数据呈现具有波峰波谷的周期性振荡特性, 而峰值检测则是根据加速度数据中波峰个数来计算步数的。虽然滤波技术可以消除运动方式和身体抖动等因素产生的大部分伪波峰, 但是仍然存在部分伪波峰导致步数计算过多的问题。因此, 本文提出两种约束条件: 最小峰距和自适应阈值, 来约束峰值检测。并根据分类器识别出的不同运动模式分别调整最小峰距和自适应阈值, 以进一步提高峰值检测算法的鲁棒性。

1) 自适应最小峰距

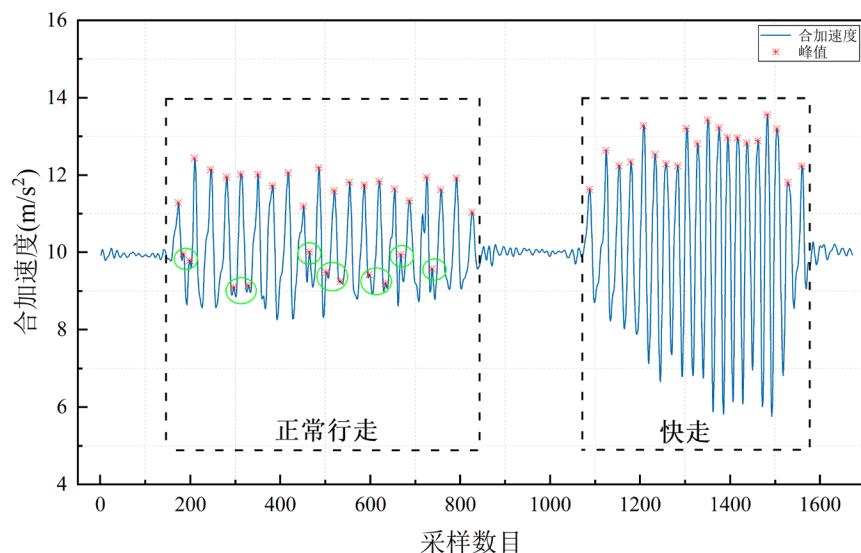
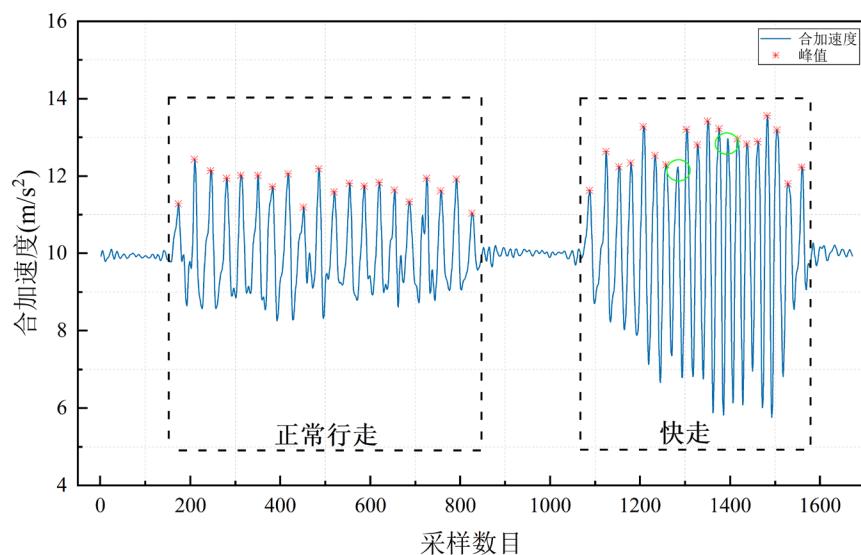
虽然经过数据预处理后能够滤除大量噪声, 但在两个峰值之间仍存在未被过滤的伪波峰, 这些伪波峰会被基于峰值检测的方法计入正常计步而增加误差。因此, 本文根据相同运动模式下两峰值间周期一致原理, 使用最小峰距去除相邻峰内的其他波峰数, 计算过滤后峰值 $Peak_t$ 公式如下:

$$Peak_t = (a_t \geq (a_{t-k} : a_{t-1}) \& \& a_t \leq (a_{t+1} : a_{t+k})) \quad (4-11)$$

其中 a_t 指在 t 点样本下合加速度值, k 指 t 点左右两侧的样本数量阈值, 其中 k 值

应小于两个真实波峰之间的样本数。由于正常行走和快走时运动周期频率不同，因此行人在两种运动状态下产生的真实波峰间样本数也不同，使用固定阈值 k 限制最小峰距会造成计数误差问题。

根据实验数据分析，如图 4-8(a)所示当设置阈值 $k=10$ 时，行人在快走中步频算法的峰值等于真实步数，但切换到正常行走中由于阈值设置过小会引入未被过滤的伪波峰(绿色圈)，增加伪步数统计；如图 4-8(b)当设置阈值 $k=20$ 时，行人在正常行走下能过滤伪波峰精确计步，但运动切换到快走后，由于阈值设置过大而忽略其中的真峰值(绿色圈)，而减少真实步数统计。

(a) 正常行走和快走 $k=10$ (b) 正常行走和快走 $k=20$

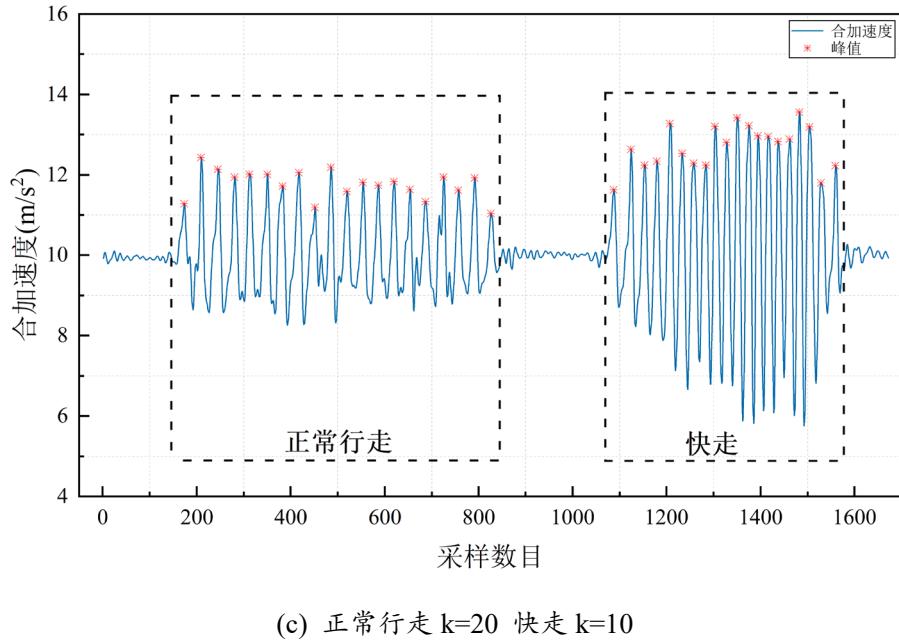
图 4-8 不同 k 值下峰值

Fig.4-8 Peak values at different k values

因此本文在最小峰距算法中提出自适应阈值，先根据运动模型检测出当前运动状态属于正常行走还是快走，并自适应调整最小峰距 k 值。根据实验结果，本文设置正常行走模式下 $k=20$ ，快走模式下 $k=10$ ，如图 4-8(c)所示在不同运动模式下有效利用不同阈值获得更高精度检测。

2) 自适应动态阈值

行人在行走过程中，不同手机姿态下的传感器数据会产生不同的周期性特征。在导航模式下，每走一步时，先出现一些小波峰，然后出现一个较大的波峰。这些大波峰对应着真实的一步，而影响计步的小波峰需要作为伪波峰予以消除。而在口袋模式下，每走一步时，先出现一个大波峰，然后出现一些小波峰，接着出现一个中等大小的波峰，其中需要真实计步的波峰呈现一大一中的规律。在使用固定阈值设置方法时，设置较小的固定阈值会引入伪波峰，而设置较大的固定阈值会将口袋模式下的中峰作为伪波峰排除计步。

因此，本文提出了一种自适应的动态阈值法，能够有效提高不同运动模式下的计步精度。动态阈值法基于在一个窗口内加速度的最大值和最小值构建的动态阈值，其中窗口尺寸大小取决于行人的运动状态和采集频率，不同的窗口大小同样会影响阈值

精度。

在一般情况下，正常走与快走的每步平均时间^[84]如表 4-2 所示：

表 4-2 每步平均时间

Tab.4-2 Average time per step

运动类型	每步平均时间 Ts(s)
正常行走	0.507
快走	0.469

根据不同运动状态下的每步时间 T_s 和当前手机采样频率 F_s 设置窗口尺寸公式如下：

$$W = (T_s * F_s) - 1 \quad (4-12)$$

$$TH_{peak} = \sqrt{\frac{W_{\max}(a_t)^2 + W_{\min}(a_t)^2}{2}} * d \quad (4-13)$$

TH_{peak} 为当前窗口下计算的动态阈值， W_{\max} 当前窗口的最大值， W_{\min} 当前窗口最小值， d 指趋近峰值程度，由于导航和电话姿势每一步波峰振幅大致相同，而口袋和摆臂姿势每步波峰呈大小峰形式，因此根据实验结果设置导航和电话姿势下 $d=1.05$ ，口袋和摆臂姿势下 $d=0.9$ 。经过最小峰距过滤后的峰值与窗口内动态阈值进行比较，若当前峰值不小于窗口内动态阈值 TH_{peak} ，则将此峰值计为真实一步。

如图 4-9 所示，正常行走时行人加速度值普遍低于快走模式，并且在摆臂姿势下波峰呈现一大一小的状态。因此，使用固定阈值方法无法准确检测步频，可能会忽略真实波峰或引入伪波峰。根据本文提出的自适应阈值法，利用分类器检测的不同运动模式计算当前窗口下的自适应动态阈值，从而提高步频检测精度和鲁棒性。

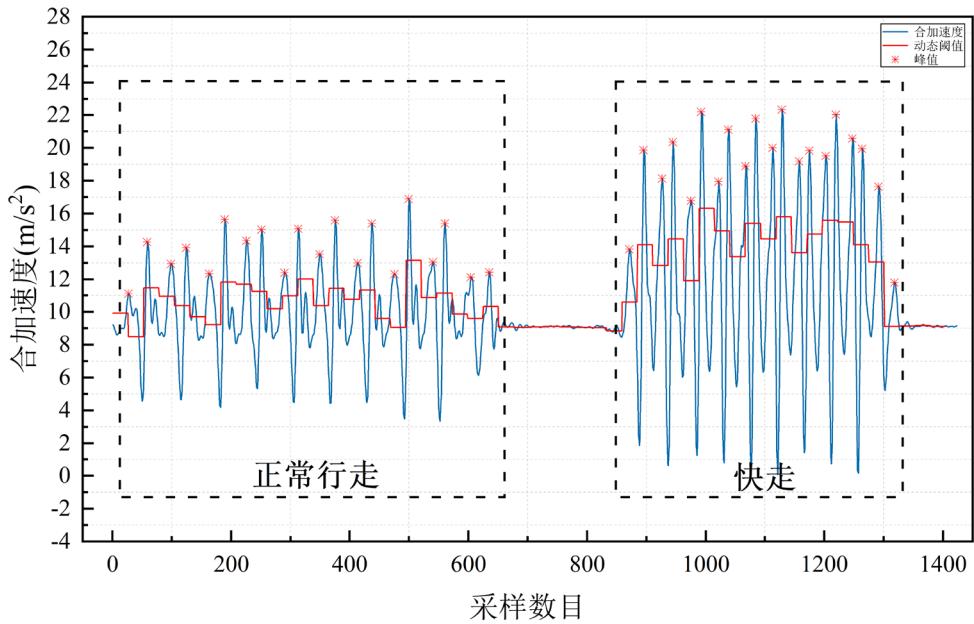


图 4-9 摆臂姿势下峰值

Fig.4-9 Peak under the swing arm pose

4.2.3 步频实验分析

为了验证本文提出步频检测算法的有效性，实验采用的设备是基于 Android 13 系统的 OPPO Reno6pro 智能手机，手机内置三轴加速度计和三轴陀螺仪，传感器输出频率 F_s 设置为 50Hz。

实验选择五名行人，身高从 1.65m 至 185m 之间。根据第二章划分行人日常习惯，分别正常行走和快走运动状态，导航、通话、摆臂和口袋四种手机姿态共 8 种组合运动模式，五位行人分别以每个运动模式按直线走 60 步，总计每位行实际行走步数为 480 步。

首先为了探究本文所提出的滤波组合对数据噪声引起伪波峰的过滤效果，本实验分别比较了无滤波、低通滤波、卷积平滑滤波和低通卷积平滑组合滤波四种方法对噪声引起伪波峰的优化情况。由于噪声不受不同行人之间的差异影响，本实验随机选取了一名行人在正常行走下的四种运动模式，每种模式直线走了 60 步，即真实波峰值为 60。

实验结果如图 4-10 所示，在未使用滤波器对原始采集数据进行预处理时，会产生大量伪波峰，导致总波峰数严重失真偏离真实值。当单独使用低通滤波和卷积平滑滤

波时，过滤效果明显降低。在口袋模式下，低通滤波明显优于卷积平滑滤波；而在摆臂模式下，卷积平滑滤波略优于低通滤波。当使用低通-卷积平滑组合滤波时，滤波效果明显优于使用单一滤波器，四种运动模式下相对低通滤波平均提升 10.25%。

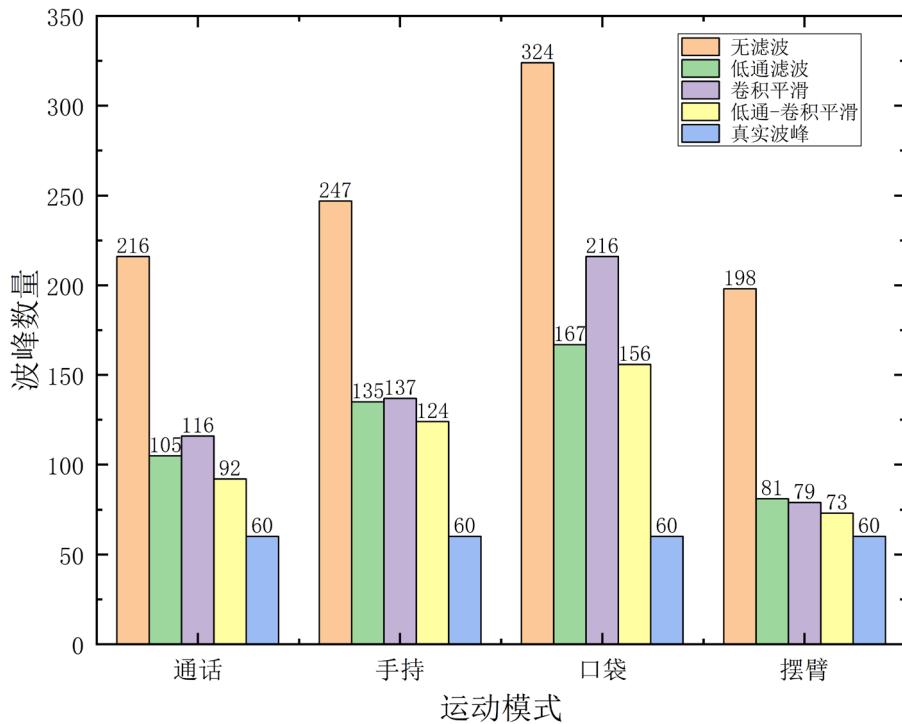


图 4-10 不同滤波下波峰值对比

Fig.4-10 Comparison of wave peaks under different filters

在步频检测实验中，考虑到不仅由于伪波峰引入伪真值，同时会由于不同阈值设置而忽略部分真值，因此引入正误差数 S_{plus} 指代算法检测中过多伪真值个数，负误差数 S_{minus} 指代被忽略的真值个数，步行估计误差计算公式如下：

$$\text{Error} = \frac{S_{\text{plus}} + S_{\text{minus}}}{S_{\text{true}}} \times 100\% \quad (4-14)$$

其中 Error 为实验误差率， S_{true} 为行人实际行走步数。

表 4-3 通过实验对比峰值检测法、固定阈值法和本文提出方法。实验结果表明，峰值检测法的平均误差率为 7.28%，是四种方法中误差最大的。固定阈值法的误差率受到选定阈值的影响。当阈值 $TH_{\text{peak}}=10$ 时，选择的固定阈值偏小，导致检测的正误差数过多，平均误差率为 4.38%。当阈值为 $TH_{\text{peak}}=11$ 时，平均误差率为 2.21%，但选择的固定阈值偏大，导致漏检的负误差数高达 14 次。因此，固定阈值难以适应不

同行人和不同运动模式的要求。本文方法在 8 种运动模式下平均误差率为 1.31%，且平均每位行人仅出现一次负误差数统计，实现不受运动模式变化影响的精确步频检测。

表 4-3 五名行人步频检测结果

Tab.4-3 Five pedestrians' step frequency detection results

行 人 编 号	实 际 步 数	峰值检测				固定阈值 $TH_{peak}=10$		固定阈值 $TH_{peak}=11$		本文方法			
		正 误 差 数	负 误 差 数	正 误 差 数	负 误 差 数	正 误 差 数	负 误 差 数	正 误 差 数	负 误 差 数	正 误 差 数	负 误 差 数	正 误 差 数	负 误 差 数
1	480	30	0	6.25%	24	0	5.00%	16	2	3.80%	9	1	2.10%
2	480	42	0	3.75%	27	0	5.65%	10	0	2.10%	4	0	0.85%
3	480	51	0	10.60%	19	0	3.95%	3	9	2.60%	6	1	1.50%
4	480	36	0	7.50%	23	0	4.80%	6	1	1.50%	4	0	0.85%
5	480	40	0	8.30%	12	0	2.50%	3	2	1.05%	4	2	1.25%

图 4-11 统计五名行人在四种手机姿势模式下的四种方法误差率。结果表明，在电话和导航模式下，四种检测方法误差率相对较低。然而，在口袋和摆臂模式下，由于加速度轨迹呈现一大一小的运动规律，波峰检测法和固定阈值法在这种复杂规律下误差率上升。相比之下，本文提出的方法采用阈值的自适应调整，在不同模式下都表现出最佳的步频检测性能。

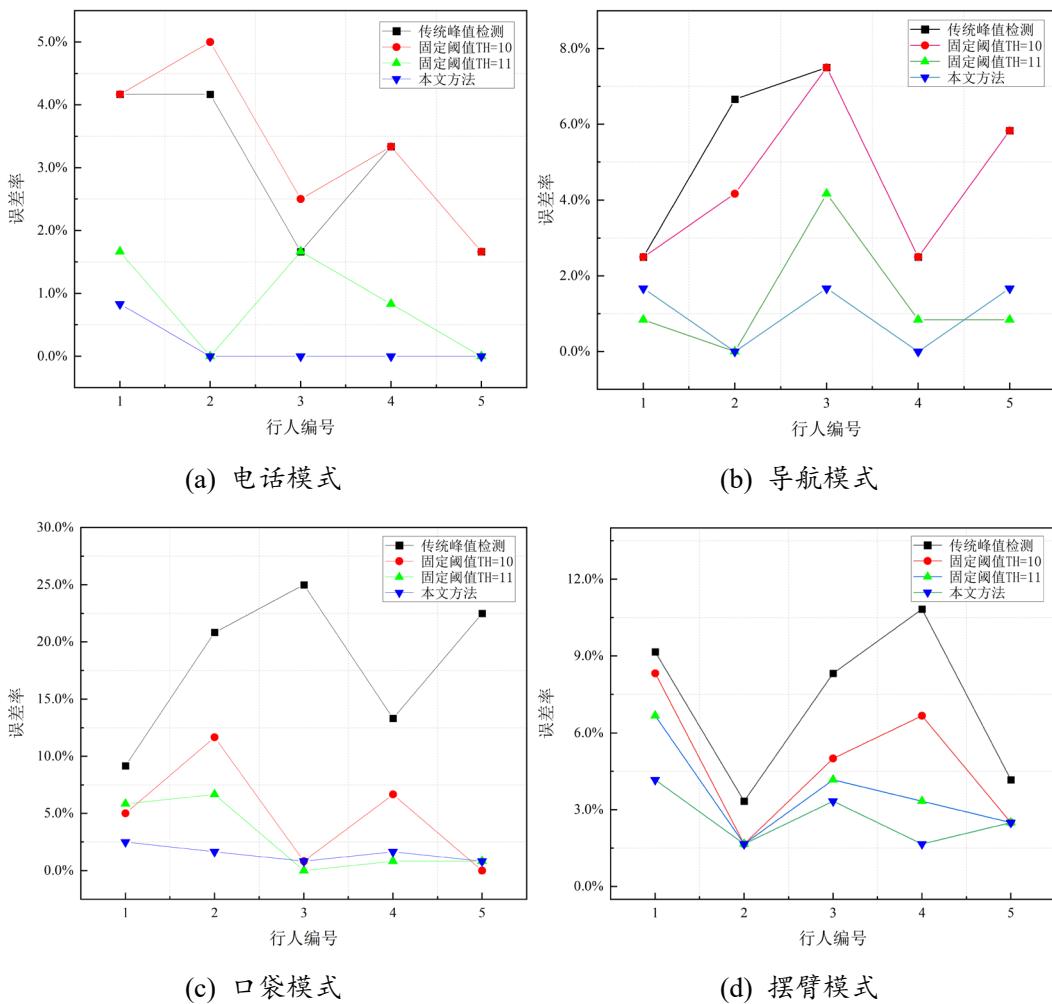


图 4-11 五名行人不同模式误差

Fig.4-11 Five pedestrians with different mode errors

4.3 行人航向估计的优化算法

在 PDR 定位技术中，航向估计是一个关键的组成部分。由于步长估计只能用于估计人在平面上的位置变化，而无法估计其方向的变化，因此在 PDR 算法中需要使用航向估计方法来估计人的方向变化，以实现更精确的定位。基于智能手机的航向估计方法利用内置的传感器，如陀螺仪、加速度计和磁力计等，测量行人的方向变化，从而计算人的位置变化方向。通过与步长估计方法结合，可以实现更准确的室内定位。

4.3.1 姿态角估计

通常，在惯性导航中使用地理坐标系来确定载体位置，而由于手机传感器数据是根据设备自身的载体坐标系采集的，在方向上需要涉及与地理坐标系之间的转换。如

图 4-12 所示，在地理坐标系中，X 轴沿当地纬线指东，y 轴沿当地子午线指北，z 轴沿当地地理垂线指上。因此，需要通过矩阵转换关系实现载体坐标系和地理坐标系之间的转换。姿态矩阵的解算方式有多样，目前常见的方法有欧拉法角、四元数法和方向余弦矩阵（也称旋转矩阵）等，以下对几种方法进行简要介绍。

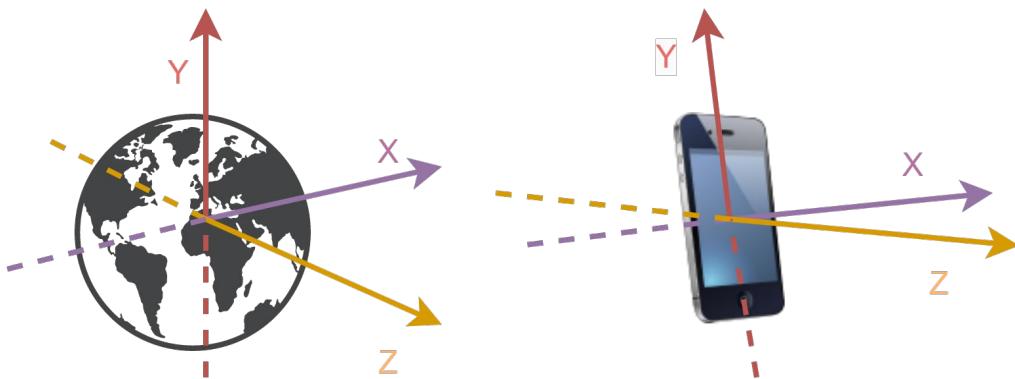


图 4-12 地理坐标系和手机坐标系

Fig.4-12: Geographic and mobile coordinate systems

1) 欧拉角法

欧拉角法的历史可以追溯到欧拉 (Leonhard Euler) 在 18 世纪提出的旋转定理。欧拉旋转定理指出，任何三维旋转都可以用三个连续的旋转(围绕不同的轴)来表示。欧拉角法将旋转分解为三个连续的旋转，分别绕三个坐标轴 (通常是 x、y 和 z 轴) 进行旋转。其中三个旋转分别称为俯仰角 (Pitch)、偏航角 (Yaw) 和翻滚角 (Roll)，它们分别表示绕 x、y 和 z 轴的旋转角度。并且在欧拉角法中，旋转顺序很重要，不同的顺序将得到不同的结果。

若以 Z-X-Y 的欧拉旋转顺序从载体坐标系 (b 系) 到地理坐标系 (n 系)。首先，需要通过选择载体坐标系的 Z 轴逆时针方向来获取偏航角度，用符号 ψ 来表示，其旋转矩阵可以被表示为：

$$R_z = \begin{bmatrix} \cos \psi & \sin \psi & 0 \\ -\sin \psi & \cos \psi & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (4-15)$$

其次，使用载体坐标系的 X 轴逆时针方向来获取翻滚角度，用符号 γ 来表示，其旋转矩阵为：

$$R_x = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \gamma & \sin \gamma \\ 0 & -\sin \gamma & \cos \gamma \end{bmatrix} \quad (4-16)$$

最后，利用载体坐标系的 Y 轴逆时针方向来获取翻滚角度，用符号 θ 来表示，其旋转矩阵为：

$$R_y = \begin{bmatrix} \cos \theta & 0 & -\sin \theta \\ 0 & 1 & 0 \\ \sin \theta & 0 & \cos \theta \end{bmatrix} \quad (4-17)$$

则旋转前的载体坐标系 $\begin{bmatrix} X \\ Y \\ Z \end{bmatrix}$ 与旋转后的欧拉角 $\begin{bmatrix} \gamma \\ \theta \\ \psi \end{bmatrix}$ 之间关系如下：

$$\begin{bmatrix} \gamma \\ \theta \\ \psi \end{bmatrix} = R_{b \rightarrow n} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \quad (4-18)$$

其中 $R_{b \rightarrow n}$ 指 b 系到 n 系的旋转矩阵，公式如下：

$$R_{b \rightarrow n} = \begin{bmatrix} \cos \theta & 0 & -\sin \theta \\ 0 & 1 & 0 \\ \sin \theta & 0 & \cos \theta \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \gamma & \sin \gamma \\ 0 & -\sin \gamma & \cos \gamma \end{bmatrix} \begin{bmatrix} \cos \psi & \sin \psi & 0 \\ -\sin \psi & \cos \psi & 0 \\ 0 & 0 & 1 \end{bmatrix} =$$

$$\begin{bmatrix} \cos \theta \sin \psi - \sin \theta \sin \gamma \sin \psi & \sin \theta \sin \gamma \cos \psi + \cos \theta \sin \psi & -\sin \theta \cos \gamma \\ -\cos \gamma \sin \psi & \cos \gamma \cos \psi & \sin \gamma \\ \cos \theta \sin \gamma \sin \psi + \sin \theta \cos \psi & -\cos \theta \sin \gamma \cos \psi + \sin \theta \sin \psi & \cos \theta \cos \gamma \end{bmatrix} \quad (4-19)$$

最终根据上式解算出三个姿态角如下：

$$\left\{ \begin{array}{l} \gamma = \arctan(R_{b \rightarrow n}^{23}) \\ \theta = \arctan(-\frac{R_{b \rightarrow n}^{13}}{R_{b \rightarrow n}^{33}}) \\ \psi = \arctan(-\frac{R_{b \rightarrow n}^{21}}{R_{b \rightarrow n}^{22}}) \end{array} \right. \quad (4-20)$$

2) 四元数法

四元数法是一种由爱尔兰数学家威廉·哈密顿 (William Rowan Hamilton) 在 1843 年发明的数学工具，旨在解决代数中的一些复杂问题。传统的欧拉角方法在某些情况

下会出现万向锁的问题，导致姿态解算失败。而四元数法可以避免这个问题，因此被广泛应用于航空器姿态解算。

四元数是一种复数扩展的数学结构，可以用一个实部和三个虚部来表示。通常用 q 表示四元数，其中实部表示旋转的余弦部分，而虚部则表示旋转轴的三个分量的正弦部分。四元数可以用公式(4-21)来表示：

$$\vec{Q}(q_0, q_1, q_2, q_3) = q_0 + q_1 \vec{i} + q_2 \vec{j} + q_3 \vec{k} = \cos \frac{\theta}{2} + \vec{u} \cdot \sin \frac{\theta}{2} \quad (4-21)$$

其中 $u = (u_1 \vec{i}, u_2 \vec{j}, u_3 \vec{k})$, $(\vec{i}, \vec{j}, \vec{k})$ 为单位矢量, θ 为相对参考坐标系的旋转角, q_0, q_1, q_2, q_3 为实数, 其求解公式如下:

$$\left\{ \begin{array}{l} q_0 = \cos \frac{\theta}{2} \\ q_1 = u_1 \sin \frac{\theta}{2} \\ q_2 = u_2 \sin \frac{\theta}{2} \\ q_3 = u_3 \sin \frac{\theta}{2} \end{array} \right. \quad (4-22)$$

由载体坐标系 (b 系) 到地球坐标系 (n 系) 的旋转矩阵可以由四元数来确定, 其姿态旋转矩阵公式如下:

$$R_{b \rightarrow n} = \begin{bmatrix} 1 - 2(q_2^2 + q_3^2) & 2(q_1q_2 - q_0q_3) & 2(q_1q_3 + q_0q_2) \\ 2(q_1q_2 + q_0q_3) & 1 - 2(q_1^2 + q_3^2) & 2(q_2q_3 - q_0q_1) \\ 2(q_1q_3 - q_0q_2) & 2(q_2q_3 + q_0q_1) & 1 - 2(q_1^2 + q_2^2) \end{bmatrix} \quad (4-23)$$

因此, 即可根据四元数结算出所需的三个姿态角 γ 、 θ 和 ψ , 其解算公式如下:

$$\left\{ \begin{array}{l} \gamma = \arctan \left(\frac{2q_0q_1 + 2q_2q_3}{1 - 2(q_1^2 + q_2^2)} \right) \\ \theta = -\arcsin(2q_0q_2 + 2q_1q_3) \\ \psi = \arctan \left(\frac{2q_1q_2 + 2q_0q_3}{1 - 2(q_2^2 + q_3^2)} \right) \end{array} \right. \quad (4-24)$$

为了确定初始状态下的姿态, 可以用陀螺仪采集到三轴角速度 ω_x 、 ω_y 和 ω_z 来计

算四元数的初始值，并可通过迭代更新公式确定下一刻的四元数值，其姿态更新方程如下：

$$\tilde{Q} = \frac{1}{2} \begin{bmatrix} 0 & -\omega_x & -\omega_y & -\omega_z \\ \omega_x & 0 & \omega_z & -\omega_y \\ \omega_y & -\omega_z & 0 & \omega_x \\ \omega_z & \omega_y & -\omega_x & 0 \end{bmatrix} Q \quad (4-25)$$

考虑到不同方法在不同场景下的局限性，文献^[85]指出，欧拉法计算速度相对较慢，且容易出现万向锁问题（奇异解），使得其具有一定的局限性。方向余弦法的优点在于能够全姿态工作，不会出现万向锁问题，但其需要求解 9 个微分方程，计算量相对较大，不具备实时性。四元数法的优点在于能够避免万向锁问题、计算精度高且无奇异性，同时具备实时性和全姿态性。此外，相比方向余弦法，四元数法计算量小，只需要计算出四个变量即可更新状态传播过程。因此，考虑到本文是移动设备为载体的姿态转换，且目前智能手机都能直接获取陀螺仪的四元数信息，所以本文选用四元数法来解算行人航向位置估计。

4.3.2 航向优化

在基于智能手机的航向估计中，陀螺仪、电子罗盘和旋转矢量传感器通常是获取航向角的几种方式。其中陀螺仪通过测量角速度后积分得出航向角，由于陀螺仪存在着一些误差源如漂移误差、零偏误差等，这些误差会随着时间的累积而导致陀螺仪输出的航向角产生误差。电子罗盘由加速度计和磁力计数据结合而成，但易受室内环境的磁场干扰导致航向角不稳定。旋转矢量传感器将陀螺仪、加速度计和磁力计的数据进行结合，输出一个四元数数组，可以带入公式(4-23)求出旋转矩阵，再带入公式(4-24)解算出当前手机姿态角。文献^[86]通过实验分析三种传感器获取航向角，其中陀螺仪和电子罗盘相比旋转矢量传感器获得的航向角误差较大，故本文使用手机内置的虚拟旋转矢量传感器进行计算。

如图 4-13 所示为导航模式下手机固定下直线行走 70m 的手机姿态角(Pitch、Roll、Yaw) 数据，可以观察出尽管手机姿态未发生变化，但三个姿态角仍然产生一定误差波动。由于 PDR 算法是相对定位且存在累积误差，当航向角偏移后，后续位置推算都会在此次误差中积累导致定位轨迹发生漂移。因此本文在航向估计中设计一种转向

判断阈值，减少行走中航向的累积误差。

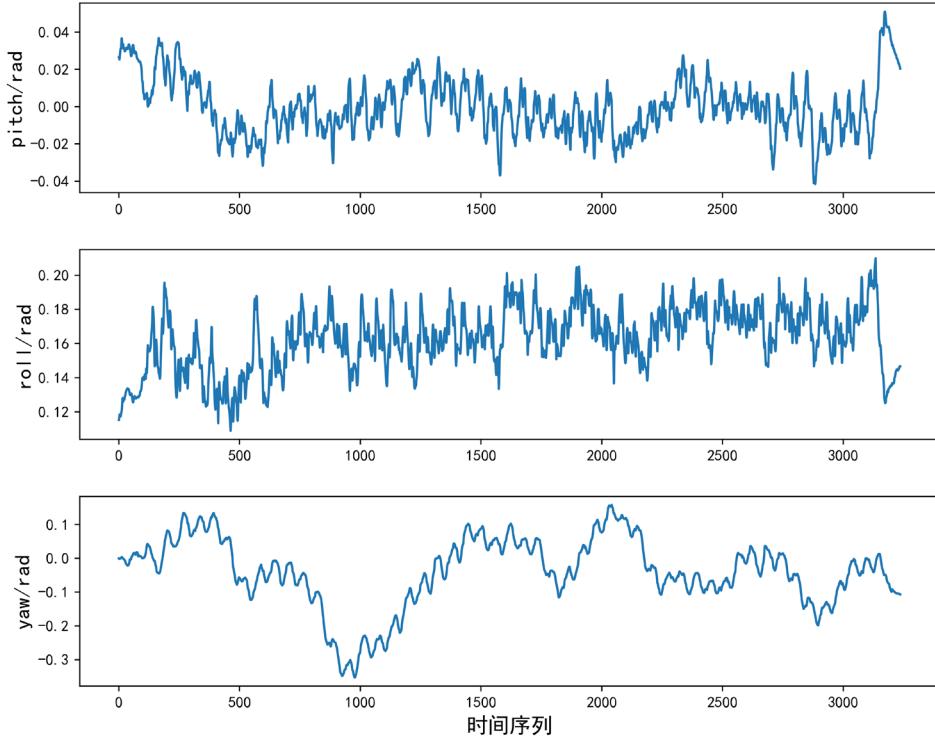


图 4-13 直线行走下手机姿态角

Fig.4-13 Straight line walking handpiece posture angle

图 4-13 中当手机未发生转向时，其偏航角 Yaw 在 $0.3/\text{rad}$ （约 17.2 度）内浮动。为了实现转向检测，故设计转向判断阈值 $\alpha=0.3$ 。当行走中相邻两步偏航角变化超过或低于该阈值时，即判断行人行走发生了转向。针对行人行走习惯和室内环境结构，利用公式(4-26)对向右、直行和向左行走三个主要方向进行了优化补偿。其中， ψ_i 为 i 时刻的偏航角， w 为步频窗口。

$$\psi_i = \begin{cases} -\frac{\pi}{2}, & |\psi_{i+w} - \psi_i| + \frac{\pi}{2} < \alpha \\ 0, & |\psi_{i+w} - \psi_i| < \alpha \\ \frac{\pi}{2}, & |\psi_{i+w} - \psi_i| - \frac{\pi}{2} < \alpha \end{cases} \quad (4-26)$$

为了验证本文航向优化的可靠性，实验沿现代交通工程中心一楼边长为 10m 的正方形轨迹线行走两圈，起点和终点坐标均为 $(0, 0)$ 。航向实验轨迹如图 4-14 所示，其中绿色为航向优化前定位轨迹，红色为使用转向判断阈值优化后的行走轨迹。可见，航向优化前的行人轨迹相对实际路径存在严重漂移，随着距离的增加，定位轨迹的漂

移现象逐渐加重，其行走后半程的定位轨迹几乎无法与实际路径贴合。而本文使用的航向优化方案通过阈值限制偏航角来减少累积误差导致的漂移现象，从而使得行人定位轨迹更加接近实际路径。因此，本文的研究针对 PDR 航向的改进优化，可减少航向角累积误差，提高 PDR 算法的定位精度。

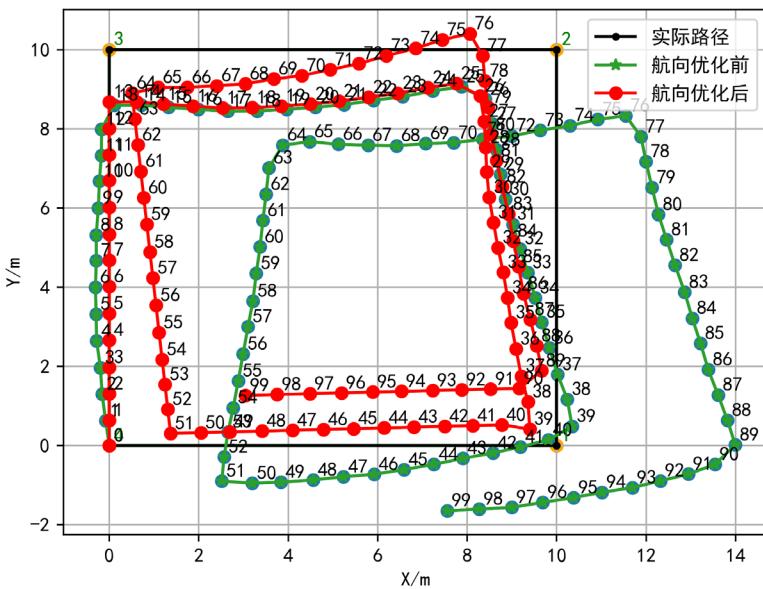


图 4-14 航向优化实验轨迹

Fig.4-14 Experimental trajectory of heading optimization

4.4 本章小结

本章主要探讨 PDR 定位技术的分析研究。首先，基于行人常见的运动模式，结合加速度和角速度等运动信息，本文设计了一种基于深度学习的分类器模型，用于准确识别行人的运动模式。其次，借助运动分类识别的结果，本文提出了一种基于特征约束的峰值检测方法，有效减少了行人步频检测中的计步误差。最后，本文介绍了几种姿态角估计方法，并针对航向估计提出了一种转向判断阈值，通过该优化方法，可降低航向角累积误差，提高 PDR 算法的定位精度。

第五章 融合定位算法与实验分析

本文在三四章分别对蓝牙 RSSI 室内定位算法和 PDR 定位算法进行改进，但两者在实际应用中都有各自的优势和局限性。一方面 PDR 技术在短距离内的准确性高，无需外部信号也能跟踪运动，但它会随着时间的推移累积定位误差。另一方面，蓝牙定位可以在一定范围内提供准确的绝对位置信息，但在复杂室内环境中，蓝牙信号受到干扰时会出现定位不稳定现象。因此，本章利用 EKF 算法将这两种技术结合起来，并通过实验验证融合定位算法可以提高定位精度和鲁棒性。

5.1 PDR/RSSI 融合定位流程与算法

1) 融合定位流程

PDR 算法可以短距离内减少定位误差，而蓝牙定位可以在覆盖范围内提供准确的位置信息，并帮助纠正 PDR 数据中的累计误差。此外，使用多种数据源有助于提高系统的鲁棒性，因为一种数据的错误或不准确可以由另一种数据来纠正。因此，本文在前两章对蓝牙和 PDR 定位技术进行改进后，提出了一种融合定位技术，该技术将蓝牙和 PDR 的定位结果进行融合。融合定位的主要目的是通过结合两种定位技术的优势，提高定位精度和可靠性。融合定位的流程如图 5-1 所示：

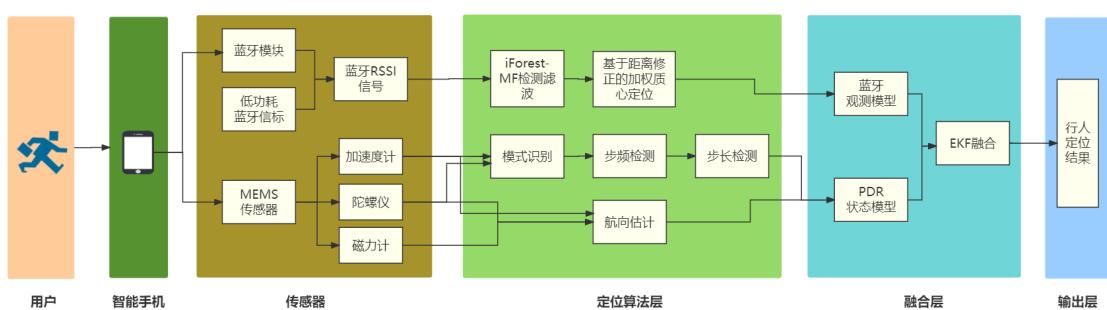


图 5-1 融合定位流程图

Fig.5-1 Flowchart of Fusion Positioning

为了更好地描述融合定位流程，将其分为三部分。第一部分是在三四章内容的单一定位技术改进，主要针对蓝牙和 PDR 子系统进行。这部分的目的是提高两个子定位系统的精度，为后续的融合打下基础。

第二部分旨在基于 PDR 定位系统和蓝牙定位系统分别建立状态模型和观测模型。作为一种基于传感器（如加速度计与陀螺仪）的室内定位方法，PDR 可通过计算步长与方向来估算用户位置及朝向，因此通常用于构建状态模型。但由于惯性导航原件有累积误差，需要将 PDR 技术所得到的步长和航向角信息与蓝牙加权质心定位坐标信息相结合，构建观测模型以校正状态模型预测的位置信息，从而提高室内定位精度。

第三部分是基于扩展卡尔曼进行计算融合，扩展卡尔曼滤波是在卡尔曼滤波的基础上对非线性问题进行估计和滤波的一种方法。通过这种方法，可以减少 PDR 子定位系统的累计误差并抑制蓝牙定位结果的发散，从而提高整个融合定位系统的精度和稳定性。

2) 融合定位算法

通过 2.3.1 节对卡尔曼滤波的背景及其模型介绍得知，它是可靠的最优系统估计算法。由于卡尔曼滤波是一种只能用于处理线性系统的滤波器，但在现实中，很少有真正的线性系统。因此，需要将非线性系统线性化处理，常见的方法有扩展卡尔曼滤波 EKF 和无迹卡尔曼滤波(Unscented Kalman Filter, UKF)，两者都采用了线性化思想，前者是先验线性化，后者是后验线性化。但由于 UKF 需要进行采样，因此计算复杂度通常比 EKF 高。

EKF 的核心思想是先将非线性系统离散化为一组线性系统，再通过 KF 算法进行估计。在 EKF 中，状态转移方程和观测方程是非线性的，但通过泰勒展开可以将其近似为一组线性方程。

EKF 的系统状态方程为：

$$X_k = \begin{bmatrix} x'_k \\ y'_k \\ \theta'_k \end{bmatrix} = \begin{bmatrix} x_{k-1} + s_{k-1} \cdot \sin \theta_{k-1} \\ y_{k-1} + s_{k-1} \cdot \cos \theta_{k-1} \\ \theta_{k-1} + \Delta \theta \end{bmatrix} + W \quad (5-1)$$

观测方程为：

$$Z_k = \begin{bmatrix} x_k \\ y_k \\ \theta_k \\ s_k \end{bmatrix} + V \quad (5-2)$$

在状态方程(5-1)中， x'_k 、 y'_k 为 k 时刻的预测位置， θ'_k 表示 k 时刻预测的航向角，

x_{k-1} 和 y_{k-1} 为前一刻时的融合定位坐标结果, s_{k-1} 和 θ_{k-1} 为前一时刻步长和航向角的观测值, $\Delta\theta$ 为航向角估计增量。在观测方程(5-2)中, x_k^- 和 y_k^- 代表 k 时刻蓝牙测量位置, θ_k 和 s_k 为 k 时刻观测的步长和航向角, 两个方程中的高斯噪声向量用 W 和 V 表示。系统状态转移矩阵 A 和观测矩阵 H 如下:

$$A = \begin{bmatrix} 1 & 0 & s_{k-1} \cdot \cos \theta_{k-1} \\ 0 & 1 & -s_{k-1} \cdot \sin \theta_{k-1} \\ 0 & 0 & 1 \end{bmatrix} \quad (5-3)$$

$$H = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (5-4)$$

在建立完系统状态方程和观测方程后, 还需知初始协方差矩阵 P_1 , 观测噪声协方差矩阵 Q 和过程噪声协方差矩阵 R , 其矩阵初始值如下:

$$P_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad Q = \begin{bmatrix} \delta_x^2 & 0 & 0 \\ 0 & \delta_y^2 & 0 \\ 0 & 0 & \delta_\theta^2 \end{bmatrix} \quad R = \begin{bmatrix} \delta_{x^-}^2 & 0 & 0 & 0 \\ 0 & \delta_{y^-}^2 & 0 & 0 \\ 0 & 0 & \delta_s^2 & 0 \\ 0 & 0 & 0 & \delta_\theta^2 \end{bmatrix} \quad (5-5)$$

其中, δ_x 和 δ_y 分别代表 PDR 定位中在 X、Y 轴的平均误差, δ_{x^-} 和 δ_{y^-} 分别代表蓝牙定位中在 X、Y 轴的平均误差, 而 δ_θ^2 和 δ_s^2 为 PDR 定位中航向角和步长估计误差。

在利用 EKF 线性化完成后, 即刻进行预测估计, 其预测状态估计方程(5-6)和预测协方差矩阵(5-7)如下公式:

$$X'_k = AX_{k-1} \quad (5-6)$$

$$P'_k = AP_{k-1}A^T + Q \quad (5-7)$$

在更新方程中, 卡尔曼增益矩阵为:

$$K_k = P'_k H^T \left(H P'_k H^T + R \right)^{-1} \quad (5-8)$$

系统状态估计更新:

$$X_k = X'_k + K_k (Z_k - H X'_k) \quad (5-9)$$

系统协方差矩阵更新:

$$P_k = (I - K_k H) P_k' \quad (5-10)$$

其中，由于 PDR 定位只能推算相对位置，因此 EKF 融合定位系统的初始位置由蓝牙定位提供。

5.2 融合定位实验验证与分析

5.2.1 实验场景与条件

本文实验场景为现代交通工程中心四楼，在其总长约 45m 的实验走廊中部署蓝牙信标 20 个，信标距离地面约 2.6m 且相邻间隔 1.8m。实验人员行走路线及真实环境如图 5-2 所示：

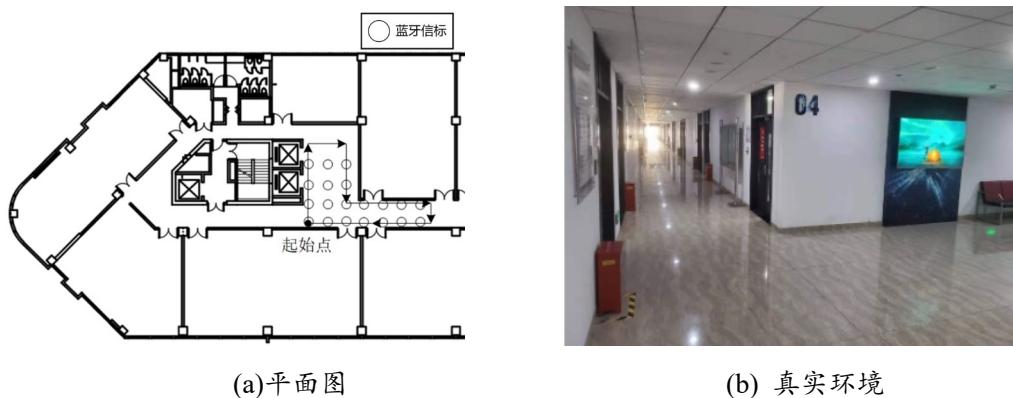


图 5-2 实验场地示意图

Fig.5-3 Schematic diagram of the experimental field

本次实验移动设备选取基于 Android 13 系统的 OPPO Reno6pro 智能手机，通过采集软件 GetSensorData2.1 可以实时获取低功耗蓝牙 RSSI 信号和手机内置加速度计、陀螺仪等数据。其中，蓝牙 RSSI 采集频率为 5Hz，PDR 中传感器采集频率为 50Hz，定位服务端选用 HUAWEI MateBook14。考虑到定位需求，实验人员使用导航模式从起始点开始沿路径方向行走并返回。为了验证本文方法可靠性，实验首先分别对两种定位方法单独验证，再对 EFK 融合定位算法进行验证。

由于实验过程中行人的运动轨迹是动态的，无法实时测量行人移动位置，因此为了反应定位轨迹与实际轨迹相似程度，本文引入基于单向距离^[87]（One Way Distance，OWD）的轨迹相似度评价模型来辅助衡量算法定位精度性能。OWD 距离的基本思想是通过判断两条轨迹围成的面积来评价其相似程度，OWD 距离越小说明两条轨迹越接近，其计算公式(5-11)为：

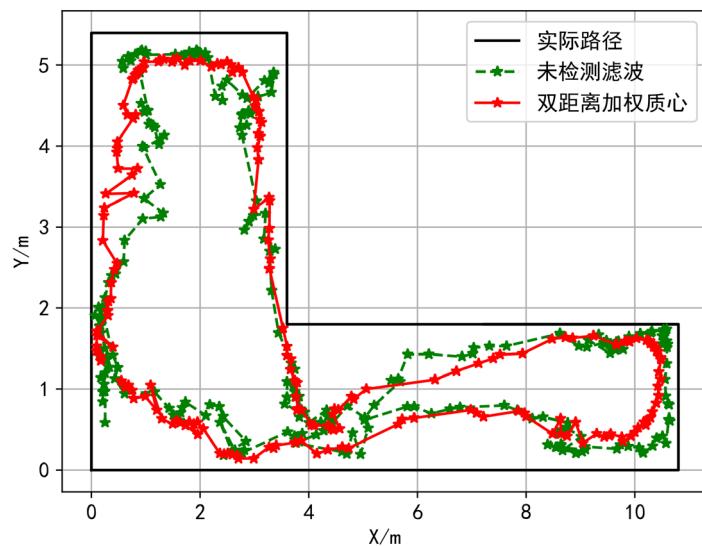
$$\begin{cases} D_{\text{point}}(p, T) = \max_{q \in T}(D_{\text{Euclid}}(p, q)) \\ D(T_1, T_2) = \frac{1}{|T_1|} \cdot \left(\int_{p \in T_1} D_{\text{point}}(p, T_2) dp \right) \\ D_{\text{owd}}(T_1, T_2) = \frac{1}{2} \times (D(T_1, T_2) + D(T_2, T_1)) \end{cases} \quad (5-11)$$

其中 T 为轨迹, $|\cdot|$ 表示轨迹长度, p 和 q 分别为两条轨迹上点, $D_{\text{Euclid}}(p, q)$ 表示两点间的欧式距离, $D_{\text{owd}}(T_1, T_2)$ 表示轨迹 T_1 与 T_2 之间的 OWD 距离。

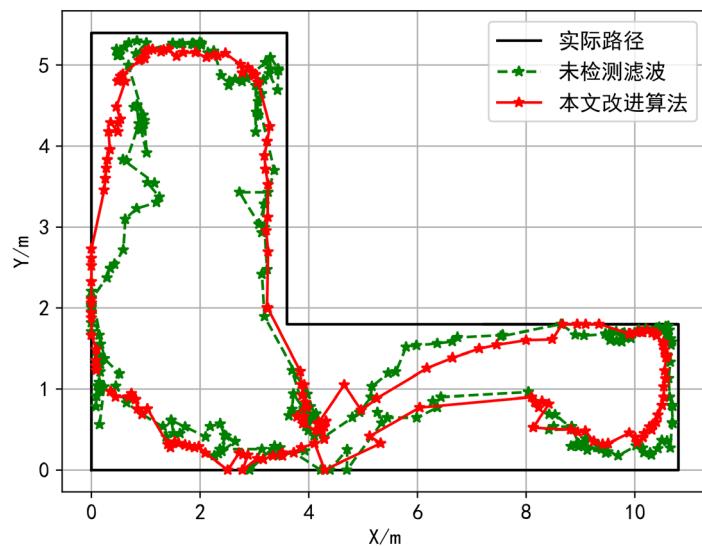
5.2.2 蓝牙定位实验验证

如图 5-3 为使用两种蓝牙定位方法后的运动轨迹曲线, 其中图 5-3 (a) 分别为使用 iForeset-MF 修正前后, 双距离加权质心定位方法得到的定位轨迹。可以看出未修正前进行加权质心定位, 蓝牙 RSSI 信号受干扰时会影响定位轨迹结果, 出现抖动的不规则现象。在使用 RSSI 信号修正后的加权质心定位, 相对修正前定位轨迹更符合真实行走情况, 但在一些位置上仍受定质心分布影响导致定位不够精准。图 5-3 (b) 显示使用本文改进的加权质心定位方法得到的定位轨迹, 可以看出本文方法在修正距离权值后相比双距离质心方法在局部定位结果更精准, 行走轨迹明显, 定位轨迹更趋近于实际路径。

同时, 在 OWD 定位轨迹相似度评估模型中, 双距离质心定位在信号修正前后其 OWD 距离分别为 0.4946 和 0.4853, 本文基于距离修正的加权质心定位在信号修正前后其 OWD 距离分别为 0.4210 和 0.4122, 相比双距离质心定位本文改进方法的定位轨迹更与实际运动轨迹相似。因此可以证明本文 iForeset-MF 修正方法和改进的加权质心定位均有效提高蓝牙定位精度。



(a) 双距离加权质心定位方法轨迹



(b) 本文改进方法轨迹

图 5-3 蓝牙定位轨迹对比

Fig.5-3 Bluetooth positioning track comparison

5.2.3 PDR 定位实验验证

在 PDR 定位中实验人员实际行走 45 步，步长估计模式采用 2.2.2 节介绍的 Weinberg 模型。PDR 定位轨迹实验结果如图 5-4 所示，图中三条轨迹中，原 PDR 算法指步频和航向均未改进的轨迹；原始航向算法仅改进步频未改进航向的轨迹；本文 PDR 算法指针对 PDR 中步频和航向均改进后的定位轨迹；小数字表示行走步数。

从图 5-4 中可以看出，在前 13 步中，三条定位轨迹都能够大致符合实际路径，然

而，在第 13 步之后，经过不同算法计算的轨迹出现了差异。在原 PDR 算法中，由行人运动过程产生的伪波峰被错误地计为真实步数，使得步频检测计数达到 50 步，这种错误导致算法在伪波峰的位置产生一定的路径偏离，进而引起后续轨迹的偏差。尽管原始航向算法对步频进行了修正，但由于传感器的累积误差使得航向角产生一定的偏移，依旧会导致最终定位轨迹发生漂移现象。本文 PDR 算法在第四章对步频检测和航向估计均进行改进后，在定位轨迹中与实际路径大致相似，即使在多次拐弯后依旧能保持与实际轨迹大致相同。

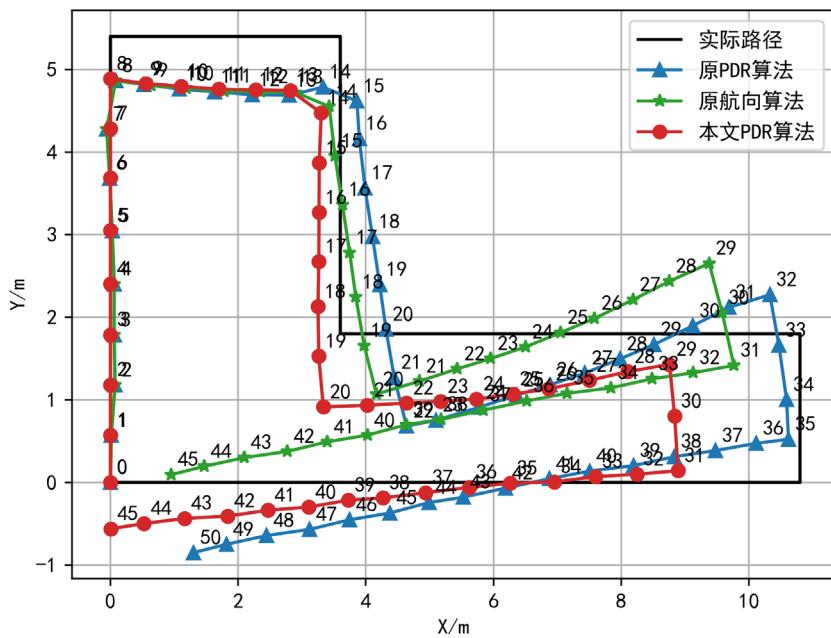


图 5-4 三种 PDR 算法轨迹对比

Fig.5-4 PDR positioning trajectory comparison

5.2.4 EKF 融合定位实验验证

从 5.2.2 节和 5.2.3 节对单一蓝牙 RSSI 和 PDR 定位技术进行定位轨迹分析后，虽然本文三四章的改进方法可以相对提升其定位精度，但两种定位技术由于其技术特性仍会产生一些问题。如蓝牙 RSSI 定位会出现定位结果跳跃、聚集等不合理现象，PDR 算法的累积误差会随着时间积累导致后续定位轨迹偏移，本文将蓝牙定位和 PDR 定位利用 EKF 算法进行融合，定位轨迹如图 5-5 所示。

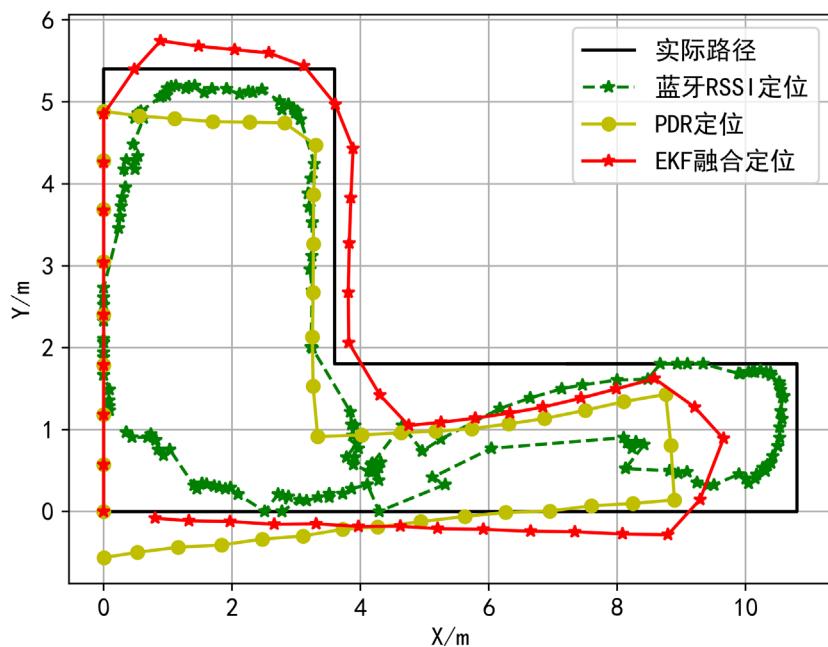


图 5-5 三种定位方法轨迹对比

Fig.5-5 Comparison of trajectories of three positioning methods

由图 5-5 可以看出，蓝牙 RSSI 信号在传播过程中受室内环境的影响会导致定位效果仍存在一定偏差，尤其在较窄转角处会出现信号跳跃、聚集等不合理现象。虽然 PDR 定位大致符合实际路径，但由于 PDR 算法是相对位置推算，使得持续的累积误差会导致后续定位轨迹偏移实际路径。而 EKF 融合定位算法将两者定位结合，使用蓝牙定位结果及时修正 PDR 定位的累积误差而避免其后续定位轨迹偏移。从局部来看 EKF 算法在转弯处轨迹较为平滑，更趋近实际路线。为了定量评估三种定位算法性能，本文根据设置路径参考点来分别统计定位误差，其结果如下表 5-1：

表 5-1 三种定位方法误差比较

Tab.5-1 Error comparison of three positioning methods

定位方式	最大误差/m	最小误差/m	平均误差/m
蓝牙定位	1.857	0.212	0.834
PDR 定位	2.083	0.091	0.806
EKF 融合定位	1.960	0.094	0.723

从表 5-1 中看出，其中蓝牙定位的平均误差最大，为 0.834m；虽然 PDR 定位由于累积误差使得最大误差为 2.083m，但其平均定位误差为 0.806 且低于蓝牙定位；相比前两者，使用 EKF 融合算法的平均定位误差为 0.723m，相比蓝牙定位和 PDR 定

位其 EKF 定位精度分别提高 13.30% 和 10.29%。

由于误差结果是算法定位点与布置参考点对比的误差统计，然而行人实际路径是连续的运动轨迹，因此为了评估三种算法定位轨迹与实际轨迹相似度，引入 OWD 距离轨迹相似度评价计算如下表 5-2：

表 5-2 三种定位方法 OWD 距离比较

Tab.5-2 OWD distance comparison between the three methods

定位方法	OWD 距离指数
蓝牙定位	0.4122
PDR 定位	0.3919
EKF 融合定位	0.3586

从表 5-2 中可知，在三种定位算法中，蓝牙定位的 OWD 距离为 0.4122，说明其定位轨迹与实际运动轨迹相似度最低；PDR 定位 OWD 距离优于蓝牙定位为 0.3919；EKF 融合定位的 OWD 距离最低为 0.3586，相比前两者分别提高 12.96% 和 8.49%，说明其定位轨迹与实际轨迹最为相似，同时也符合表 5-2 其平均误差最优的结果。

5.3 本章小结

本章利用 EKF 融合定位算法对蓝牙 RSSI 定位技术与 PDR 定位技术进行融合。首先，对本章融合定位实现流程进行说明介绍，接着展开说明在融合定位中 EKF 算法的数学模型。然后，通过引入 OWD 轨迹相似度距离分别分析蓝牙 RSSI 定位技术和 EKF 融合定位技术的定位轨迹精度。实验结果表明，在蓝牙定位实验中，本文基于距离修正的加权质心定位方法相比双距离加权质心其 OWD 距离精度提高 15.1%；在 PDR 定位实验中，本文 PDR 算法相比原 PDR 算法和原始航向算法在步频和航向优化中均有所提升；在 EKF 融合定位实验中，EKF 算法相比本文蓝牙算法和 PDR 算法，其平均定位误差精度分别提高 13.30% 和 10.29%，OWD 距离精度分别提高 12.96% 和 8.49%，证明 EKF 融合定位能够有效解决单一方法定位问题，得到更接近实际路径的定位轨迹。

第六章 总结与展望

6.1 本文工作总结

室内定位技术旨在解决卫星导航系统无法在室内提供准确可靠定位服务的问题。随着大型智慧建筑群需求的不断增加，室内位置服务已经广泛应用于机场、大型商场、物流中心和工业场所等环境。然而，由于室内环境的复杂多样，精确和鲁棒的定位技术成为室内定位领域研究的热点。本文针对智能终端设备，研究了基于蓝牙 RSSI 信号特性和其定位技术，改进了 PDR 定位技术，同时，针对蓝牙和 PDR 定位不稳定问题，展开融合定位的研究。本文主要完成工作总结如下：

首先，本文探究了蓝牙 RSSI 信号的分布特性和传播规律。通过分析 RSSI 信号分布和传播受环境干扰的影响，提出一种基于 iForest-MF 的 RSSI 信号修正方法。该方法利用孤立森林算法检测受干扰后的 RSSI 异常值，并通过均值滤波对剔除异常值的信号进行平滑处理。对修正后的 RSSI 信号，使用基于距离修正的加权质心定位算法进行解算。实验结果表明，本文所提出的改进算法，在静态定位中其定位精度提高 9.18%，在动态定位中其 OWD 距离轨迹相似度提高 15.1%。

其次，本文研究了 PDR 定位技术中的步频检测和航向估计的问题。为了降低行人运动中的计步误差和航向角误差，本文根据不同运动模式的加速度和角速度特征信息，设计一种基于 CNN-BiLSTM-SA 的分类器模型，实现 98.52% 的运动模式识别准确率。在运动模式识别后，本文采用低通-卷积平滑的组合滤波方法消除明显伪波峰，并利用自适应最小峰距和自适应动态阈值对加速度波峰进行限制，以解决步频检测中出现的计步过多或漏计问题。实现结果表明，本文所提出的步频检测方法在不同运动模式下平均误差率为 1.31%，优于峰值检测和固定阈值法。针对航向角累积误差导致的方向飘移现象，本文引入转向判断阈值，在航向角计算中对左转、右转和前进三个方向的航向角进行优化，从而使行人定位轨迹更加接近实际路径。

最后，为了解决蓝牙定位结果跳跃、不连续现象和 PDR 定位的累积误差导致轨迹漂移问题，本文在融合定位流程中采用 EKF 算法将蓝牙和 PDR 的定位信息进行融合，以提高定位精度。实验结果表明，相比本文蓝牙算法和 PDR 算法，EKF 算法的

定位平均误差降低 13.30% 和 10.29%，OWD 距离精度分别提高 12.96% 和 8.49%。

6.2 未来工作展望

本文旨在研究行人在室内环境下的蓝牙定位、PDR 定位以及两者融合的方法。尽管已经在上述方法已经进行了深入研究并取得了相关成果，但仍然存在一些局限性和未解决的问题。因此，未来的研究工作可以从以下几个方面展开：

- 1) 蓝牙信标布置方式是影响定位精度的一个因素，未来的研究方向可以从保证定位精度的基础上，考虑如何减少蓝牙信标的数量。
- 2) 考虑到行人在导航时才需要使用手机定位查看的实际需求，实验仅在导航模式下对航向进行优化，因此后续对航向优化可以考虑扩展到多种手机姿态。
- 3) 本文定位实验仅在二维空间开展，未来可以结合室内楼层地图及其他定位方式，拓展在三维空间下的精确定位。

参考文献

- [1] 邵子灏,杨世宇,马国杰.室内信息服务的基础——低成本定位技术研究综述[J].计算机科学,2022,49(09):228-235.
- [2] 王慧强,高凯旋,吕宏武.高精度室内定位研究评述及未来演进展望[J].通信学报,2021,42(07):198-210.
- [3] 柳景斌,赵智博,胡宁松,黄格格,龚晓东,杨盛.室内高精度定位技术总结与展望[J].武汉大学学报(信息科学版),2022,47(07):997-1008.
- [4] 申邵辉.基于 iBeacon 技术的室内定位系统的研究和实现[D].湖南师范大学, 2016.
- [5] Bencak P, Hercog D, Lerher T. Indoor positioning system based on bluetooth low energy technology and a nature-inspired optimization algorithm[J]. Electronics, 2022, 11(3): 308.
- [6] Lie M M K, Kusuma G P. A fingerprint-based coarse-to-fine algorithm for indoor positioning system using Bluetooth Low Energy[J]. Neural Computing and Applications, 2021, 33: 2735-2751.
- [7] 李华亮.高鲁棒性 RSSI 室内指纹定位算法研究[D].吉林大学, 2021.
- [8] Shen Y, Hwang B, Jeong J P. Particle filtering-based indoor positioning system for beacon tag tracking[J]. Ieee Access, 2020, 8: 226445-226460.
- [9] 李海啸.面向智能工厂的无线传感器网络定位技术研究[D].中国科学院大学(中国科学院沈阳计算技术研究所),2021.
- [10] Xue W, Hua X, Li Q, et al. A new weighted algorithm based on the uneven spatial resolution of RSSI for indoor localization[J]. Ieee Access, 2018, 6: 26588-26595.
- [11] 唐宗山,邓中亮,莫君,等.一种基于最大似然估计的 RSSI 定位算法[J].第九届中国卫星导航学术年会论文集——S10 多源融合导航技术, 2018.
- [12] 陶金龙,康志伟,骆坚.基于 RSSI 测距的加权概率定位算法[J].电子测量与仪器学报,2014,28(10):1123-1129.
- [13] Li J, Zhang B, Liu H, et al. An indoor hybrid localization approach based on signal propagation model and fingerprinting[J]. International Journal of Smart Home, 2013, 7(6): 157-170.
- [14] Zhuang Y, Syed Z, Li Y, et al. Evaluation of two WiFi positioning systems based on autonomous crowdsourcing of handheld devices for indoor navigation[J]. IEEE Transactions on Mobile Computing, 2015, 15(8): 1982-1995.
- [15] 林玮,陈传峰.基于 RSSI 的无线传感器网络三角形质心定位算法[J].现代电子技术,2009,32(02):180-182.
- [16] 熊海龙,刘漫丹,刘庆威.基于校正的无线传感器网络加权定位算法[J].华东理工大学学报(自然

- 科学版),2014,40(02):225-229.
- [17] 吴斌.WSN 节点定位技术的质心定位算法优化策略[J].通信技术,2020,53(12):2983-2988.
- [18] 李桢,黄劲松.基于 RSSI 抗差滤波的 WiFi 定位[J].武汉大学学报(信息科学版),2016,41(03):361-366.
- [19] Tan J, Fan X, Wang S, et al. Optimization-based Wi-Fi radio map construction for indoor positioning using only smart phones[J]. Sensors, 2018, 18(9): 3095.
- [20] Ren J, Wang Y, Niu C, et al. A novel clustering algorithm for Wi-Fi indoor positioning[J]. IEEE Access, 2019, 7: 122428-122434.
- [21] Shi Q, Zhao S, Cui X, et al. Anchor self-localization algorithm based on UWB ranging and inertial measurements[J]. Tsinghua Science and Technology, 2019, 24(6): 728-737.
- [22] 田亚飞. 基于 UWB 的室内无线定位技术研究[D]. 长春: 吉林大学, 2019.
- [23] 陆冰琳.室内环境下基于 UWB 的 TDOA/AOA 三维混合定位算法[J].电子元器件与信息技术,2022,6(01):159-163.
- [24] Munoz D, Lara F B, Vargas C, et al. Position location techniques and applications[M]. Academic Press, 2009.
- [25] Xu H, Wu M, Li P, et al. An RFID indoor positioning algorithm based on support vector regression[J]. Sensors, 2018, 18(5): 1504.
- [26] 王辉,赵卫伟,宋宇.RFID 定位方法与影响精度因素综述[J].北方工业大学学报,2018,30(05):64-70.
- [27] Wang W, Wang C, Wang Z, et al. An Improved PDR Localization Algorithm Based on Particle Filter[J]. Computing & Informatics, 2020, 39(1).
- [28] 栾鹏. 基于 PDR 的高精度室内融合定位方法研究[D].哈尔滨工程大学,2018.
- [29] Kang X, Huang B, Qi G. A novel walking detection and step counting algorithm using unconstrained smartphones[J]. Sensors, 2018, 18(1): 297.
- [30] 费程羽,苏中,李擎.行人惯性导航零速检测算法[J].传感器与微系统,2016,35(03):147-150+153.
- [31] Pan M S, Lin H W. A step counting algorithm for smartphone users: Design and implementation[J]. IEEE Sensors Journal, 2014, 15(4): 2296-2305.
- [32] Wang B, Liu X, Yu B, et al. Pedestrian dead reckoning based on motion mode recognition using a smartphone[J]. Sensors, 2018, 18(6): 1811.
- [33] Pham V T, Nguyen D A, Dang N D, et al. Highly accurate step counting at various walking states using low-cost inertial measurement unit support indoor positioning system[J]. Sensors, 2018, 18(10): 3186.
- [34] Yao Y, Pan L, Fen W, et al. A robust step detection and stride length estimation for pedestrian dead reckoning using a smartphone[J]. IEEE Sensors Journal, 2020, 20(17): 9685-9697.
- [35] Tian Q, Salcic Z, Kevin I, et al. A multi-mode dead reckoning system for pedestrian tracking using

- smartphones[J]. IEEE Sensors Journal, 2015, 16(7): 2079-2093.
- [36] Yang R, Wang B. PACP: A position-independent activity recognition method using smartphone sensors[J]. Information, 2016, 7(4): 72.
- [37] Vildjiounaite E, Malm E J, Kaartinen J, et al. Location estimation indoors by means of small computing power devices, accelerometers, magnetic sensors, and map knowledge[C]. Pervasive Computing: First International Conference, Pervasive 2002 Zurich, Switzerland, August 26–28, 2002 Proceedings 1. Springer Berlin Heidelberg, 2002: 211-224.
- [38] Ladetto Q. On foot navigation: continuous step calibration using both complementary recursive prediction and adaptive Kalman filtering[C]. Proceedings of the 13th International Technical Meeting of the Satellite Division of The Institute of Navigation (ION GPS 2000). 2000: 1735-1740.
- [39] Weinberg H. Using the ADXL202 in pedometer and personal navigation applications[J]. Analog Devices AN-602 application note, 2002, 2(2): 1-6.
- [40] Tian Q, Salcic Z, Kevin I, et al. A multi-mode dead reckoning system for pedestrian tracking using smartphones[J]. IEEE Sensors Journal, 2015, 16(7): 2079-2093.
- [41] 李景文, 韦晶闪, 周俊芬, 毛佳影, 陆妍玲. 融合 UWB+PDR 的室内定位方法改进[J]. 测绘通报, 2022(03): 36-40.
- [42] Xu S, Wang Y, Sun M, et al. A Real-Time BLE/PDR Integrated System by Using an Improved Robust Filter for Indoor Position[J]. Applied Sciences, 2021, 11(17): 8170.
- [43] 韩冷, 戴鹏, 阳媛等. 多源信息融合的室内定位方法[J]. 传感器与微系统, 2020, 39(07): 21-24.
- [44] Song S, Feng F, Xu J. Review of Geomagnetic Indoor Positioning[C]. 2020 IEEE 4th International Conference on Frontiers of Sensors Technologies (ICFST). IEEE, 2020: 30-33.
- [45] 周家鹏, 汪云甲, 李昕, 等. 地磁室内定位技术研究[J]. 2019, (1): 18-22.
- [46] Kasmi Z, Norrdine A, Blankenbach J. Towards a decentralized magnetic indoor positioning system[J]. Sensors, 2015, 15(12): 30319-30339.
- [47] Gozick B, Subbu K P, Dantu R, et al. Magnetic maps for indoor navigation[J]. IEEE Transactions on Instrumentation and Measurement, 2011, 60(12): 3883-3891.
- [48] 王睿. 单目视觉 SLAM 关键技术研究[D]. 中国矿业大学, 2020.
- [49] Fu Q, Yu H, Lai L, et al. A robust RGB-D SLAM system with points and lines for low texture indoor environments[J]. IEEE Sensors Journal, 2019, 19(21): 9908-9920.
- [50] Zhang X, Lin J, Li Q, et al. Continuous indoor visual localization using a spatial model and constraint[J]. IEEE Access, 2020, 8: 69800-69815.
- [51] Joshi R, Hiwale A, Birajdar S, et al. Indoor navigation with augmented reality[C]. ICCCE 2019: Proceedings of the 2nd International Conference on Communications and Cyber Physical Engineering. Springer Singapore, 2020: 159-165.
- [52] 刘伟, 佟天旭, 田咪等. 自动驾驶车辆视觉全局定位研究综述[J]. 北京信息科技大学学报(自然科学版), 2022, 37(05): 74-83.

- [53] Sainjeon F, Gaboury S, Bouchard B. Real-time indoor localization in smart homes using ultrasound technology[C].Proceedings of the 9th acm international conference on pervasive technologies related to assistive environments. 2016: 1-4.
- [54] 宋博涵. 基于超声波测距的室内移动机器人自主导航技术研究[D].哈尔滨工业大学,2017.
- [55] Yu N, Zhan X, Zhao S, et al. A precise dead reckoning algorithm based on Bluetooth and multiple sensors[J]. IEEE Internet of Things Journal, 2017, 5(1): 336-351.
- [56] Li G, Geng E, Ye Z, et al. An indoor positioning algorithm based on RSSI real-time correction[C].2018 14th IEEE International Conference on Signal Processing (ICSP). IEEE, 2018: 129-133.
- [57] Feng Z, Mo L, Li M. Analysis of low energy consumption wireless sensor with BLE[C].2015 IEEE SENSORS. IEEE, 2015: 1-4.
- [58] Dickinson P, Cielniak G, Szymanezyk O, et al. Indoor positioning of shoppers using a network of Bluetooth Low Energy beacons[C].2016 International Conference on Indoor Positioning and Indoor Navigation (IPIN). IEEE, 2016: 1-8.
- [59] 高伟,侯聪毅,许万旸,陈玄.室内导航定位技术研究进展与展望[J].导航定位学报,2019,7(01):10-17.
- [60] 张亚磊,王坚,韩厚增,杨燈.蓝牙室内测距模型研究与精度分析[J].测绘科学,2021,46(03):1-7+66.
- [61] 毕京学,甄杰,郭英.室内定位无线接收信号强度测距模型的研究[J].导航定位学报,2014,2(04):8-10.
- [62] 任晓奎,于百川,李岩.基于 RSSI 的加权质心定位算法的改进[J].传感器与微系统,2021,40(11):150-153.
- [63] Martins P, Abbasi M, Sá F, et al. Improving bluetooth beacon-based indoor location and fingerprinting[J]. Journal of Ambient Intelligence and Humanized Computing, 2020, 11: 3907-3919.
- [64] 邹林杰. 基于 WiFi 和蓝牙的室内融合定位技术研究[D].辽宁工业大学,2018.
- [65] Ferreira D, Souza R, Carvalho C. Qa-knn: Indoor localization based on quartile analysis and the knn classifier for wireless networks[J]. Sensors, 2020, 20(17): 4714.
- [66] Yen L, Yan C H, Renu S, et al. A modified WKNN indoor Wi-Fi localization method with differential coordinates[C].2017 International Conference on Applied System Innovation (ICASI). IEEE, 2017: 1822-1824.
- [67] 曹晓祥, 陈国良. 一种改进的组合定权的指纹定位算法[J]. 测绘通报, 2018(2): 6-10.
- [68] Ho N H, Truong P H, Jeong G M. Step-detection and adaptive step-length estimation for pedestrian dead-reckoning at various walking speeds using a smartphone[J]. Sensors, 2016, 16(9): 1423.
- [69] Vezočnik M, Juric M B. Average step length estimation models' evaluation using inertial sensors: A review[J]. IEEE Sensors Journal, 2018, 19(2): 396-403.
- [70] A. Y. Wang and L. Wang, "Walking step prediction based on GA optimized neural network

- algorithm", Proc. 2nd IEEE Int. Conf. Comput. Intell. Appl. (ICCIA), pp. 295-298, Sep. 2017.
- [71] 李蓉,李哲.基于 MEMS 室内定位的姿态角解算[J].计算机与数字工程,2017,45(12):2379-2382.
- [72] 刘元成,蔡成林,韦照川,彭滨,沈文波.基于 PDR 和地磁匹配融合的楼层定位方法[J].传感技术学报,2020,33(04):557-563.
- [73] 胡文强,胡建鹏,吴飞等.基于 EKF 的初始状态自适应室内融合定位算法[J].传感器与微系统,2022,41(11):147-151.
- [74] Fetzer T, Ebner F, Deinzer F, et al. On Monte Carlo smoothing in multi sensor indoor localisation[C].2016 International Conference on Indoor Positioning and Indoor Navigation (IPIN). IEEE, 2016: 1-8.
- [75] Kalman R E. A new approach to linear filtering and prediction problems[J]. 1960.
- [76] Chopin N. A sequential particle filter method for static models[J]. Biometrika, 2002, 89(3): 539-552.
- [77] 陈维克,李文锋,首珩,袁兵.基于 RSSI的无线传感器网络加权质心定位算法[J].武汉理工大学学报(交通科学与工程版),2006(02):265-268.
- [78] 吕振,赵鹏飞.一种改进的无线传感器网络加权质心定位算法[J].计算机测量与控制,2013,21(04):1102-1104.
- [79] Hou X, Bergmann J. Pedestrian dead reckoning with wearable sensors: A systematic review[J]. IEEE Sensors Journal, 2020, 21(1): 143-152.
- [80] Wang Q, Ye L, Luo H, et al. Pedestrian walking distance estimation based on smartphone mode recognition[J]. Remote Sensing, 2019, 11(9): 1140.
- [81] Siami-Namini S, Tavakoli N, Namin A S. The performance of LSTM and BiLSTM in forecasting time series[C].2019 IEEE International Conference on Big Data (Big Data). IEEE, 2019: 3285-3292.
- [82] Wei S, Qu Q, Zeng X, et al. Self-attention bi-lstm networks for radar signal modulation recognition[J]. IEEE Transactions on Microwave Theory and Techniques, 2021, 69(11): 5160-5172.
- [83] Rusiecki A. Trimmed categorical cross - entropy for deep learning with label noise[J]. Electronics Letters, 2019, 55(6): 319-320.
- [84] Wang X, Chen G, Cao X, et al. Robust and accurate step counting based on motion mode recognition for pedestrian indoor positioning using a smartphone[J]. IEEE Sensors Journal, 2021, 22(6): 4893-4907.
- [85] Lipka M, Sippel E, Vossiek M. An extended Kalman filter for direct, real-time, phase-based high precision indoor localization[J]. IEEE Access, 2019, 7: 25288-25297.
- [86] 冯昆. 基于 PDR/BLE 的 EKF 室内融合定位系统研究与实现[D].中国矿业大学,2018.
- [87] Lin B, Su J. One way distance: For shape based similarity search of moving object trajectories[J]. GeoInformatica, 2008, 12: 117-142.

攻读硕士学位期间发表的学术论文及取得的相关科研成果

1. 发表的学术论文

- [1] 第一作者. 结合 CNN-BiLSTM-SA 运动模式识别的自适应步频检测方法[J]. 全球定位系统, 2022. (CSCD)
- [2] 第五作者. SUES-200: A Multi-height Multi-scene Cross-view Image Benchmark Across Drone and Satellite[J], IEEE Transactions on Circuits and Systems for Video Technology, 2023. (SCI 一区)

2. 取得的相关科研成果及获奖情况

2.1 发明专利

- 2.2 第一作者. 一种基于 CNN-LSTM 运动模式识别的自适应步频检测方法[P]. 上海市: CN115439934A, 2022-12-06.

2.3 获奖情况

- [1] “华为杯”第十八届中国研究生数学建模竞赛, 全国二等奖, 2021.12
- [2] “华为杯”第十九届中国研究生数学建模竞赛, 全国三等奖, 2023.01
- [3] “兆易创新杯”第十六届中国研究生电子设计竞赛, 上海市二等奖, 2021.08
- [4] 2020 年上海工程技术大学学业奖学金, 一等奖, 2020.10
- [5] 2021 年上海工程技术大学学业奖学金, 二等奖, 2021.10
- [6] 2022 年上海工程技术大学学业奖学金, 二等奖, 2022.10

致 谢

当我站在硕士论文完成的时刻，我感到无尽的喜悦和满足。在这段充满挑战和收获的研究旅程中，我有幸得到了许多人的关心、支持和激励。在这里，我想向所有那些在我学术生涯中给予我帮助和鼓励的人表示最诚挚的谢意。

首先，我要深深地感谢我的导师吴飞教授。您不仅在学术上给予我耐心的指导和深入的学术洞察，更在我面临困难和挫折时，给予我鼓舞和支持。您对学术研究的严谨态度和卓越能力，让我受益匪浅，从您身上我学到了追求卓越的精神和智慧。

我还要感谢朱海老师和尹玲老师，您的独到见解和悉心指导让我受益匪浅。您在我的研究中提供的专业建议和深厚学术背景，为我研究成果的提升起到了至关重要的推动作用。

此外，我还要感谢 7416 这温馨的大家庭，感谢我的同门朱润哲和杨明泽，这三年每天朝夕相伴、并肩作战，在学习中一起探讨进步，在生活一起畅言分享，在我的研究生生涯留下美好的记忆。感谢郭丞、胡毅轩、聂大惟、张雯涛、陆雯霞、韩学法等师兄师姐，在你们的帮助下很快融入这个大家庭，并提供很多意见与支持。感谢蔡美玉、张开昱、李家乐等师弟师妹，在 7146 大家庭中承上启下成为中流砥柱，祝你们的未来越来越好。

最后，我要感谢我的家人们，感谢他们一直以来的支持和包容。他们的无私奉献和关爱，是我前进路上最坚实的后盾和最温暖的依靠。

在这里，我再次向所有关心、支持、鼓励、帮助过我的人们致以最真诚的谢意，是你们的支持和鼓励，让我在学术道路上不断前行，让我在人生路上收获满满的成长和收获。最后，我祝愿您们身体健康、心想事成！